Taller 2: Mercado laboral y micronegocios en Colombia

Informe técnico y metodológico · Grupo 10

Juan José Echeverry · Miguelangel Palma · Sergio López

Maestría en Economía Aplicada (MECA) · Taller de programación en R · Universidad de los Andes · 2026-02

1. Conformación y unión de las bases de datos

1.1. GEIH: generalidades, lógica del pegue y controles

La Gran Encuesta Integrada de Hogares (GEIH) es la fuente oficial del DANE para medir el mercado laboral, los ingresos y las condiciones sociodemográficas de los hogares colombianos. La recolección es mensual y continua, con cobertura para el total nacional, cabeceras, centros poblados y rural disperso, así como dominios departamentales y ciudades principales [1]. Cada registro individual se identifica mediante tres variables jerárquicas: * `DIRECTORIO`: identifica la vivienda seleccionada en la muestra. * `SECUENCIA_P`: identifica el hogar dentro de la vivienda. * `ORDEN`: número consecutivo asignado a cada persona dentro del hogar.

Para armar las bases anuales, se utilizaron dos ciclos `for`: uno para recorrer los años 2023 y 2024, y otro para iterar sobre los doce meses de cada año. En cada mes se leen los cuatro módulos de la encuesta mediante `read.csv(sep = ";")`, usando codificación UTF-8 para leer correctamente los nombres de archivo con tildes y caracteres especiales. El código contempla la variación del archivo de marzo de 2024, nombrado en singular como `"No ocupado.CSV"`.

La unión mensual se construyó con un `left_join` tomando como base el módulo de *Características generales*, pues contiene a todas las personas encuestadas sin importar edad ni condición de ocupación. Para reducir el consumo de memoria, se seleccionaron las variables necesarias con `select()` inmediatamente después de leer cada archivo: General pasó de entre 67 y 74 columnas a 17; Fuerza, de 43 a 7; Ocupados, de 200 a 23; y No ocupados, de entre 37 y 38 a 4, antes de unir y apilar los meses (`1_1_eficiencia.csv`).

La integridad de las uniones se comprobó con dos controles en el código: 1. Unicidad de llaves: la combinación `DIRECTORIO + SECUENCIA_P + ORDEN` no presentó registros duplicados en ningún módulo de los 24 meses analizados (`1_1_verificacion_llaves.csv`). 2. Filas del módulo base: el total de observaciones tras cada unión coincidió exactamente con el tamaño de *Características generales*, confirmando que el pegue no multiplicó registros (`1_1_verificacion_pegues.csv`).

1.2. Tamaño muestral y consistencia de las definiciones laborales

Tabla 1. Registros muestrales por módulo, GEIH 2024. El total anual suma observaciones mensuales; no representa personas únicas debido a la rotación muestral.

Mes	General	Fuerza	Ocupados	No ocupados
Enero	70.648	55.738	28.815	26.923
Febrero	72.148	56.856	29.943	26.913
Marzo	70.719	56.063	29.638	26.425
Abril	70.457	55.696	29.741	25.955
Mayo	70.188	55.773	30.142	25.631
Junio	70.020	55.530	29.925	25.605
Julio	69.694	55.038	29.929	25.109
Agosto	69.390	54.844	29.951	24.893
Septiembre	68.341	54.228	29.383	24.845
Octubre	67.216	53.631	29.127	24.504
Noviembre	66.235	52.679	28.924	23.755
Diciembre	64.627	51.727	28.154	23.573
TOTAL_2024	829.683	657.803	353.672	304.131

La diferencia en el número de observaciones proviene de la estructura del cuestionario [1]: * *Características generales* (829.683 observaciones en 2024) incluye a todas las personas del hogar encuestado. * *Fuerza de trabajo* (657.803 observaciones) se aplica solo a la Población en Edad de Trabajar (PET, 15 años o más). * *Ocupados* (353.672) y *No ocupados* (304.131) dividen a la PET en dos grupos mutuamente excluyentes cuya suma es igual al total de personas de 15 años o más.

En el archivo `1_2_consistencia_laboral_2024.csv` se comprobó mes a mes que se cumplen las identidades básicas del mercado de trabajo:

$$\text{PET} = \text{Fuerza de Trabajo (FT)} + \text{Población Fuera de la Fuerza de Trabajo (FFT)}$$

$$\text{Fuerza de Trabajo (FT)} = \text{Ocupados (OCI)} + \text{Desocupados (DSI)}$$

La diferencia entre la suma de los componentes y los totales agregados fue cero en todos los meses.

1.3. Base analítica y diccionario de variables

La base analítica conserva las variables indicadas para los ejercicios posteriores, añade las necesarias para clasificar el empleo informal (`EI`) y genera la variable `ANIO` a partir de `PERIODO`. Se verificó mediante código que la tabla final contenga únicamente este conjunto de columnas.

Tabla 2. Diccionario de variables analíticas de la GEIH utilizadas en 1.3(a a d) [1].

Variable	Módulo	Descripción	Categoría / unidad
DIRECTORIO	General	Identificador del directorio	Identificador alfanumérico
SECUENCIA_P	General	Secuencia del hogar	Secuencia
ORDEN	General	Número de orden de la persona	Secuencia persona
PERIODO	General	Período de la encuesta	AAAAMMDD
MES	General	Mes de la encuesta	Mes (1-12)
P3271	General	Sexo	1 Hombre; 2 Mujer
P3042	General	Nivel educativo	Nivel educativo (1-13); 99 No sabe, no informa
P6090	General	Afiliación a seguridad social en salud	1 Sí; 2 No; 9 No sabe, no informa
P6040	General	Edad	Años cumplidos
P6160	General	Sabe leer y escribir	1 Sí; 2 No
DPTO	General	Departamento	Código DIVIPOLA departamental
AREA	General	Área geográfica	Código de ciudad / área metropolitana
CLASE	General	Clase geográfica	1 Cabecera; 2 Centros poblados y rural disperso
FEX_C18	General	Factor de expansión	Ponderador muestral
PT	General	Población total	Indicador = 1
PET	Fuerza	Población en edad de trabajar	PET = 1 (>= 15 años)
FT	Fuerza	Población en la fuerza de trabajo	FT = 1 (Fuerza de trabajo)
FFT	Fuerza	Población fuera de la fuerza de trabajo	FFT = 1 (Inactivos)
P6240	Fuerza	Actividad principal	Actividad principal (1-6)
OCI	Ocupados	Población ocupada	OCI = 1 (Ocupados)
RAMA2D_R4	Ocupados	Rama de actividad económica	CIIU Rev. 4 (2 dígitos)
P6430	Ocupados	Posición ocupacional	Posición ocupacional (1-9)
INGLABO	Ocupados	Ingreso laboral monetario	COP mensuales
DSI	No ocupados	Población desocupada	DSI = 1 (Desocupados)

Categorías: `P3042`: 1 ninguno, 2 preescolar, 3 primaria, 4 secundaria, 5 media académica, 6 media técnica, 7 normalista, 8 técnica profesional, 9 tecnológica, 10 universitaria, 11 especialización, 12 maestría, 13 doctorado y 99 no sabe/no informa. `P6240`: 1 trabajando, 2 buscando trabajo, 3 estudiando, 4 oficios del hogar, 5 incapacitado permanente y 6 otra actividad. `P6430`: 1 empleado particular, 2 empleado del gobierno, 3 doméstico, 4 cuenta propia, 5 patrón, 6 familiar sin remuneración, 7 sin remuneración en otros hogares, 8 jornalero y 9 otro.

Las variables `DPTO`, `AREA` y `CLASE` miden dimensiones territoriales diferentes y no son intercambiables: * `DPTO` corresponde a la división político-administrativa departamental. * `AREA` identifica los dominios de ciudades y áreas metropolitanas. * `CLASE` distingue la cabecera municipal (valor 1) de los centros poblados y la zona rural dispersa, agrupados en el valor 2 de estos microdatos. Un departamento contiene distintas clases geográficas y no necesariamente coincide con un área metropolitana.

1.4. Integración GEIH y EMICRON 2024

La muestra de la Encuesta de Micronegocios (EMICRON) se toma de la GEIH: selecciona a ocupados clasificados como trabajadores por cuenta propia o empleadores en unidades de hasta nueve personas [2]. Esto genera una relación asimétrica entre las fuentes: todo micronegocio de EMICRON proviene de un hogar encuestado en la GEIH, pero solo una pequeña parte de los encuestados de la GEIH administra un micronegocio. En cobertura geográfica, la GEIH abarca el total nacional, mientras que EMICRON excluye de su marco a ocho departamentos de la Amazonía y Orinoquía (Amazonas, Arauca, Casanare, Guainía, Guaviare, Putumayo, Vaupés y Vichada). Los factores de expansión también difieren: `F_EXP` expande unidades económicas anuales, mientras que `FEX_C18` expande personas.

Para definir la llave de enlace, se examinó `SECUENCIA_ENCUESTA`: toma valores de 1 a 16 y hay hogares con uno a seis propietarios. Se comprobó una coincidencia única con `ORDEN` para los 78.501 registros (`1_4_relacion_orden.csv`). La llave de persona es `DIRECTORIO + SECUENCIA_P + ORDEN`. El contraste temporal siguiente muestra que `MES_REF` está un mes adelante del mes GEIH, incluyendo diciembre de 2023 para enero de 2024. EMICRON se recolecta en una segunda etapa y sus ventas corresponden al mes previo a su entrevista; las preguntas de crédito y ahorro se refieren al año anterior [2]. La relación observada delimita los meses enlazables y no permite equiparar los meses de ambas encuestas.

Contraste de las tres hipótesis temporales (`1_4_relacion_meses.csv`).

MES_REF respecto a GEIH	Coincidencias	Porcentaje
Mismo mes	0	0 %
Un mes atrás	0	0 %
Un mes adelante	78.501	100 %

Tabla 3. Auditoría mensual del enlace entre EMICRON y GEIH 2024 (`base_micro`).

Mes ref.	EMICRON	Enlazados	Sin enlace	Enlace (%)
ENERO	6.747	0	6.747	0
FEBRERO	6.337	6.337	0	100
MARZO	6.756	6.756	0	100
ABRIL	6.571	6.571	0	100
MAYO	6.604	6.604	0	100
JUNIO	6.544	6.544	0	100
JULIO	6.459	6.459	0	100
AGOSTO	6.661	6.661	0	100
SEPTIEMBRE	6.690	6.690	0	100
OCTUBRE	6.572	6.572	0	100
NOVIEMBRE	6.201	6.201	0	100
DICIEMBRE	6.359	6.359	0	100

Los módulos de identificación, características, inclusión financiera y ventas se unieron con `left_join`, tomando identificación como base. La llave `DIRECTORIO + SECUENCIA_P + SECUENCIA_ENCUESTA` no tiene duplicados en ninguno de los cuatro módulos; la base `base_micro` conserva las 78.501 filas, de las cuales 71.754 (91,41 %) enlazaron con la GEIH de 2024. La verificación con variables comunes mostró una coincidencia del 100 % en sexo (`P35` con `P3271`), edad (`P241` con `P6040`) y zona geográfica (`CLASE_TE` con `CLASE`).

Los 6.747 micronegocios sin enlace en la GEIH 2024 (8,59 %) corresponden a enero de 2024. Debido al desfase de un mes en la recolección, esos informantes fueron encuestados en la GEIH en diciembre de 2023. Al revisar los archivos de 2023, se confirmó que los 6.747 registros están en esa base (`1_4_fuera_2024.csv`). Por tanto, al limitar la unión a los archivos de 2024, este grupo queda fuera por diseño temporal y no por un error en la llave.

Entre los propietarios enlazados, el 88,53 % declaró en la GEIH ser trabajador por cuenta propia y el 9,22 % patrón o empleador (97,75 % en conjunto). El 2,25 % restante reportó otras posiciones, como obrero particular o trabajador sin remuneración en empresas de otros hogares (`1_4_posicion_ocupacional.csv`). Las diferencias podrían relacionarse con transiciones ocupacionales, actividades secundarias o imprecisiones de reporte; el cruce no permite distinguir estas explicaciones. Para la medición del empleo, la posición ocupacional declarada en la GEIH y la identificación como propietario en EMICRON describen aspectos distintos de la actividad económica de una persona.

2. Indicadores de mercado laboral

2.1. Tasas trimestrales y poblaciones según sexo

De acuerdo con la metodología del DANE [1], los principales indicadores laborales se definen como relaciones porcentuales entre subconjuntos de la población:

$$\text{Tasa Global de Participación (TGP)} = \left(\frac{\text{Fuerza de Trabajo}}{\text{Población en Edad de Trabajar}}\right) \times 100$$

$$\text{Tasa de Ocupación (TO)} = \left(\frac{\text{Población Ocupada}}{\text{Población en Edad de Trabajar}}\right) \times 100$$

$$\text{Tasa de Desempleo (TD)} = \left(\frac{\text{Población Desocupada}}{\text{Fuerza de Trabajo}}\right) \times 100$$

Para obtener estimaciones agregadas del trimestre, el factor mensual `FEX_C18` se divide entre tres (FEX_C18/3), lo que refleja el promedio poblacional del período. En los datos se comprobó que la suma de ocupados y desocupados es igual a la fuerza de trabajo en todos los trimestres y para ambos sexos (`2_1_consistencia_tasas.csv`).

Tabla 4. Tasas (%) y poblaciones de hombres, total nacional (2023 a 2024).

Indicador	E-M 23	A-J 23	J-S 23	O-D 23	E-M 24	A-J 24	J-S 24	O-D 24
TGP (%)	76,50	76,74	76,84	76,49	76,27	76,56	76,37	76,30
TO (%)	69,48	70,50	70,96	70,53	68,97	69,88	70,51	70,92
TD (%)	9,18	8,14	7,66	7,78	9,57	8,72	7,67	7,06
Población	24.748.804	24.810.197	24.869.525	24.930.631	24.990.309	25.049.813	25.107.634	25.167.164
PET	18.881.919	18.946.514	19.011.565	19.080.726	19.149.619	19.218.233	19.283.702	19.349.487
Fuerza laboral	14.444.388	14.540.454	14.609.435	14.594.473	14.604.582	14.712.896	14.726.116	14.764.021
Ocupados	13.118.794	13.357.249	13.490.093	13.458.585	13.207.089	13.429.720	13.597.066	13.722.209
Desocupados	1.325.594	1.183.205	1.119.342	1.135.888	1.397.493	1.283.176	1.129.050	1.041.812

Tabla 5. Tasas (%) y poblaciones de mujeres, total nacional (2023 a 2024).

Indicador	E-M 23	A-J 23	J-S 23	O-D 23	E-M 24	A-J 24	J-S 24	O-D 24
TGP (%)	52,13	52,75	53,07	52,44	52,02	52,27	52,69	52,66
TO (%)	44,26	45,93	46,88	46,35	44,23	45,64	46,30	46,79
TD (%)	15,09	12,92	11,65	11,62	14,98	12,68	12,12	11,15
Población	26.080.284	26.152.845	26.223.382	26.295.834	26.366.929	26.437.712	26.506.805	26.577.650
PET	20.454.972	20.529.442	20.603.334	20.680.445	20.756.972	20.833.277	20.907.273	20.982.464
Fuerza laboral	10.662.324	10.829.473	10.933.226	10.845.021	10.797.737	10.890.556	11.016.301	11.050.039
Ocupados	9.053.858	9.429.973	9.659.727	9.585.297	9.180.448	9.509.175	9.680.991	9.817.474
Desocupados	1.608.466	1.399.500	1.273.499	1.259.724	1.617.289	1.381.381	1.335.310	1.232.565

Nota: E-M = enero a marzo; A-J = abril a junio; J-S = julio a septiembre; O-D = octubre a diciembre. Tasas en porcentaje; poblaciones en personas promedio estimadas.

2.2. Análisis económico de la serie de tiempo y brechas de género

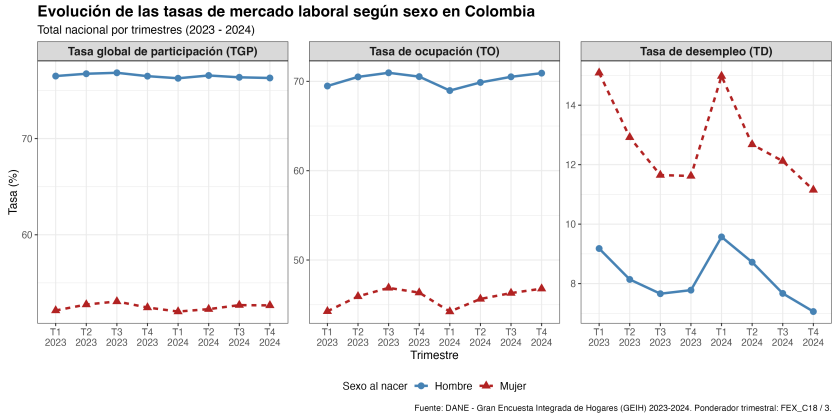


Figura 1: Evolución trimestral de TGP, TO y TD por sexo, Colombia 2023 a 2024. Fuente: GEIH (DANE), procesamiento del Grupo 10.

- En participación, la TGP de los hombres se ubica cercano a ~76,5 %, frente a la de las mujeres que se ubica cercana a ~52,5 % (la brecha de género es ~24pp en promedio). En ocupación, la TO masculina se encuentra en tasas cercanas a un ~69,5 %, y la femenina se encuentra en tasas cercanas al ~45 % (la brecha de género es de ~24,5 %pp en promedio).
- La TD femenina varía entre 11,15 % y 15,09 %, frente a 7,06 % a 9,57 % en hombres. La diferencia desfavorable para las mujeres se sitúa entre 3,84 y 5,91 puntos porcentuales. Se puede ver claramente que las mujeres manejan una varianza mayor que los hombres además que tienen consistentemente una tasa mayor.
- En general, los cambios en el desempleo coinciden con cambios en la ocupación y la participación. En el caso de los hombres, debido a que manejan mayores niveles de participación en general y son bastante estables, los cambios en el desempleo provienen principalmente de cambios en la ocupación. Por otro lado, por la parte de las mujeres, su participación es bastante menor y presenta una mayor varianza, entonces, las variaciones en su desempleo obedece a una combinación entre cambios de la participación y cambios en la ocupación.

2.3. Formalidad laboral en las 13 ciudades y áreas metropolitanas

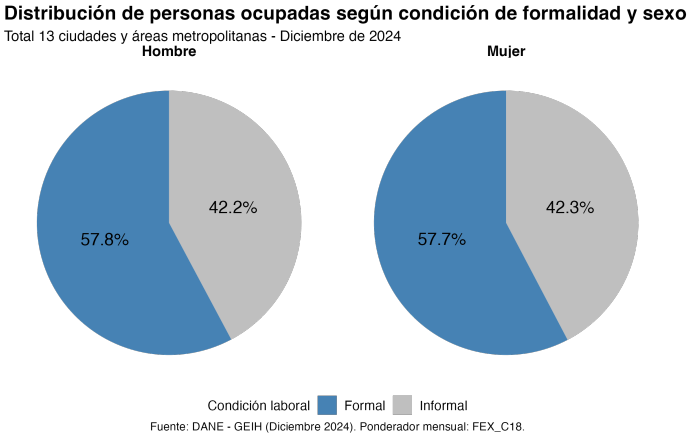


Figura 2: Distribución de ocupados según condición de formalidad y sexo, 13 ciudades (Diciembre 2024). Fuente: GEIH (DANE).

La condición de formalidad laboral (`EI`) adapta las reglas de la sintaxis SAS del DANE [3]. Evalúa rama y posición ocupacional, registro mercantil y renovación (`P3065`, `P3067`, `P3067S1`, `P3067S2`), contabilidad (`P3046`, `P3066`, `P6775`),

separación de gastos (`P3068`), forma de trabajo (`P6765`), tamaño (`P3069`), oficio y cotización a salud y pensión. El contraste independiente coincide en `EI` para los 353.672 ocupados. `FORMAL` difiere en 11.911 empleados domésticos (0 en R y faltante en SAS), sin afectar `EI`.

Al replicar el cálculo para octubre a diciembre de 2024 en las 13 ciudades (factor mensual dividido entre tres), la informalidad estimada fue de 42,5 %, igual a la cifra oficial del DANE (`2_3_control_ei_dane.csv`). En diciembre fue de 42,2 % en hombres y 42,3 % en mujeres (`2_3_tabla_formalidad_13ciudades.csv`). Estas proporciones describen las 13 ciudades y áreas metropolitanas identificadas con `AREA`, sin incluir todo el territorio nacional ni su población rural.

2.4. Posición ocupacional a nivel nacional

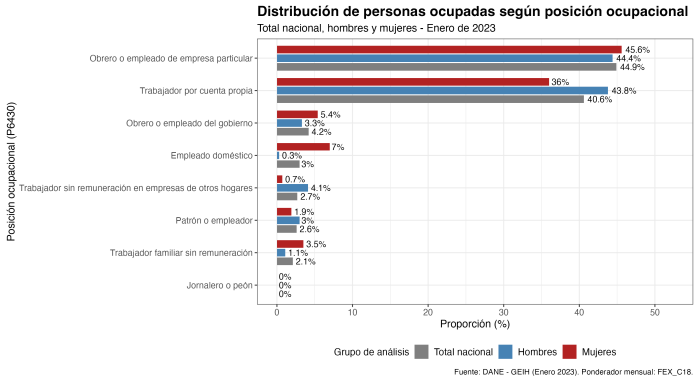


Figura 3: Distribución de la población ocupada según posición ocupacional y sexo, total nacional (Enero 2023). Fuente: GEIH (DANE).

Con los datos expandidos de enero de 2023, los trabajadores por cuenta propia (40,6 %) y los patrones o empleadores (2,6 %) suman el 43,2 % de la ocupación nacional (alrededor de 9,3 millones de personas). De estas posiciones ocupacionales provienen los propietarios potenciales de micronegocios,además que decisiones como el registro único tributario o el registro ante cámara de comercio son afectadas directamente por la situación ocupacional de estos propietarios. Si el propietario es "por cuenta propia" es posible asumir que es más dfiícil que cuente con RUT o el registro ante Cámara de comercio. Esto concuerda con lo que vemos en el próximo punto, la mayoría de los micronegocios no cuentan con estos registros y los trabajadores por cuenta propia también son una mayoría en estos posibles dueños de micronegocios.

3. Micronegocios en Colombia

3.1. Indicadores básicos del tejido empresarial

Los porcentajes de `3_1_indicadores.xlsx` se calcularon directamente a partir de la suma de `F_EXP` antes de redondear los totales expandidos. El total nacional en 2024 asciende a 5.297.252 micronegocios, cifra que coincide con la publicada por el DANE [2]. El 64,6 % de las unidades está liderado por hombres y el 35,4 % por mujeres; por ramas (`GRUPOS12`), comercio y reparación de vehículos (23,9 %) y agricultura, ganadería, silvicultura y pesca (21,5 %) concentran el 45,4 % del total (mientras que 4 registros con código `GRUPOS12 = 13` suman 82 unidades expandidas, 0,0 %). En formalización tributaria, el 22,4 % cuenta con RUT (`P1633 == 1`) y el 77,6 % no lo posee.

En el registro mercantil ante Cámara de Comercio (`P1055 == 1`), nuestro cálculo arroja 10,3 % (89,7 % sin registro), frente al 10,5 % (89,5 %) publicado en el Gráfico 9 del Boletín Técnico EMICRON 2024 [2]: una diferencia de $-0,2$ puntos porcentuales. La Tabla 8 publica 547.581 registrados sobre 5.297.252 micronegocios, equivalentes a 10,337 % (10,3 % a un decimal). Estos totales coinciden con nuestros cálculos sin redondear (547.580,7 y 5.297.252,1); la discrepancia con el gráfico no proviene del redondeo. El total, el sexo, el RUT y las participaciones por rama coinciden con las cifras oficiales al redondear a un decimal.

Tabla 6. Indicadores básicos de micronegocios, total nacional 2024 [2].

Categoría	Micronegocios	Porcentaje
Total micronegocios	5.297.252	100,0 %
Hombre	3.421.325	64,6 %
Mujer	1.875.927	35,4 %
Agricultura, ganadería, caza, silvicultura y pesca	1.138.758	21,5 %
Industrias manufactureras	531.988	10,0 %
Comercio y reparación de vehículos	1.263.754	23,9 %
Alojamiento y servicios de comida	440.223	8,3 %
Cuenta con RUT	1.185.978	22,4 %
No registrado	4.749.671	89,7 %
Registrado ante Cámara de Comercio	547.581	10,3 %

3.2. Inclusión financiera por rama de actividad

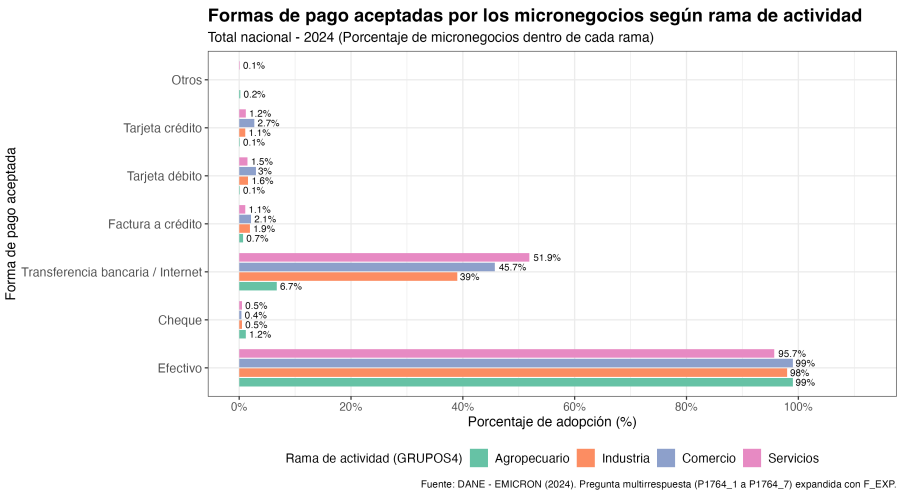


Figura 4: Medios de pago aceptados por micronegocios según rama económica, Colombia 2024. Fuente: EMICRON (DANE).

El cálculo de las siete opciones de medios de pago (`P1764_1` a `P1764_7`) se programó mediante un ciclo que recorre cada variable y rama (`GRUPOS4`), ponderando con `F_EXP` para evitar repeticiones de código.

El efectivo es la forma de cobro más habitual: lo acepta el 99,0 % de los micronegocios agropecuarios y de comercio, el 98,0 % de industria y el 95,7 % de servicios. Es impirtante resaltar que las transferencias bancarias o pagos por internet alcanzan el 51,9 % en servicios y el 43,4 % en comercio, frente al 6,7 % en el agro; se ve una clara relación entre las ramas que generalmente se ubican en lo urbano (servicios o comercio) y su adopción de medios electrónicos, a diferencia de el agro que suele estar en la zona rural y se usa sólo efectivo principalmente. Entre los micronegocios en general, el 14,2 % solicitó crédito o préstamo y el 18,1 % ahorró dinero del negocio durante el año anterior (`3_2_credito_ahorro.csv`). La solicitud no implica aprobación ni permite distinguir crédito formal de otras fuentes [2].

3.3. Análisis conjunto GEIH y EMICRON: educación del propietario y tenencia de RUT

Se pregunta: *¿se asocia la educación del propietario (GEIH: `P3042`) con la tenencia de RUT del micronegocio (EMICRON: `P1633`)?*

El análisis usa exclusivamente `F_EXP`, porque la unidad analizada es el micronegocio. Comprende 71.754 propietarios enlazados en febrero a diciembre de 2024, equivalentes a 4.864.444 micronegocios expandidos. Todos tienen educación conocida (`P3042` de `1` a `13`), sin códigos `99`, faltantes ni códigos inválidos; tampoco hay faltantes en `P1633`. Los resultados describen esta ventana efectiva y no todo el año calendario.

Tabla de contingencia: micronegocios expandidos por educación y RUT.

Nivel educativo	Sin RUT	Con RUT
Ninguno	266.762	7.644
Preescolar	456	0
Básica primaria (1o - 5o)	1.235.381	163.757
Básica secundaria (6o - 9o)	543.667	92.464
Media académica (Bachillerato clásico)	1.144.981	328.046
Media técnica (Bachillerato técnico)	70.764	25.901
Normalista	3.422	515
Técnica profesional	184.742	95.068
Tecnológica	82.086	64.277
Universitaria	211.492	226.380
Especialización	22.136	60.309
Maestría	6.742	24.918
Doctorado	285	2.250

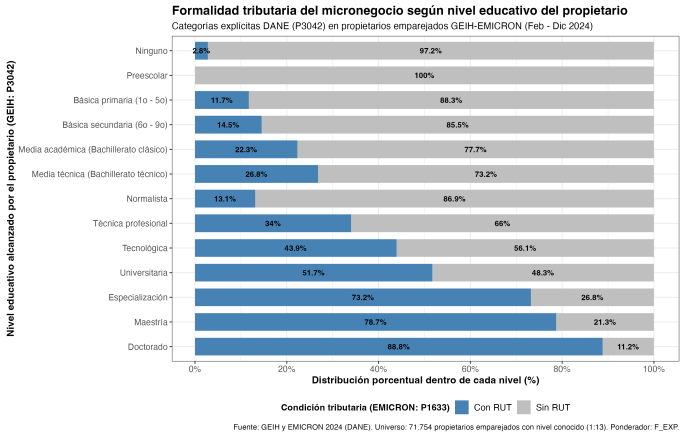


Figura 5: Tenencia de RUT según las 13 categorías educativas del DANE (P3042) en propietarios emparejados, 2024. Fuente: GEIH y EMICRON (DANE), ponderador: F_EXP.

La tabla de contingencia (`3_3_tabla_educacion_rut.csv`) muestra diferencias en la tenencia de RUT según educación: 0,0 % en *Preescolar* ($n = 6$), 2,8 % en *Ninguno*, 11,7 % en *Básica primaria*, 13,1 % en *Normalista*, 14,5 % en *Básica secundaria*, 22,3 % en *Media académica* y 26,8 % en *Media técnica*. Las proporciones alcanzan 34,0 % en *Técnica profesional*, 43,9 % en *Tecnológica*, 51,7 % en *Universitaria*, 73,2 % en *Especialización*, 78,7 % en *Maestría* y 88,8 % en *Doctorado*. La escala del negocio y la concentración de propietarios más escolarizados en servicios profesionales parecen tener una correlación inversa, a mayor escolaridad, aumenta la proporción de posesión de RUT.

4. Análisis socioeconómico de la población colombiana

4.1. Diferencias territoriales: informalidad e ingreso departamental

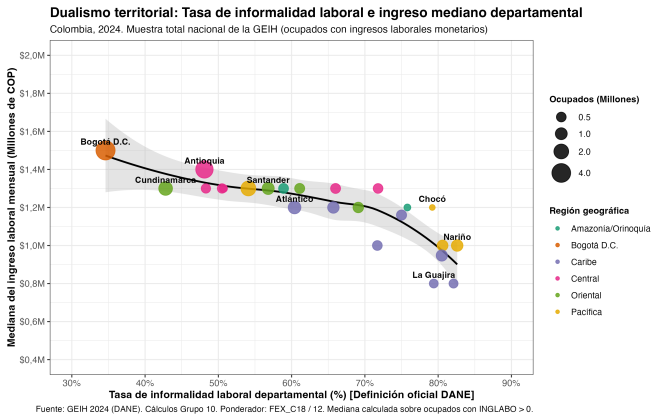


Figura 6: Tasa de informalidad laboral departamental e ingreso laboral mediano, Colombia 2024. Fuente: GEIH 2024.

Los datos departamentales muestran una relación inversa entre informalidad e ingreso laboral (`4_1_tabla_departamental.csv`). En Bogotá la informalidad es de 34,6 % y la mediana muestral del ingreso mensual positivo es de 1,5 millones de pesos; en Chocó, de 79,2 % y 1,2 millones; en La Guajira, de 79,4 % y 800.000 pesos; y en Sucre, de 82,1 % y 800.000 pesos. Las tasas se expanden con `FEX_C18 / 12`, mientras que las medianas son estadísticas muestrales sin ponderar de ocupados con ingreso positivo y `EI` conocido.

4.2. Pagos digitales y nivel de ventas en micronegocios

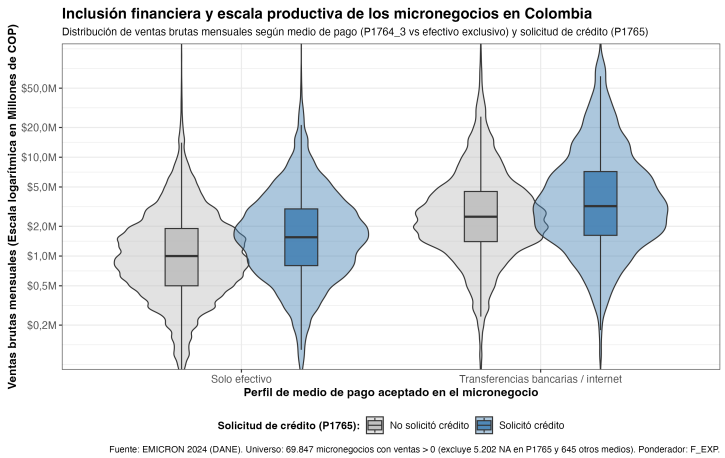


Figura 7: Distribución de ventas brutas según medio de pago (P1764_3 vs. efectivo exclusivo) y solicitud de crédito (P1765), EMICRON 2024.

Se comparan transferencias bancarias o por internet (`P1764_3`) y efectivo exclusivo según solicitud de crédito o préstamo (`P1765`, año anterior). De 75.671 registros con ventas positivas, se excluyen 5.202 sin respuesta en crédito (338.120 unidades expandidas; 5.376 faltantes en toda EMICRON) y 645 con otros perfiles de pago, con 23 registros en ambas exclusiones. Quedan 69.847 registros (4.711.543 expandidos). Las medianas muestrales, sin ponderar, son \$1,20 millones y \$1,70 millones para efectivo sin y con solicitud ($n = 37.700$ y $n = 5.804$); para transferencias son \$2,30 millones y \$3,00 millones ($n = 21.061$ y $n = 5.282$). El gráfico pondera las distribuciones con `F_EXP` y conserva todos los registros en el cálculo. Esta asociación no identifica efectos causales ni demuestra mecanismos de información financiera (Stiglitz y Weiss, 1981).

4.3. Nivel educativo y posición ocupacional

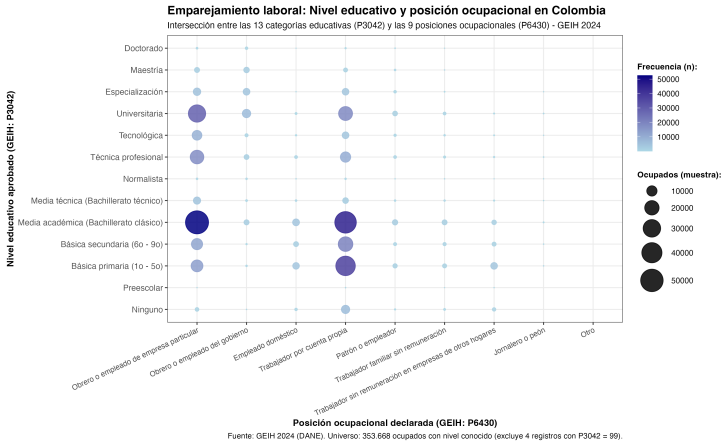


Figura 8: Intersección entre las 13 categorías educativas (P3042) y las 9 posiciones ocupacionales (P6430), Colombia 2024. Fuente: GEIH 2024.

El cruce comprende 353.668 ocupados con educación conocida; excluye cuatro registros con `P3042 == 99` (473 ocupados expandidos), sin faltantes ni códigos inválidos (`4_3_tabla_mismatch_educacion.csv`). El gráfico representa frecuencias muestrales; los porcentajes y poblaciones siguientes usan `FEX_C18 / 12`. Cuenta propia predomina en *Ninguno* (62,5 %), *Primaria* (54,8 %) y *Secundaria* (48,6 %). Desde *Media académica* (47,8 % empleado particular; 39,9 % cuenta propia) y *Media técnica* (57,8 %; 32,7 %) predomina el empleo particular. Sus proporciones son 61,5 % en técnica profesional, 66,6 % en tecnológica, 62,1 % en universitaria, 58,4 % en especialización, 55,6 % en maestría y 56,5 % en doctorado. El empleo público pasa de 10,8 % en universitaria a 28,2 % en doctorado. Hay 986.256 ocupados con educación superior por cuenta propia, incluidos 454.991 universitarios y 360.875 técnicos profesionales. Identificar sobreeducación requiere conocer la educación exigida por el puesto (Hartog, 2000).

Referencias

1. DANE. *Gran Encuesta Integrada de Hogares (GEIH) 2023–2024*. Metodología, formulario y microdatos en ANDA.
2. DANE. *Boletín técnico: Encuesta de Micronegocios (EMICRON) 2024*. Bogotá: DANE.
3. DANE. *Empleo informal y seguridad social, octubre–diciembre 2024*. Boletín y anexo estadístico (`Código_SAS`).
4. Hartog, J. (2000). Over-education and earnings: where are we, where should we go? *Economics of Education Review*, 19(2), 131–147.
5. Stiglitz, J. E., & Weiss, A. (1981). Credit rationing in markets with imperfect information. *American Economic Review*, 71(3), 393–410.

Anexo. Declaración de uso de inteligencia artificial

En cumplimiento de los lineamientos institucionales de la Universidad de los Andes (*Lineamientos para el uso de inteligencia artificial generativa - IAG*, Octubre de 2024, Nivel 3: *Uso de IA para editar y refinar*) y de las normas establecidas en el enunciado del Taller 2, a continuación se declara de manera explícita y transparente el alcance del uso de herramientas de IAG durante el desarrollo del trabajo. Se enfatiza que las herramientas se emplearon exclusivamente como soporte técnico, instrumental y práctico, preservando la autoría intelectual, el razonamiento analítico y el dominio computacional en los integrantes del grupo:

Elemento	Declaración formal y alcance del Grupo 10
Herramientas y Nivel	ChatGPT (OpenAI GPT-4o) y Claude (Anthropic 3.5 Sonnet). Nivel 3 institucional (*Editar, revisar y refinar*).
Propósito y tareas prácticas asistidas	**1. Depuración sintáctica en R (Función 4 Uniandes):** Consulta puntual para resolución de errores de sintaxis en consola, advertencias de tipado y verificación de la estructura del outline jerárquico (`----`). **2. Maquetación técnica en Quarto / XeLaTeX (Función 1 Uniandes):** Soporte técnico de sintaxis en tablas `booktabs`, dimensionamiento relativo de columnas (`p{...}`) y configuración de encabezados con `fancyhdr`. **3. Revisión ortotipográfica y gramatical (Función 1 Uniandes):** Revisión de ortografía, puntuación y estilo gramatical sobre explicaciones elaboradas previamente por los integrantes, sin alterar el sentido analítico original.
Límites y tareas no delegadas (Autoría humana)	**1. Lógica analítica y de pegues:** La demostración empírica de la llave común GEIH–EMICRON (`SECUENCIA_ENCUESTA == ORDEN`) y el desfase temporal de recolección (`MES_REF == MES_GEIH + 1`) fue formulada y probada 100 % por el grupo. **2. Algoritmo de formalidad laboral:** La traducción e implementación en `dplyr` del código oficial SAS del DANE (`EI`) fue programada y validada manualmente (0,0 pp de discrepancia frente al boletín oficial de 13 ciudades). **3. Tasas e indicadores laborales:** La estimación ponderada con factores de expansión (`FEX_C18 / 3`) y la comprobación de consistencia aditiva (`FT = Ocupados + Desocupados`) son desarrollo original del grupo.
Supervisión crítica y control de calidad	Se aplicó un flujo estructurado en tres fases (exploración sintáctica, depuración controlada y verificación empírica). Toda respuesta fue auditada críticamente frente a los microdatos oficiales del DANE y los scripts de clase, descartando proactivamente sugerencias erróneas de librerías ajenas (`data.table`) o supuestos inválidos sobre llaves y ponderadores. Ninguna cifra ni análisis sustantivo fue generado por IA.

Flujo metodológico por fases y matriz de descarte crítico de alucinaciones

Conforme a las recomendaciones de las Secciones 3.1 y 3.2 de los lineamientos institucionales de la Universidad de los Andes, el proceso se estructuró en tres fases secuenciales: (1)~*Exploración sintáctica y conceptual inicial* para consultas sobre documentación; (2)~*Depuración técnica y maquetación controlada* para resolver errores de consola y formatear tablas; y (3)~*Auditoría y validación humana estricta*, donde cada bloque fue ejecutado en una sesión limpia y contrastado frente a los boletines oficiales.

Dimensión técnica	Sugerencia errónea descartada (Alucinación) y acción correctiva humana
Librerías del curso	La IA sugirió optimizar lectura con `data.table::fread()`. *Acción humana:* Se descartó por violar las restricciones del enunciado, implementando lectura modular con `read.csv()` y pre-filtrado con `dplyr::select()`.
Llaves de emparejamiento	La IA asumió un pegue directo por `DIRECTORIO + ORDEN` dentro del mismo mes. *Acción humana:* Se descartó al descubrir el desfase de recolección de EMICRON (MES_REF = MES_{GEIH} + 1) y la equivalencia empírica SECUENCIA_ENCUESTA == ORDEN.
Factores de expansión	La IA sugirió ponderar el cruce GEIH–EMICRON combinando `FEX_C18` y `F_EXP`. *Acción humana:* Se corrigió el error metodológico, aplicando exclusivamente `F_EXP` al evaluar la unidad de micronegocios.

Privacidad y confidencialidad: En estricto cumplimiento de las políticas de privacidad de la Universidad y de reserva estadística del DANE, ningún microdato individual, registro no anonimizado ni archivo de datos fue ingresado en las herramientas de IA generativa.