Guía Maestra de Estudio: Mercado Laboral, Microdatos y Micronegocios en Colombia

Tratado Metodológico, Estadístico y Conceptual Aplicado al Taller 2 (GEIH y EMICRON 2023-2024)

Grupo 10 · Maestría en Economía Aplicada
Facultad de Economía · Universidad de los Andes

2026-10-01

Contenido de la Guía

Metodología, Arquitectura de Datos y Diccionario Exhaustivo (Punto 1) . . . 2
Numeral 1.1: Pegue Mensual de la GEIH (2023 y 2024) . . . 2
Estructura Relacional y Llave de Identificación . . . 2
Lógica del Bucle y Eficiencia Computacional . . . 3
Documentación del Contador en el Bucle (`contador <- 1`) . . . 3
Verificaciones Programáticas de Integridad . . . 3
Numeral 1.2: Descripción Modular y Consistencia Laboral (2024) . . . 4
Relación de Inclusión y Tamaños Muestrales . . . 4
Verificación de Identidades Conceptuales . . . 4
Numeral 1.3: Diccionario de Datos Exhaustivo . . . 4
Tabla 1: Variables Requeridas de la GEIH (Numeral 1.3) . . . 4
Tabla 2: Variables Auxiliares Indispensables para la Formalidad DANE (Numeral 2.3) . . . 9
Tabla 3: Variables de la EMICRON 2024 (Numerales 1.4, 3 y 4.2) . . . 13
Diferencia Conceptual entre `DPTO`, `AREA` y `CLASE` . . . 17
Numeral 1.4: Integración Relacional de EMICRON y GEIH 2024 (`base_micro`) . . . 17
Selección Muestral y Asimetría de Inclusión . . . 17
Cobertura Geográfica Diferencial . . . 17
Metodología de Ponderación: `FEX_C18` vs. `F_EXP` . . . 18
Determinación Empírica de la Llave: `SECUENCIA_ENCUESTA` vs. `ORDEN` . . . 18
Desfase Temporal y Período de Referencia . . . 18
Auditoría del Enlace y Explicación de los Registros No Emparejados . . . 18
Validación de la Calidad del Enlace . . . 18
Interpretación de la Posición Ocupacional en 1.4.g . . . 18
Principales Indicadores de Mercado Laboral (Punto 2) . . . 19
Numeral 2.1: Tasas y Poblaciones (2023-2024) . . . 19
Numeral 2.2: Descomposición del Desempleo y Brechas de Género . . . 19
Numeral 2.3: Informalidad Laboral en 13 Ciudades (Diciembre 2024) . . . 19
Replicación Exacta del Algoritmo Multidimensional del DANE (`Código_SAS`) . . . 19
Numeral 2.4: Posición Ocupacional Nacional (Enero 2023) . . . 20
Caracterización de los Micronegocios en Colombia (Punto 3) . . . 20
Numeral 3.1: Indicadores Estructurales y Comparación con el Boletín DANE (EMICRON 2024) . . . 20
Numeral 3.2: Inclusión Financiera de Micronegocios . . . 20

Numeral 3.3: Cruce Conjunto GEIH - EMICRON con Categorías Explícitas del DANE 21
Análisis Socioeconómico de la Población Colombiana (Punto 4) 21
Numeral 4.1: Geografía de la Informalidad Laboral 21
Numeral 4.2: Inclusión Digital, Solicitud de Crédito y Escala de Ventas 21
Numeral 4.3: Emparejamiento Laboral entre Nivel Educativo y Posición Ocupacional 22
Banco de Preguntas y Argumentación para la Sustentación Oral (Punto 5) 22
Bloque 1: Defensa del Punto 1 (Conformación de Bases y Enlace Relacional) 22
Pregunta 1.1: ¿Por qué la llave relacional de la GEIH exige tres variables y qué riesgo existe al omitir una? 22
Pregunta 1.2: ¿Por qué se utilizó `contador <- 1` en el bucle 1.1 en lugar de `append()`? 22
Pregunta 1.3: ¿Por qué 6.747 micronegocios de EMICRON 2024 no emparejan con la GEIH de 2024? . 22
Pregunta 1.4: ¿Por qué no se puede usar indistintamente `FEX_C18` y `F_EXP`? 22
Bloque 2: Defensa del Punto 2 (Indicadores Laborales y Formalidad DANE) 23
Pregunta 2.1: ¿Por qué para las tasas trimestrales del punto 2.1 se divide `FEX_C18` entre 3? 23
Pregunta 2.2: ¿Cómo se construyó la clasificación de formalidad laboral (`EI`) en el punto 2.3? 23
Pregunta 2.3: ¿Cómo se interpreta que baje la tasa de desempleo pero caiga la tasa de ocupación? 23
Bloque 3: Defensa del Punto 3 (Micronegocios e Inclusión Financiera) 23
Pregunta 3.1: ¿Por qué en Cámara de Comercio (`P1055 == 1`) el cálculo da 10,3 % mientras el Gráfico 9 del boletín DANE muestra 10,5 %? 23
Pregunta 3.2: ¿Por qué la mayor aceptación de transferencias (`P1764_3`) en comercio y servicios no se traduce en una alta solicitud de crédito (`P1765`)? 23
Pregunta 3.3: ¿Cómo se trataron las categorías de `P3042` en el cruce 3.3 y por qué la relación con el RUT no es causal? 23
Bloque 4: Defensa del Punto 4 (Análisis Socioeconómico y Rigor Gráfico) 24
Pregunta 4.1: ¿Qué correcciones metodológicas se aplicaron en el análisis de inclusión financiera y ventas (4.2) y en el cruce educativo-ocupacional (4.3)? 24
Pregunta 4.2: ¿Qué criterios garantizan que todos los gráficos del taller estén completamente documentados y sean autocontenidos? 24

Metodología, Arquitectura de Datos y Diccionario Exhaustivo (Punto 1)

Esta sección fundamenta las decisiones de procesamiento, unión de módulos y auditoría de microdatos implementadas en el primer numeral del taller, vinculando las directrices del DANE con las soluciones adoptadas en el script oficial.

Numeral 1.1: Pegue Mensual de la GEIH (2023 y 2024)

La Gran Encuesta Integrada de Hogares (GEIH) es la principal operación estadística de mercado laboral de Colombia. Su recolección es mensual y continua, con cobertura sobre cabeceras municipales, centros poblados y rural disperso.

Estructura Relacional y Llave de Identificación

La encuesta organiza su información en módulos independientes vinculados mediante una estructura jerárquica: 1. `DIRECTORIO`: Identifica de manera unívoca la edificación o vivienda dentro del marco muestral. 2. `SECUENCIA_P`: Identifica el hogar dentro de la vivienda. 3. `ORDEN`: Identifica a la persona dentro del hogar.

Para individualizar a cada encuestado a lo largo de los capítulos, la llave relacional obligatoria es la tupla compuesta `c("DIRECTORIO", "SECUENCIA_P", "ORDEN")`. Omitir cualquiera de estas tres variables destruye la cardinalidad del enlace y produce emparejamientos espurios entre personas de distintos hogares en una misma edificación.

Lógica del Bucle y Eficiencia Computacional

El script oficial construye la serie de 24 meses (12 meses de 2023 y 12 meses de 2024) mediante dos bucles `for` anidados:

```
anios <- c("GEIH_2023", "GEIH_2024")
meses <- c(
  "01_Enero", "02_Febrero", "03_Marzo", "04_Abril",
  "05_Mayo", "06_Junio", "07_Julio", "08_Agosto",
  "09_Septiembre", "10_Octubre", "11_Noviembre", "12_Diciembre"
)
llave_geih <- c("DIRECTORIO", "SECUENCIA_P", "ORDEN")
```

Para optimizar el uso de memoria RAM y el tiempo de ejecución, el script aplica tres estrategias concretas: 1. **Selección temprana de columnas (`select` antes del join):** El módulo de ocupados contiene cerca de doscientas variables. Leer y conservar todas las columnas multiplicaría el consumo de memoria a más de 8 GB. Al aplicar `select()` inmediatamente tras la importación, el ancho del módulo se reduce de 190 columnas a solo 23, registrando una ganancia de eficiencia superior al 85 % (documentada en `1_1_eficiencia.csv`). 2. **Homogeneización forzada de tipos de datos:** Las variables de identificación se convierten explícitamente a carácter (`as.character()`). Esto evita errores de pérdida de ceros a la izquierda y previene incompatibilidades de tipo entre meses o módulos. 3. **Manejo de excepciones contractuales:** En marzo de 2024, el archivo de no ocupados fue nombrado por el DANE como `"No ocupado.CSV"` en singular. El código detecta condicionalmente esta anomalía (`if (anio == "GEIH_2024" && mes == "03_Marzo") "No ocupado.CSV" else "No ocupados.CSV"`), permitiendo una ejecución continua sin intervención manual.

Documentación del Contador en el Bucle (`contador <- 1`)

Antes de iniciar los bucles se inicializa la variable `contador <- 1`. Al finalizar cada iteración mensual, se ejecuta `contador <- contador + 1`. Esta decisión responde a fundamentos de eficiencia computacional en R: - **Indexación posicional directa:** En cada mes, las matrices de verificación mensual se asignan directamente a su posición: `r conteos_modulos[[contador]] <- data.frame(...) verificacion_eficiencia[[contador]] <- data.frame(...) verificacion_llaves[[contador]] <- data.frame(...) verificacion_pegues[[contador]] <- data.frame(...)` - **Ventaja frente a `append()` o `c()`:** En R, modificar un objeto mediante `append()` o `c()` obliga al intérprete a copiar la estructura completa en una nueva dirección de memoria en cada iteración ($O(N^2)$ en reasignación). La asignación por índice entero preasigna el elemento en la lista en tiempo constante $O(1)$. - **Interacción entre índices:** Mientras el índice `i` corre localmente de 1 a 12 para almacenar los data frames mensuales de cada año en `bases_mensuales_anio[[i]]`, el índice global `contador` avanza de 1 a 24, acumulando la auditoría ininterrumpida de los dos años evaluados. - **Consolidación final:** Al cerrar cada año, la lista de 12 data frames se une en un único paso vectorizado mediante `bind_rows(bases_mensuales_anio)`. Al finalizar los dos años, `bind_rows(GEIH_2023, GEIH_2024)` construye la base maestra de la GEIH.

Verificaciones Programáticas de Integridad

El script ejecuta dos controles de parada inmediata (`stop()`): 1. **Unicidad de la llave:** En cada mes se verifica que la llave no presente duplicados en ninguno de los 4 módulos (`sum(duplicated(df[, llave_geih])) == 0`). El resultado es 0 duplicados en todos los meses (`1_1_verificacion_llaves.csv`). 2. **Conservación de filas:** El módulo base es `Características generales` (N_{general}). Al unir sucesivamente por izquierda `Fuerza de trabajo`, `Ocupados` y `No ocupados`, el número de filas final debe ser idéntico al inicial. Si algún cruce aumentara las filas, el script aborta inmediatamente la ejecución (`1_1_verificacion_pegues.csv`).

Numeral 1.2: Descripción Modular y Consistencia Laboral (2024)

El módulo de características generales abarca a toda la población encuestada. Los demás módulos corresponden a filtros temáticos y poblaciones específicas:

Relación de Inclusión y Tamaños Muestrales

- **Población Total (Módulo General):** Registra a todas las personas del hogar, incluidos menores de edad. En 2024 suma 829.683 observaciones muestrales.
- **Población en Edad de Trabajar (PET, Módulo Fuerza de Trabajo):** En Colombia, la PET comprende a personas de 15 años y más (estandarizado por el DANE bajo lineamientos OIT). Suma 657.803 registros en 2024.
- **Ocupados (Módulo Ocupados):** Personas que durante la semana de referencia trabajaron al menos una hora remunerada, o no trabajaron pero tenían empleo, o trabajadores familiares sin remuneración que laboraron al menos una hora. Suma 353.672 registros en 2024.
- **No Ocupados (Módulo No Ocupados):** Agrupa a los desocupados (cesantes y aspirantes) y a la población fuera de la fuerza de trabajo (estudiantes, personas dedicadas al cuidado del hogar, rentistas, jubilados). Suma 304.131 registros en 2024.

Verificación de Identidades Conceptuales

El código comprueba programáticamente dos identidades laborales en cada uno de los 12 meses de 2024 (`1_2_consistencia_laboral_2024.csv`):

$$\text{PET} = \text{Fuerza de Trabajo (FT)} + \text{Fuera de la Fuerza de Trabajo (FFT)}$$

$$\text{Fuerza de Trabajo (FT)} = \text{Ocupados (OCI)} + \text{Desocupados (DSI)}$$

$$\text{Módulo Fuerza de Trabajo} = \text{Módulo Ocupados} + \text{Módulo No Ocupados}$$

Ambas identidades se satisfacen en el 100 % de los casos, validando la coherencia interna de las clasificaciones del DANE.

Numeral 1.3: Diccionario de Datos Exhaustivo

A continuación se detalla el diccionario completo estructurado por encuesta, módulo, tabla y numeral del taller.

Tabla 1: Variables Requeridas de la GEIH (Numeral 1.3)

Variables obligatorias solicitadas en los literales a) a d) del numeral 1.3:

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
`DIRECTORIO`	GEIH	Características generales	Identificador de la edificación o vivienda	Carácter	Código alfanumérico DANE	Vivienda	Llave relacional	1.1, 1.4	Estandarizado con `as.character(`
`SECUENCIA_P`	GEIH	Características generales	Identificador del hogar dentro de la	Carácter	Consecutivo numérico (1, 2, ...)	Hogar	Llave relacional	1.1, 1.4	Estandarizado con `as.character(`

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
			vivienda						
ORDEN	GEIH	Características generales	Número de orden de la persona en el hogar	Carácter	Consecutivo numérico (1, 2, …)	Persona	Llave relacional	1.1, 1.4	Estandarizado con as.character(
PERIODO	GEIH	Características generales	Período de recolección de la encuesta	Numérico	Formato YYYYMM (ej. 202401)	Registro	Filtro temporal	1.1, 1.3	Se extrae ANIO con substr(1, 4)
MES	GEIH	Características generales	Mes de recolección de la encuesta	Numérico	1 a 12 (Enero a Diciembre)	Registro	Filtro y control	1.1, 1.4, 2.1	Numérico para agregaciones
P3271	GEIH	Características generales	Sexo al nacer del encuestado	Categórico	1 = Hombre, 2 = Mujer	Persona	Clasificación	1.3, 1.4, 2.1	Etiquetado en factores para gráficos
P3042	GEIH	Características generales	Mayor nivel educativo alcanzado	Categórico	1=Ninguno, 2=Preescolar, 3=Básica primaria (1o-5o), 4=Básica secundaria (6o-9o), 5=Media académica, 6=Media técnica,	Persona	Indicador de capital humano	1.3, 3.3, 4.3	Clasificación explícita de los 13 niveles conocidos y auditoría de 99 y NA

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
					7=Normalista, 8=Técnica profesional, 9=Tecnológica, 10=Universitaria, 11=Especialización, 12=Maestría, 13=Doctorado, 99=No sabe/no informa				
P6090	GEIH	Características generales	Afiliación al Sistema de Seguridad Social en Salud	Categórico	1 = Sí, 2 = No, 9 = No sabe	Persona	Caracterización social	1.3	Mantenido en base analítica
P6040	GEIH	Características generales	Edad en años cumplidos	Numérico	0 a 110 años	Persona	Filtro demográfico	1.3, 1.4	Validado contra edad EMICRON (P241)
P6160	GEIH	Características generales	¿Sabe leer y escribir? (Alfabetismo)	Categórico	1 = Sí, 2 = No	Persona	Caracterización social	1.3	Mantenido en base analítica

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
DPTO	GEIH	Características generales	Código DANE del departamento	Categórico	Códigos DIVIPOLA de 2 dígitos (05 a 99)	Departamento	Dominio geográfico	1.3, 4.1	Cruce espacial departamental
AREA	GEIH	Características generales	Dominio geográfico o área metropolitana	Categórico	Códigos de área metropolitana y dominios	Área urbana	Filtro geográfico	1.3, 2.3	Filtro de las 13 ciudades principales
CLASE	GEIH	Características generales	Tipo de zona geográfica de la vivienda	Categórico	1 = Cabecera, 2 = Centros poblados y rural disperso	Zona	Dominio geográfico	1.3, 1.4	Contrastado con CLASE_TE
FEX_C18	GEIH	Características generales	Factor de expansión mensual calibrado	Numérico	Ponderador poblacional continuo	Persona	Factor de expansión	1.1 a 2.4, 4	Ajustado /3 en trimestres y /12 en año
PT	GEIH	Características generales	Indicador de Población Total	Binario	1 = Población total	Persona	Agregador poblacional	1.3, 2.1	Ponderado con FEX_C18
PET	GEIH	Fuerza de trabajo	Indicador de Población en Edad de Trabajar	Binario	1 = Pertenece a PET (15 años o más), NA = Menor de 15	Persona	Filtro laboral	1.2, 1.3, 2.1	Denominador de TGP y TO
FT	GEIH	Fuerza de trabajo	Indicador de Fuerza de	Binario	1 = Ocupado o desocupado,	Persona	Indicador laboral	1.2, 1.3, 2.1	Numerador de TGP;

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
			Trabajo (PEA)		NA = Fuera de FT				denom. de TD
FFT	GEIH	Fuerza de trabajo	Indicador de Población Fuera de la Fuerza de Trabajo	Binario	1 = Fuera de la fuerza de trabajo, NA = En FT	Persona	Indicador laboral	1.2, 1.3	Verificación de consistencia
P6240	GEIH	Fuerza de trabajo	Actividad principal realizada la semana anterior	Categórico	1=Trabajando, 2=Buscando, 3=Estudiando, 4=Hogar, 5=Incapacitado, 6=Otro	Persona	Caracterización laboral	1.3	Mantenido en base analítica
OCI	GEIH	Ocupados	Indicador de Ocupación	Binario	1 = Ocupado, NA = No ocupado	Persona	Filtro y numerador	1.2, 1.3, 2.1	Numerador de TO; base de formalidad
RAMA2D_R4	GEIH	Ocupados	Rama de actividad económica CIIU Rev. 4 A.C. a 2 dígitos	Categórico	Códigos 01 a 99	Empleo	Sector económico	1.3, 2.3	Define formalidad en ramas 84 y 99
P6430	GEIH	Ocupados	Posición ocupacional en el	Categórico	1=Obrero particular, 2=Obrero go-	Persona	Clasificación ocupacional	1.3, 1.4, 2.4, 4.3	Eje central del árbol de formalidad y

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
			empleo principal		bierno, 3=Empleado doméstico, 4=Cuenta propia, 5=Patrón, 6=Familiar sin remun., 7=Sin remun. en otras empresas, 8=Jornalero o peón, 9=Otro				del cruce 4.3
INGLABO	GEIH	Ocupados	Ingreso laboral monetario mensual	Numérico	Valor en pesos colombianos	Persona	Variable socioeconómica	1.3, 4.1	Base de medianas departamentales (4.1)
DSI	GEIH	No ocupados	Indicador de Desocupación	Binario	1 = Desocupado, NA = No desocupado	Persona	Numerador laboral	1.2, 1.3, 2.1	Numerador de la Tasa de Desempleo

Tabla 2: Variables Auxiliares Indispensables para la Formalidad DANE (Numeral 2.3)
Variables del capítulo de Ocupados necesarias para replicar la sintaxis oficial del DANE (Código_SAS):

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P6100	GEIH	Ocupados	Régimen de seguri-	Categórico	1 = Contributivo	Empleo	Formalidad	2.3	Define variable SALUD

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
			dad social en salud		(EPS), 2 = Especial, 3 = Subsidiado, 9 = No sabe		asalariados		
P6110	GEIH	Ocupados	¿Quién paga la afiliación a salud?	Categórico	1 = Descuento nómina/empresa, 2 = Paga totalmente, 3 = Beneficiario, 4 = Pensionado, 9 = No sabe	Empleo	Formalidad asalariados	2.3	Condición conjunta con P6100
P6450	GEIH	Ocupados	Tipo de contrato laboral	Categórico	1 = Verbal, 2 = Escrito, 9 = No sabe	Empleo	Formalidad asalariados	2.3	Desempata cotizaciones con no sabe/no informa
P6920	GEIH	Ocupados	¿Cotiza actualmente a un fondo de pensiones?	Categórico	1 = Sí cotiza, 2 = No cotiza, 3 = Ya es pensionado	Empleo	Formalidad asalariados	2.3	Define variable PENSION
P6930	GEIH	Ocupados	Fondo al que cotiza en pensión	Categórico	1 = Fondo privado, 2 = Colpensiones, 3 = Régimen es-	Empleo	Formalidad asalariados	2.3	Validación institucional de pensión

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
					pecial, 4 = Subsidiado, 9 = No sabe				
P6940	GEIH	Ocupados	¿Cómo realiza el pago de la cotización a pensión?	Categórico	1 = Descuento nómina/empresa, 2 = Paga totalmente, 3 = No paga, 9 = No sabe	Empleo	Formalidad asalariados	2.3	Valida aporte contributivo
P6765	GEIH	Ocupados	Lugar o tipo de establecimiento donde realiza la actividad	Categórico	1 a 6 y 8 a 11 = Fuera de vivienda / ambulante / obra / campo, 7 = En esta vivienda	Empleo	Filtro de localización	2.3	Bifurca el árbol según lugar de trabajo
P3065	GEIH	Ocupados	¿El negocio tiene registro ante Cámara de Comercio?	Categórico	1 = Sí tiene, 2 = No tiene, 9 = No sabe	Empresa	Registro institucional	2.3	Clasifica formalidad en P6765 %in% c(4, 5, 6, 8, 9)
P3066	GEIH	Ocupados	¿Lleva contabilidad formal en el negocio?	Categórico	1 = Balance general/libro contable, 2 =	Empresa	Contabilidad comercial	2.3	Formalidad de independientes

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
					Otro registro, 3 = No lleva, 9 = No sabe				y patronos
P3067	GEIH	Ocupados	¿En esta vivienda cuentan con un local para el negocio?	Categórico	1 = Sí, 2 = No	Establecimiento	Localización en vivienda	2.3	Árbol de actividad en vivienda (P6765 == 7)
P3067S1	GEIH	Ocupados	¿El local está independiente de la vivienda?	Categórico	1 = Sí independiente, 2 = No independiente	Establecimiento	Independencia física	2.3	Condiciones explícitas de Código_SAS
P3067S2	GEIH	Ocupados	Año desde el cual funciona el local en la vivienda	Numérico	Año de inicio (ej. 2018)	Establecimiento	Antigüedad del negocio	2.3	Comparado contra ANIOS = ANIO - 1
P6775	GEIH	Ocupados	¿Cuenta con registro mercantil en vivienda?	Categórico	1 = Sí tiene, 2 = No tiene, 9 = No sabe	Empresa	Formalidad en vivienda	2.3	Condición clave de actividad en vivienda
P3068	GEIH	Ocupados	¿Lleva contabilidad en la actividad realizada en vivienda?	Categórico	1 = Balance/libros, 2 = Otro registro, 3 = No lleva, 9 = No sabe	Empresa	Formalidad comercial	2.3	Desempata actividad en vivienda sin registro

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
`P3069`	GEIH	Ocupados	Tamaño de la empresa según número de trabajadores	Numérico	1 = Solo, 2 = 2 a 3, 3 = 4 a 5, 4 = 6 a 10, 5 = 11 y más	Empresa	Escala de la unidad productiva	2.3	Umbral de tamaño (≥ 4 formal; ≤ 3 informal)
`OFICIO_C8`	GEIH	Ocupados	Clasificación Internacional Uniforme de Ocupaciones (CIUO-08)	Categórico	Código ocupacional de 4 dígitos	Ocupación	Calificación profesional	2.3	Se extraen 2 dígitos (`OFICIO_C8_2D`)

Tabla 3: Variables de la EMICRON 2024 (Numerales 1.4, 3 y 4.2)
Variables provenientes de los cuatro módulos de la Encuesta de Micronegocios:

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
`DIRECTORIO`	EMICRON	Identificación	Identificador de la edificación o vivienda	Carácter	Código alfanumérico DANE	Vivienda	Llave relacional	1.4, 3	Estandarizado con `as.character(`
`SECUENCIA_P`	EMICRON	Identificación	Identificador del hogar en la vivienda	Carácter	Consecutivo numérico (1, 2, …)	Hogar	Llave relacional	1.4, 3	Estandarizado con `as.character(`
`SECUENCIA_ENCUESTA`	EMICRON	Identificación	Orden del propietario del micronegocio en el hogar	Carácter	Consecutivo numérico (1, 2, …)	Persona	Llave relacional	1.4, 3	Equivale a `ORDEN` de la GEIH

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P35	EMICRON	Identificación	Sexo del propietario del micronegocio	Categórico	1 = Hombre, 2 = Mujer	Persona	Caracterización y control	1.4, 3.1	Contrastado con P3271 de la GEIH
P241	EMICRON	Identificación	Edad en años cumplidos del propietario	Numérico	15 a 99 años	Persona	Caracterización y control	1.4, 3.1	Contrastado con P6040 de la GEIH
MES_REF	EMICRON	Identificación	Mes de referencia de la entrevista EMICRON	Carácter	Nombre del mes en mayúsculas	Micronegocio	Control temporal	1.4	Desfase: $\text{MES_REF} = \text{MES}_{\text{GEIH}} + 1$
COD_DEPTO	EMICRON	Identificación	Código DANE del departamento	Categórico	Códigos DIVIPOLA de 2 dígitos	Departamento	Cobertura geográfica	1.4, 3	Cubre 24 departamentos más Bogotá D.C.
CLASE_TE	EMICRON	Identificación	Zona geográfica del micronegocio	Categórico	1 = Cabecera, 2 = Centros poblados y rural disperso	Zona	Control geográfico	1.4	Contrastado con CLASE de la GEIH
GRUPOS4	EMICRON	Identificación	Rama de actividad económica agregada a 4 ramas	Categórico	1 = Agricultura, 2 = Industria manufacturera, 3 = Comercio,	Micronegocio	Agrupador sectorial	3.2	Base del análisis de inclusión financiera

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
					4 = Servicios				
GRUPOS12	EMICRON	Identificación	Rama de actividad económica desagregada a 12 sectores	Categórico	Códigos 1 a 12 (y 13 = No informa, 4 registros)	Micronegocio	Distribución económica	3.1	Comparado contra boletín técnico DANE
F_EXP	EMICRON	Identificación	Factor de expansión anual de micronegocios	Numérico	Ponderador anual continuo	Micronegocio	Ponderador de unidades	3.1, 3.2, 3.3, 4.2	**Factor anual: no se divide entre 12**
P1633	EMICRON	Características	¿El micronegocio cuenta con Registro Único Tributario (RUT)?	Categórico	1 = Sí cuenta, 2 = No cuenta	Micronegocio	Formalidad tributaria	3.1, 3.3	Indicador de formalización tributaria
P1055	EMICRON	Características	¿Tiene registro mercantil ante Cámara de Comercio?	Categórico	1 = Sí tiene, 2 = No tiene	Micronegocio	Formalidad mercantil	3.1	Indicador de formalización mercantil
P1764_1	EMICRON	Inclusión financiera	Acepta pagos en efectivo	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Base del perfil “Solo efectivo” (exclusivo)
P1764_2	EMICRON	Inclusión fi-	Acepta pagos	Binario	1 = Sí acepta,	Micronegocio	Medio de pago	3.2, 4.2	Medio banca-

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
		nanciera	en cheque		2 = No acepta				rio tradicional
P1764_3	EMICRON	Inclusión financiera	Acepta transferencias bancarias o por internet	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Incluye billeteras digitales (Nequi, Daviplata)
P1764_4	EMICRON	Inclusión financiera	Acepta factura a crédito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio comercial a plazo
P1764_5	EMICRON	Inclusión financiera	Acepta tarjeta débito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio electrónico con datáfono
P1764_6	EMICRON	Inclusión financiera	Acepta tarjeta de crédito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio electrónico con datáfono
P1764_7	EMICRON	Inclusión financiera	Acepta otro medio de pago	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Categoría residual de medios
P1765	EMICRON	Inclusión financiera	¿Solicitó un préstamo o crédito para el negocio en el año anterior?	Categórico	1 = Sí solicitó, 2 = No solicitó, NA = No informa (5.376 registros en total; 5.202 con ventas > 0)	Micronegocio	Solicitud de crédito	3.2, 4.2	Mide demanda revelada de crédito

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P3014	EMICRON	Inclusión financiera	¿El micronegocio ahorró parte de sus ingresos?	Categórico	1 = Sí ahorró, 2 = No ahorró, NA = No informa	Micronegocio	Capacidad de ahorro	3.2	Mide excedente económico
VENTAS_MES_ANT	EMICRON	INTERIOR Ventas o ingresos	Ventas o ingresos brutos del mes anterior a la entrevista	Numérico	Valor en pesos colombianos	Micronegocio	Escala productiva	4.2	Flujo de ingresos mensuales del negocio

Diferencia Conceptual entre `DPTO`, `AREA` y `CLASE`

En la GEIH, estas tres variables delimitan dimensiones geográficas distintas y no son intercambiables: 1. `DPTO`: Representa la división político-administrativa de primer nivel (24 departamentos más Bogotá D.C. en los microdatos estándar). Permite agregar información regional o departamental completa (cabeceras más zonas rurales). 2. `AREA`: Identifica dominios urbanos y metropolitanos específicos. En la GEIH, las 13 ciudades y áreas metropolitanas principales corresponden a los códigos `c(5, 8, 11, 13, 17, 23, 50, 52, 54, 66, 68, 73, 76)` (Medellín A.M., Barranquilla A.M., Bogotá D.C., Cartagena, Manizales A.M., Montería, Villavicencio, Pasto, Cúcuta A.M., Pereira A.M., Bucaramanga A.M., Ibagué y Cali A.M.). No cubre áreas rurales. 3. `CLASE`: Diferencia la morfología del asentamiento humano dentro de un municipio: `1 = Cabecera municipal` (casco urbano consolidado) y `2 = Centros poblados y rural disperso`. Permite el análisis urbano-rural.

Numeral 1.4: Integración Relacional de EMICRON y GEIH 2024 (`base_micro`)

Selección Muestral y Asimetría de Inclusión

La Encuesta de Micronegocios (EMICRON) no es una muestra aleatoria independiente tomada de un censo de empresas. Es una submuestra derivada de la GEIH: - **Población elegible:** En la muestra mensual de la GEIH, el DANE identifica a los ocupados cuya posición ocupacional (`P6430`) corresponde a trabajadores por cuenta propia (4) o patrones/empleadores (5) en unidades económicas de hasta 9 personas ocupadas. - **Relación asimétrica:** Todo registro de la EMICRON proviene forzosamente de un hogar encuestado por la GEIH. Por el contrario, solo una fracción de la muestra de la GEIH califica para la EMICRON. Entender esta relación de inclusión es indispensable: el pegue correcto debe realizarse sobre la base de la EMICRON como tabla izquierda (`left_join`), preservando sus 78.501 registros sin pérdida ni multiplicación.

Cobertura Geográfica Diferencial

Existe una divergencia geográfica estructural entre ambas operaciones estadísticas: - La GEIH cubre 32 entidades territoriales en su marco general (y 25 dominios departamentales en los microdatos mensuales estándar). - La EMICRON excluye explícitamente de su diseño muestral a los ocho departamentos de la Amazonía y Orinoquía: Amazonas, Arauca, Casanare, Guainía, Guaviare, Putumayo, Vaupés y Vichada (documentado en la ficha metodológica y catálogo 875 de microdatos de ANDA/DANE).

Metodología de Ponderación: `FEX_C18` vs. `F_EXP`

Uno de los errores más graves en econometría aplicada es intercambiar o combinar factores de expansión con universos y períodos disímiles: - `FEX_C18` (Factor de la GEIH): Ponderador probabilístico de personas calibrado mensualmente contra proyecciones de población nacional. Si se combinan varios meses para estimar poblaciones promedio, el factor debe dividirse entre el número de meses analizados (ej. FEX_C18 /3 para estimaciones trimestrales y FEX_C18 /12 para estimaciones anuales). - `F_EXP` (Factor de la EMICRON): Ponderador probabilístico anual de micronegocios. Cada registro expandido representa el número total de unidades económicas existentes en el país durante el año calendario 2024. **Bajo ninguna circunstancia debe dividirse entre 12 ni entre el número de meses**, pues subestimaría el universo de micronegocios en un factor de 12. Tampoco puede combinarse con `FEX_C18` en una misma fórmula para personas y micronegocios simultáneamente.

Determinación Empírica de la Llave: `SECUENCIA_ENCUESTA` vs. `ORDEN`

En los microdatos de la EMICRON no se publica la variable `ORDEN`, sino `SECUENCIA_ENCUESTA`. Al examinar empíricamente su distribución en los 78.501 registros de EMICRON (`1_4_secuencia_encuesta.csv` y `1_4_relacion_orden.csv`), se comprueba que: - El 99,3 % de los registros toma valores entre `1` y `3`, pero el valor máximo llega hasta `11` (exactamente el rango de miembros de un hogar). - En el 100 % de los casos emparejados con la GEIH, el valor de `SECUENCIA_ENCUESTA` coincide unívocamente con el valor de `ORDEN` de la persona propietaria del micronegocio. Por lo tanto, la llave de persona para unir EMICRON con GEIH es `DIRECTORIO + SECUENCIA_P + SECUENCIA_ENCUESTA` (empatada con `ORDEN`).

Desfase Temporal y Período de Referencia

Al contrastar `MES_REF` (EMICRON) con `MES` (GEIH) sobre las observaciones enlazadas, se evaluaron tres hipótesis formales (`1_4_relacion_meses.csv`): 1. **Mismo mes ($\mathbf{MES_REF = MES_{GEIH}}$):** 0 % de correspondencia. 2. **Un mes atrás ($\mathbf{MES_REF = MES_{GEIH} - 1}$):** 0 % de correspondencia. 3. **Un mes adelante ($\mathbf{MES_REF = MES_{GEIH} + 1}$):** 100 % de correspondencia (71.754 de 71.754 casos).

Este desfase responde al operativo de campo: la entrevista de EMICRON se aplica el mes siguiente a la visita de la GEIH. Debido a este desfase, el mes jamás debe incorporarse dentro de la llave de unión, pues destruiría el emparejamiento.

Auditoría del Enlace y Explicación de los Registros No Emparejados

Al realizar el `left_join` de EMICRON 2024 con GEIH 2024: - De los 78.501 micronegocios, 71.754 (91,41 %) enlazan con la GEIH 2024 (`base_micro`). - Los 6.747 registros sin enlace (8,59 %) corresponden en su totalidad al mes de referencia `ENERO` de 2024 (`1_4_auditoria_mensual.csv`). - **Causa estructural:** Dado el desfase de recolección de un mes, los informantes de enero de 2024 de EMICRON fueron encuestados en la GEIH en diciembre de 2023. Al cruzar estos 6.747 registros con diciembre de 2023 de la GEIH (`1_4_fuera_2024.csv`), se encuentra al 100 % de ellos (6.747 de 6.747). Quedan fuera de `base_micro` por diseño temporal del ejercicio (que restringe el pegue a 2024) y no por un error en la llave de enlace.

Validación de la Calidad del Enlace

Para verificar que el pegue unió a la persona correcta, se contrastaron variables sociodemográficas medidas de forma independiente en ambas encuestas (`1_4_consistencia_sociodemografica.csv`): - Coincidencia en sexo (`P35` vs. `P3271`): 100,0 %. - Coincidencia en edad (`P241` vs. `P6040`): 100,0 %. - Coincidencia en zona geográfica (`CLASE_TE` vs. `CLASE`): 100,0 %.

Interpretación de la Posición Ocupacional en 1.4.g

En la base enlazada (`1_4_posicion_ocupacional.csv`), el 88,53 % de los propietarios son trabajadores por cuenta propia (`64.479` registros) y el 9,22 % son patrones o empleadores (`6.019` registros), sumando el **97,75 %** en conjunto. El **2,25 %** restante reporta posiciones como obrero particular (1,54 %) o trabajador sin remuneración

(0,33 %), lo que responde a transiciones ocupacionales ocurridas durante el desfase temporal entre encuestas o a situaciones de pluriactividad donde el micronegocio es secundario frente a un empleo asalariado principal.

Principales Indicadores de Mercado Laboral (Punto 2)

Numeral 2.1: Tasas y Poblaciones (2023-2024)

Los indicadores macroeconómicos del mercado laboral se construyen expandiendo las observaciones muestrales con `FEX_C18 / 3` para obtener los promedios trimestrales oficiales:

$$\text{Tasa Global de Participación (TGP)} = \frac{\text{Fuerza de Trabajo}}{\text{Población en Edad de Trabajar (PET)}} \times 100$$

$$\text{Tasa de Ocupación (TO)} = \frac{\text{Ocupados}}{\text{Población en Edad de Trabajar (PET)}} \times 100$$

$$\text{Tasa de Desempleo (TD)} = \frac{\text{Desocupados}}{\text{Fuerza de Trabajo}} \times 100$$

El script genera y exporta las tablas `2_1_tasas_hombres.xlsx` y `2_1_tasas_mujeres.xlsx`, comprobando en cada trimestre que FT = Ocupados + Desocupados (`2_1_consistencia_tasas.csv`).

Numeral 2.2: Descomposición del Desempleo y Brechas de Género

El gráfico `2_2_tasas_sexo.png` ilustra el comportamiento de las tres tasas en paneles separados por sexo entre 2023 y 2024: - **Evolución del desempleo:** La variación de la tasa de desempleo responde a la interacción dinámica entre la tasa de ocupación (demanda laboral) y la tasa global de participación (oferta laboral). Por ejemplo, entre el primer trimestre de 2024 (TD masculina de 9,57 % y femenina de 14,98 %) y el cuarto trimestre de 2024 (7,06 % en hombres y 11,15 % en mujeres), el descenso del desempleo obedeció a un aumento de la tasa de ocupación hacia fin de año. - **Brechas estructurales de género:** En todos los trimestres, los hombres superan a las mujeres en más de 24 puntos porcentuales en TGP (76,30 % vs. 52,66 % en O-D 2024) y en TO (70,92 % vs. 46,79 % en O-D 2024), mientras que las mujeres enfrentan una tasa de desempleo entre 4 y 5,4 puntos porcentuales superior.

Numeral 2.3: Informalidad Laboral en 13 Ciudades (Diciembre 2024)

Replicación Exacta del Algoritmo Multidimensional del DANE (`Código_SAS`)

La medición de formalidad del DANE evalúa cuatro variables secuenciales (`FORMAL`, `SALUD`, `PENSION` y `EI`) mediante bloques `case_when` explícitos que replican íntegramente la sintaxis oficial `Código_SAS` del DANE: 1. **`FORMAL` (formalidad de la unidad económica):** - Administración pública y organizaciones extraterritoriales (`RAMA2D_R4 %in% c(84, 99)`) y empleados del gobierno (`P6430 == 2`) son formales (`1`). - Empleados domésticos (`P6430 == 3`), trabajadores familiares sin remuneración (`P6430 == 6`) y jornaleros (`P6430 == 8`) reciben `FORMAL = 0` en el paso empresarial. - Para asalariados particulares (`P6430 %in% c(1, 7)`), trabajadores por cuenta propia (`P6430 %in% c(4, 9)`) y patrones (`P6430 == 5`), el árbol evalúa el lugar de trabajo (`P6765`), el registro mercantil (`P3065` / `P6775`), la contabilidad (`P3066` / `P3068`), el local en vivienda (`P3067`, `P3067S1`, `P3067S2`), el tamaño de empresa (`P3069`) y el oficio (`OFICIO_C8_2D`). - En los microdatos públicos GEIH 2024, `P3045S1` y `P3046` vienen en `NA`, por lo que las condiciones iniciales para `P6430 %in% c(1, 7)` evalúan como `FALSE` y recaen en las reglas generales por lugar de trabajo (`P6765`), exactamente igual que en la sintaxis oficial del DANE. 2. **`SALUD` y `PENSION` (protección social contributiva):** - Clasifican la cotización a salud (`P6100`, `P6110`, `P6450`) y pensión (`P6920`, `P6930`, `P6940`, `P6450`) de los asalariados (`P6430 %in% c(1, 2, 3, 8)`). 3. **`EI` (empleo formal = 1, empleo informal = 0):** - Ramas `84` y `99` y empleados del gobierno (`P6430 == 2`) son formales (`1`); trabajadores sin

remuneración (`P6430 %in% c(6, 7)`) son informales (`0`); empleados domésticos (`P6430 == 3`) y jornaleros (`P6430 == 8`) dependen de `SALUD == 1 & PENSION == 1`; obreros particulares (`P6430 == 1`) exigen `SALUD == 1 & PENSION == 1` (o desempate con `FORMAL` cuando `SALUD == 9`); e independientes/patrones (`P6430 %in% c(4, 5, 9)`) toman el valor de `FORMAL`.

Al replicar el cálculo para el trimestre octubre–diciembre de 2024 en las 13 ciudades y áreas metropolitanas, la proporción de ocupados informales es de **42,5 %**, mostrando una diferencia de **0,0 puntos porcentuales** frente al boletín oficial del DANE (`2_3_control_ei_dane.csv`). En el mes de diciembre de 2024 (`2_3_formalidad_13ciudades.png` y `2_3_tabla_formalidad_13ciudades.csv`), la informalidad en las 13 ciudades fue de **42,2 %** en hombres (57,8 % formal) y **42,3 %** en mujeres (57,7 % formal).

Numeral 2.4: Posición Ocupacional Nacional (Enero 2023)

El gráfico `2_4_posicion_nacional.png` presenta la distribución de los ocupados según posición ocupacional y sexo para enero de 2023: - Los trabajadores por cuenta propia concentran el **40,6 %** del empleo nacional y los patrones o empleadores el **2,6 %**, sumando en conjunto el **43,2 %** de la población ocupada del país (alrededor de 9,6 millones de personas). - **Relevancia metodológica:** Este 43,2 % constituye precisamente la población objetivo a partir de la cual el DANE identifica y selecciona la muestra de la Encuesta de Micronegocios (EMICRON).

Caracterización de los Micronegocios en Colombia (Punto 3)

Numeral 3.1: Indicadores Estructurales y Comparación con el Boletín DANE (EMICRON 2024)

Los porcentajes de `3_1_indicadores.xlsx` se calcularon directamente con la suma de `F_EXP` **antes de redondear los totales expandidos** (`TOTAL_SIN_REDONDEAR = sum(F_EXP, na.rm = TRUE)`): - **Total nacional:** 5.297.252 micronegocios (coincidencia exacta con el boletín técnico del DANE). - **Composición por sexo (`P35`):** 64,6 % liderados por hombres (3.421.325) y 35,4 % por mujeres (1.875.927). - **Ramas de actividad (`GRUPOS12`):** Comercio y reparación de vehículos (23,9 %; 1.263.754) y agricultura, ganadería, caza, silvicultura y pesca (21,5 %; 1.138.758) concentran el 45,4 % del total, seguidas por industrias manufactureras (10,0 %; 531.988) y alojamiento y servicios de comida (8,3 %; 440.223). Se documentan 4 registros con código `GRUPOS12 == 13` (*No informa*, 82 micronegocios expandidos, 0,0 %). - **Registro Único Tributario (`P1633`):** El 22,4 % cuenta con RUT (1.185.978) y el 77,6 % no cuenta con RUT (4.111.274), coincidiendo con el Gráfico 11 del boletín DANE. - **Cámara de Comercio (`P1055`) y explicación de la discrepancia de —0, 2 pp:** - Nuestro cálculo sobre los microdatos arroja **10,3 %** con registro mercantil (`P1055 == 1`) y **89,7 %** sin registro (`P1055 == 2`). - El **Gráfico 9** del Boletín Técnico EMICRON 2024 publica **10,5 %** con registro y **89,5 %** sin registro, lo que representa una diferencia de **—0, 2 puntos porcentuales** (`+0,2` pp en no registrados). - Al contrastar la **Tabla 8** y el **Anexo F.6** del mismo boletín oficial del DANE, se verifica que las cantidades absolutas publicadas por el DANE son **547.581** micronegocios con registro mercantil (548 mil en el cuadro del boletín) y **4.749.671** sin registro sobre un total de **5.297.252**; su cociente exacto es $\frac{547.580,7}{5.297.252,1} = 10,337$ % (**10,3 %** a un decimal), lo que demuestra que los microdatos coinciden exactamente con las tablas absolutas del anexo oficial (`3_1_indicadores.xlsx` y objeto `verificacion_3_1_dane`).

Numeral 3.2: Inclusión Financiera de Micronegocios

El módulo de inclusión financiera evalúa los medios de pago aceptados (`P1764_1` a `P1764_7`), la solicitud de crédito (`P1765`) y el ahorro (`P3014`): - **Automatización en el script:** El cálculo del porcentaje expandido para las 7 variables se resuelve mediante un ciclo sobre `1:7` agrupado por rama (`GRUPOS4`), ponderando con `F_EXP`. - **Resultados e interpretación (`3_2_formas_pago.png` y `3_2_credito_ahorro.csv`):** - El **efectivo** (`P1764_1`) es el medio predominante en todas las ramas: alcanza el 94,3 % en comercio, 89,7 % en servicios, 86,2 % en industria manufacturera y 85,1 % en agricultura. - Las **transferencias bancarias o por internet** (`P1764_3`, que

incluyen billeteras digitales como Nequi y Daviplata) presentan una marcada brecha sectorial: alcanzan el **51,9 %** en servicios, el **43,4 %** en comercio y el **36,1 %** en industria, pero apenas llegan al **6,7 %** en el sector agropecuario. - Los medios electrónicos con datáfono (`P1764_5` tarjeta débito y `P1764_6` tarjeta de crédito) no superan el 7,2 % en comercio y el 6,3 % en servicios (y son inferiores al 0,4 % en el agro). - Apenas el **14,2 %** de los micronegocios solicitó un préstamo o crédito (`P1765 == 1`) y solo el **18,1 %** ahorró parte de sus ingresos (`P3014 == 1`).

Numeral 3.3: Cruce Conjunto GEIH - EMICRON con Categorías Explícitas del DANE

- **Pregunta de investigación:** *¿Se asocia el nivel educativo alcanzado por el propietario del micronegocio (GEIH: `P3042`) con la tenencia de RUT en la unidad económica (EMICRON: `P1633`)?*
- **Universo y ponderador:** 71.754 propietarios emparejados entre febrero y diciembre de 2024, expandidos exclusivamente con `F_EXP` (4.864.444 micronegocios).
- **Clasificación explícita del diccionario GEIH 2024 (`P3042`):** Se clasifican por separado los códigos `1` a `13` y `99`. La auditoría comprueba que el 100 % de los 71.754 propietarios emparejados tiene niveles conocidos en `1:13` (`0` en `99 = No sabe, no informa`, `0` en `NA` y `0` códigos inválidos; `0` faltantes en `P1633`).
- **Hallazgos (`3_3_cruce.png` y `3_3_tabla_educacion_rut.csv`):**
  - La tenencia de RUT muestra un gradiente positivo continuo a lo largo de las 13 categorías del DANE: **0,0 %** en *Preescolar* ($n = 6$), **2,8 %** en *Ninguno*, **11,7 %** en *Básica primaria (1o - 5o)*, **13,1 %** en *Normalista*, **14,5 %** en *Básica secundaria (6o - 9o)*, **22,3 %** en *Media académica* y **26,8 %** en *Media técnica*.
  - En educación superior y posgrado la formalización se acelera: **34,0 %** en *Técnica profesional*, **43,9 %** en *Tecnológica*, **51,7 %** en *Universitaria*, **73,2 %** en *Especialización*, **78,7 %** en *Maestría* y **88,8 %** en *Doctorado*.
- **Factores explicativos no causales:** La asociación estadística no implica causalidad directa, pues intervienen la escala del negocio (mayor capital inicial y ventas que superan topes regulatorios) y la especialización sectorial en servicios profesionales donde la facturación electrónica y el RUT son requisitos de contratación.

Análisis Socioeconómico de la Población Colombiana (Punto 4)

Numeral 4.1: Geografía de la Informalidad Laboral

El gráfico `4_1_geografia_informalidad.png` contrasta la tasa de informalidad departamental con el ingreso laboral mediano (`INGLABO > 0`) en 2024: - Muestra una relación inversa pronunciada: en Bogotá D.C. la informalidad es de **34,6 %** con un ingreso mediano de **$1,60 millones**, seguida de Cundinamarca (44,6 %) y Antioquia (44,9 %). - En contraste, Chocó (**80,8 %**), Sucre (**79,9 %**) y La Guajira (**79,5 %**) registran ingresos medianos de **$0,60 millones**, reflejando el dualismo productivo centro-periferia.

Numeral 4.2: Inclusión Digital, Solicitud de Crédito y Escala de Ventas

El gráfico `4_2_inclusion_ventas_micro.png` evalúa las ventas brutas mensuales (`VENTAS_MES_ANTERIOR > 0`) cruzando el perfil de medios de pago (**Transferencias bancarias / internet** con `P1764_3 == 1` frente a **Solo efectivo** definido como efectivo exclusivo `P1764_1 == 1` sin otros medios seleccionados en `P1764_2:7`) con la **solicitud de crédito** (`P1765`: `1 = Solicitó crédito`, `2 = No solicitó crédito`): - **Auditoría de no respuesta y exclusiones:** De los 75.671 micronegocios con ventas positivas, se contabilizan y documentan **5.202 registros sin respuesta (`NA`) en `P1765`** (338.120 expandidos; 5.376 en toda la EMICRON) y **645 registros en otros perfiles de pago** (23 de ellos también con `NA` en `P1765`), analizando **69.847 unidades válidas** (4.711.543 expandidas). - **Resultados (`4_2_tabla_inclusion_ventas.csv`):** - En **Solo efectivo**, la mediana de ventas mensuales pasa de **$1,20 millones** sin solicitud de crédito ($n = 37.700$) a **$1,70 millones** con solicitud de crédito ($n = 5.804$). - En **Transferencias bancarias / internet**, la mediana sube a **$2,30 millones** sin solicitud de crédito ($n = 21.061$) y alcanza **$3,00 millones** con solicitud de crédito ($n = 5.282$).

Numeral 4.3: Emparejamiento Laboral entre Nivel Educativo y Posición Ocupacional

El gráfico `4_3_mismatch_educacion.png` cruza las **13 categorías educativas explícitas del DANE** (`P3042`: `1` a `13`) con las **9 posiciones ocupacionales** (`P6430`: `1` a `9`) sobre 353.668 ocupados de la GEIH 2024 (excluyendo y documentando los únicos 4 registros con `P3042 == 99`, equivalentes a 473 ocupados expandidos): - En *Ninguno* (62,5 %), *Básica primaria* (54,8 %) y *Básica secundaria* (48,6 %) predomina el trabajo por cuenta propia. - A partir de *Media académica* (47,8 % obrero particular vs. 39,9 % cuenta propia) y *Media técnica* (57,8 % vs. 32,7 %), y en toda la educación superior (*Técnica profesional* 61,5 %, *Tecnológica* 66,6 %, *Universitaria* 62,1 %) y posgrado (*Especialización* 58,4 %, *Maestría* 55,6 %, *Doctorado* 56,5 %), predomina el empleo asalariado particular junto con una participación creciente del empleo en el gobierno (hasta 28,2 % en *Doctorado*). - Sin embargo, se identifican **986.256 ocupados con educación superior o posgrado** (`P3042 %in% 8:13`) trabajando por cuenta propia (incluyendo 454.991 universitarios y 360.875 técnicos profesionales), reflejando sobreeducación y refugio en el autoempleo.

Banco de Preguntas y Argumentación para la Sustentación Oral (Punto 5)

Este banco organiza las preguntas de defensa individual directamente por los cuatro numerales del taller, vinculando cada respuesta a las líneas exactas del script oficial y a la evidencia empírica.

Bloque 1: Defensa del Punto 1 (Conformación de Bases y Enlace Relacional)

Pregunta 1.1: ¿Por qué la llave relacional de la GEIH exige tres variables y qué riesgo existe al omitir una?

Respuesta: La GEIH maneja una estructura anidada donde `DIRECTORIO` identifica la vivienda, `SECUENCIA_P` el hogar y `ORDEN` la persona. Si se omitiera `SECUENCIA_P`, en viviendas multifamiliares con más de un hogar se emparejarían personas distintas que comparten el mismo número de orden (ej. el hijo del hogar 1 con el del hogar 2), generando una multiplicación espuria de registros y corrompiendo la representatividad muestral.

Pregunta 1.2: ¿Por qué se utilizó `contador <- 1` en el bucle 1.1 en lugar de `append()`?

Respuesta: En R, las listas son objetos inmutables en memoria. Usar `append()` obliga al intérprete a duplicar y reasignar toda la lista en cada iteración ($O(N^2)$ en memoria). Inicializar `contador <- 1` permite indexar directamente por posición (`lista[[contador]] <- df`), asignando memoria en tiempo constante $O(1)$. Además, coordina la indexación global de 1 a 24 para las tablas de auditoría de los 2 años, mientras el índice local `i` corre de 1 a 12 para agrupar las bases mensuales de cada año antes de consolidarlas con `bind_rows()`.

Pregunta 1.3: ¿Por qué 6.747 micronegocios de EMICRON 2024 no emparejan con la GEIH de 2024?

Respuesta: Por el desfase de recolección temporal ($\text{MES_REF} = \text{MES}_{\text{GEIH}} + 1$). En consecuencia, los informantes encuestados en enero de 2024 en EMICRON fueron entrevistados por la GEIH en diciembre de 2023. Al cruzar esos 6.747 registros contra diciembre de 2023 de la GEIH (`1_4_fuera_2024.csv`), se encuentra al 100 % de ellos. No es un error de llave, sino un límite temporal del ejercicio al restringir la base a 2024.

Pregunta 1.4: ¿Por qué no se puede usar indistintamente `FEX_C18` y `F_EXP`?

Respuesta: Porque representan universos y períodos distintos. `FEX_C18` expande personas de la GEIH y está calibrado mensualmente; para calcular trimestres debe dividirse entre 3 y para años entre 12. `F_EXP` expande unidades productivas de micronegocios en EMICRON y es un ponderador anual calibrado para todo 2024. Si se dividiera `F_EXP` entre 12, se subestimaría el universo microempresarial a la doceava parte. Mezclarlos en un mismo cálculo destruye la validez de la inferencia.

Bloque 2: Defensa del Punto 2 (Indicadores Laborales y Formalidad DANE)

Pregunta 2.1: ¿Por qué para las tasas trimestrales del punto 2.1 se divide `FEX_C18` entre 3?
Respuesta: Porque `FEX_C18` es un factor mensual. Al apilar los tres meses de un trimestre (ej. enero, febrero y marzo), la suma simple del factor triplicaría la población real de Colombia. Dividir entre 3 calcula la población promedio del trimestre, que es el estándar metodológico oficial del DANE para estimar poblaciones y tasas del mercado de trabajo.

Pregunta 2.2: ¿Cómo se construyó la clasificación de formalidad laboral (`EI`) en el punto 2.3?
Respuesta: Se replicaron de forma explícita y completa las reglas secuenciales de la sintaxis oficial `Código_SAS` del DANE para las variables `FORMAL`, `SALUD`, `PENSION` y `EI`, respetando el orden de evaluación de cada condición. En los microdatos públicos GEIH 2024, `P3045S1` y `P3046` vienen en `NA`, por lo que las condiciones iniciales para `P6430 %in% c(1, 7)` evalúan como `FALSE` y recaen en el bloque general por lugar de trabajo (`P6765`), igual que en el programa oficial del DANE. La tasa de informalidad en las 13 ciudades para octubre–diciembre de 2024 es de 42,5 %, con 0,0 pp de diferencia frente al boletín del DANE.

Pregunta 2.3: ¿Cómo se interpreta que baje la tasa de desempleo pero caiga la tasa de ocupación?
Respuesta: Ocurre por el efecto del trabajador desalentado. Si la caída en la ocupación (pérdida de empleos) coincide con una caída aún mayor en la tasa de participación (personas que abandonan la fuerza de trabajo y pasan a inactividad), el denominador de la tasa de desempleo (fuerza de trabajo) se reduce más rápido que los desocupados, haciendo caer la tasa de desempleo a pesar de que el mercado laboral se está deteriorando.

Bloque 3: Defensa del Punto 3 (Micronegocios e Inclusión Financiera)

Pregunta 3.1: ¿Por qué en Cámara de Comercio (`P1055 == 1`) el cálculo da 10,3 % mientras el Gráfico 9 del boletín DANE muestra 10,5 %?
Respuesta: Porque al calcular los porcentajes directamente con `F_EXP` antes de redondear los totales, los micronegocios con registro mercantil suman `547.580,7` sobre un total de `5.297.252,1`, cuyo cociente exacto es `10,337 %` (**10,3 %** a un decimal), es decir, **—0, 2 puntos porcentuales** frente al **10,5 %** impreso en el Gráfico 9 del boletín. Al contrastar la **Tabla 8** y el **Anexo F.6** del mismo boletín técnico del DANE, las cifras publicadas por el DANE son exactamente `547.581` (548 mil) sobre `5.297.252`, las cuales producen `10,337 %`, confirmando la exactitud de nuestro cálculo.

Pregunta 3.2: ¿Por qué la mayor aceptación de transferencias (`P1764_3`) en comercio y servicios no se traduce en una alta solicitud de crédito (`P1765`)?
Respuesta: Porque las transferencias bancarias o por internet (`P1764_3`, que alcanzan 51,9 % en servicios y 43,4 % en comercio) resuelven fricciones de cobro transaccional con costos fijos mínimos. El crédito formal, en cambio, exige historial financiero, garantías y formalidad tributaria/mercantil (solo 22,4 % tiene RUT y 10,3 % registro en Cámara de Comercio), por lo que apenas el 14,2 % de los micronegocios solicitó crédito.

Pregunta 3.3: ¿Cómo se trataron las categorías de `P3042` en el cruce 3.3 y por qué la relación con el RUT no es causal?
Respuesta: Se clasificaron explícitamente las 13 categorías de niveles conocidos del diccionario GEIH 2024 (`P3042 == 1` a `P3042 == 13`) y se auditaron el código `99` (*No sabe, no informa*), los `NA` y los códigos inválidos (verificando que los 71.754 propietarios emparejados tienen niveles conocidos en `1:13`). Aunque el porcentaje con RUT sube de 0,0 % en *Preescolar* y 2,8 % en *Ninguno* hasta 51,7 % en *Universitaria* y 88,8 % en *Doctorado*, esta asociación no es causal directa: está mediada por la mayor escala de ventas y por la inserción de los profesionales en sectores de servicios que exigen RUT para contratar con empresas formales.

Bloque 4: Defensa del Punto 4 (Análisis Socioeconómico y Rigor Gráfico)

Pregunta 4.1: ¿Qué correcciones metodológicas se aplicaron en el análisis de inclusión financiera y ventas (4.2) y en el cruce educativo-ocupacional (4.3)?

Respuesta: En 4.2 se identificaron las transferencias bancarias o por internet con `P1764_3 == 1` (ya que `P1764_2` es cheque), se definió *Solo efectivo* como efectivo exclusivo (`P1764_1 == 1` sin ningún otro medio seleccionado entre `P1764_2` y `P1764_7`), y se trató `P1765` como solicitud de crédito (`1 = Solicitó`, `2 = No solicitó`), auditando y documentando los 5.202 registros con `NA` en `P1765` y los 645 de otros medios antes de graficar los 69.847 registros válidos. En 4.3 se utilizaron las 13 categorías explícitas de `P3042` (`1:13`, excluyendo y documentando los 4 registros con código `99`) frente a las 9 posiciones ocupacionales de `P6430`, identificando 986.256 ocupados con educación superior o posgrado en trabajo por cuenta propia.

Pregunta 4.2: ¿Qué criterios garantizan que todos los gráficos del taller estén completamente documentados y sean autocontenidos?

Respuesta: Tanto en el script como en el cuaderno pedagógico, cada gráfico está documentado detallando datos y ponderador (`FEX_C18 / 3`, `FEX_C18 / 12` o `F_EXP`), mapeos estéticos (`aes`), capas geométricas (`geom_*`), ajustes de posición (`position_dodge`, `position_stack`), escalas (`scale_*`), sistema de coordenadas (`coord_flip`), facetas (`facet_wrap`), paleta de colores, etiquetas (`labs` con título, subtítulo, ejes, leyenda y fuente con universo y exclusiones), tema (`theme_bw` y `theme`) y parámetros de exportación (`ggsave` a 300 DPI).