Guía Maestra de Estudio: Mercado Laboral, Microdatos y Micronegocios en Colombia

Tratado Metodológico, Estadístico y Conceptual Aplicado al Taller 2 (GEIH y EMICRON 2023-2024)

Grupo 10 · Maestría en Economía Aplicada
Facultad de Economía · Universidad de los Andes

2026-10-01

Contenido de la Guía

Metodología, Arquitectura de Datos y Diccionario Exhaustivo (Punto 1) . . . 2
Numeral 1.1: Pegue Mensual de la GEIH (2023 y 2024) . . . 2
Estructura Relacional y Llave de Identificación . . . 2
Lógica del Bucle y Eficiencia Computacional . . . 3
Documentación del Contador en el Bucle (`contador <- 1`) . . . 3
Verificaciones Programáticas de Integridad . . . 3
Numeral 1.2: Descripción Modular y Consistencia Laboral (2024) . . . 4
Relación de Inclusión y Tamaños Muestrales . . . 4
Verificación de Identidades Conceptuales . . . 4
Numeral 1.3: Diccionario de Datos Exhaustivo . . . 4
Tabla 1: Variables Requeridas de la GEIH (Numeral 1.3) . . . 4
Tabla 2: Variables Auxiliares Indispensables para la Formalidad DANE (Numeral 2.3) . . . 7
Tabla 3: Variables de la EMICRON 2024 (Numerales 1.4, 3 y 4.2) . . . 9
Diferencia Conceptual entre `DPTO`, `AREA` y `CLASE` . . . 11
Numeral 1.4: Integración Relacional de EMICRON y GEIH 2024 (`base_micro`) . . . 12
Selección Muestral y Asimetría de Inclusión . . . 12
Cobertura Geográfica Diferencial . . . 12
Metodología de Ponderación: `FEX_C18` vs. `F_EXP` . . . 12
Determinación Empírica de la Llave: `SECUENCIA_ENCUESTA` vs. `ORDEN` . . . 12
Desfase Temporal y Período de Referencia . . . 12
Auditoría del Enlace y Explicación de los Registros No Emparejados . . . 13
Validación de la Calidad del Enlace . . . 13
Interpretación de la Posición Ocupacional en 1.4.g . . . 13
Principales Indicadores de Mercado Laboral (Punto 2) . . . 13
Numeral 2.1: Tasas y Poblaciones (2023-2024) . . . 13
Numeral 2.2: Descomposición del Desempleo y Brechas de Género . . . 14
Numeral 2.3: Informalidad Laboral en 13 Ciudades (Diciembre 2024) . . . 14
Adaptación y validación de la clasificación del DANE (`Código_SAS`) . . . 14
Numeral 2.4: Posición Ocupacional Nacional (Enero 2023) . . . 14
Caracterización de los Micronegocios en Colombia (Punto 3) . . . 14
Numeral 3.1: Indicadores Estructurales y Comparación con el Boletín DANE (EMICRON 2024) . . . 14
Numeral 3.2: Inclusión Financiera de Micronegocios . . . 15

Numeral 3.3: Cruce Conjunto GEIH - EMICRON con Categorías Explícitas del DANE 15
Análisis Socioeconómico de la Población Colombiana (Punto 4) 16
Numeral 4.1: Geografía de la Informalidad Laboral 16
Numeral 4.2: Inclusión Digital, Solicitud de Crédito y Escala de Ventas 16
Numeral 4.3: Emparejamiento Laboral entre Nivel Educativo y Posición Ocupacional 16
Banco de Preguntas y Argumentación para la Sustentación Oral (Punto 5) 16
Bloque 1: Defensa del Punto 1 (Conformación de Bases y Enlace Relacional) 17
Pregunta 1.1: ¿Por qué la llave relacional de la GEIH exige tres variables y qué riesgo existe al omitir una? 17
Pregunta 1.2: ¿Por qué se utilizó `contador <- 1` en el bucle 1.1 en lugar de `append()`? 17
Pregunta 1.3: ¿Por qué 6.747 micronegocios de EMICRON 2024 no emparejan con la GEIH de 2024? . 17
Pregunta 1.4: ¿Por qué no se puede usar indistintamente `FEX_C18` y `F_EXP`? 17
Bloque 2: Defensa del Punto 2 (Indicadores Laborales y Formalidad DANE) 17
Pregunta 2.1: ¿Por qué para las tasas trimestrales del punto 2.1 se divide `FEX_C18` entre 3? 17
Pregunta 2.2: ¿Cómo se construyó la clasificación de formalidad laboral (`EI`) en el punto 2.3? 17
Pregunta 2.3: ¿Cómo se interpreta que baje la tasa de desempleo pero caiga la tasa de ocupación? 17
Bloque 3: Defensa del Punto 3 (Micronegocios e Inclusión Financiera) 18
Pregunta 3.1: ¿Por qué en Cámara de Comercio (`P1055 == 1`) el cálculo da 10,3 % mientras el Gráfico 9 del boletín DANE muestra 10,5 %? 18
Pregunta 3.2: ¿Por qué la mayor aceptación de transferencias (`P1764_3`) en comercio y servicios no se traduce en una alta solicitud de crédito (`P1765`)? 18
Pregunta 3.3: ¿Cómo se trataron las categorías de `P3042` en el cruce 3.3 y por qué la relación con el RUT no es causal? 18
Bloque 4: Defensa del Punto 4 (Análisis Socioeconómico y Rigor Gráfico) 18
Pregunta 4.1: ¿Qué correcciones metodológicas se aplicaron en el análisis de inclusión financiera y ventas (4.2) y en el cruce educativo-ocupacional (4.3)? 18
Pregunta 4.2: ¿Qué criterios garantizan que todos los gráficos del taller estén completamente documentados y sean autocontenidos? 18

Metodología, Arquitectura de Datos y Diccionario Exhaustivo (Punto 1)

Esta sección fundamenta las decisiones de procesamiento, unión de módulos y auditoría de microdatos implementadas en el primer numeral del taller, vinculando las directrices del DANE con las soluciones adoptadas en el script oficial.

Numeral 1.1: Pegue Mensual de la GEIH (2023 y 2024)

La Gran Encuesta Integrada de Hogares (GEIH) es la principal operación estadística de mercado laboral de Colombia. Su recolección es mensual y continua, con cobertura sobre cabeceras municipales, centros poblados y rural disperso.

Estructura Relacional y Llave de Identificación

La encuesta organiza su información en módulos independientes vinculados mediante una estructura jerárquica: 1. `DIRECTORIO`: Identifica de manera unívoca la edificación o vivienda dentro del marco muestral. 2. `SECUENCIA_P`: Identifica el hogar dentro de la vivienda. 3. `ORDEN`: Identifica a la persona dentro del hogar.

Para individualizar a cada encuestado a lo largo de los capítulos, la llave relacional obligatoria es la tupla compuesta `c("DIRECTORIO", "SECUENCIA_P", "ORDEN")`. Omitir cualquiera de estas tres variables destruye la cardinalidad del enlace y produce emparejamientos espurios entre personas de distintos hogares en una misma edificación.

Lógica del Bucle y Eficiencia Computacional

El script oficial construye la serie de 24 meses (12 meses de 2023 y 12 meses de 2024) mediante dos bucles `for` anidados:

```
anios <- c("GEIH_2023", "GEIH_2024")
meses <- c(
  "01_Enero", "02_Febrero", "03_Marzo", "04_Abril",
  "05_Mayo", "06_Junio", "07_Julio", "08_Agosto",
  "09_Septiembre", "10_Octubre", "11_Noviembre", "12_Diciembre"
)
llave_geih <- c("DIRECTORIO", "SECUENCIA_P", "ORDEN")
```

Para optimizar el uso de memoria RAM y el tiempo de ejecución, el script aplica tres estrategias concretas: 1. **Selección temprana de columnas (`select` antes del join):** Ocupados pasa de 200 a 23 columnas, una reducción de 88,5 % documentada en `1_1_eficiencia.csv`. Las variables se seleccionan después de leer cada CSV y antes de unir los módulos. Este control no cuantifica directamente el ahorro de RAM. 2. **Homogeneización forzada de tipos de datos:** Las variables de identificación se convierten explícitamente a carácter (`as.character()`). Esto evita errores de pérdida de ceros a la izquierda y previene incompatibilidades de tipo entre meses o módulos. 3. **Manejo de excepciones contractuales:** En marzo de 2024, el archivo de no ocupados fue nombrado por el DANE como `"No ocupado.CSV"` en singular. El código detecta condicionalmente esta anomalía (`if (anio == "GEIH_2024" && mes == "03_Marzo") "No ocupado.CSV" else "No ocupados.CSV"`), permitiendo una ejecución continua sin intervención manual.

Documentación del Contador en el Bucle (`contador <- 1`)

Antes de iniciar los bucles se inicializa la variable `contador <- 1`. Al finalizar cada iteración mensual, se ejecuta `contador <- contador + 1`. El contador permite organizar las auditorías mensuales: - **Indexación posicional directa:** En cada mes, las matrices de verificación mensual se asignan directamente a su posición: `r conteos_modulos[[contador]] <- data.frame(...) verificacion_eficiencia[[contador]] <- data.frame(...) verificacion_llaves[[contador]] <- data.frame(...) verificacion_pegues[[contador]] <- data.frame(...)` - **Almacenamiento en listas:** Se acumulan los resultados mensuales y se consolidan al finalizar. Las listas empiezan vacías; la asignación por índice no preasigna memoria ni demuestra un costo constante. - **Interacción entre índices:** Mientras el índice `i` corre localmente de 1 a 12 para almacenar los data frames mensuales de cada año en `bases_mensuales_anio[[i]]`, el índice global `contador` avanza de 1 a 24, acumulando la auditoría ininterrumpida de los dos años evaluados. - **Consolidación final:** Al cerrar cada año, la lista de 12 data frames se une en un único paso vectorizado mediante `bind_rows(bases_mensuales_anio)`. Al finalizar los dos años, `bind_rows(GEIH_2023, GEIH_2024)` construye la base maestra de la GEIH.

Verificaciones Programáticas de Integridad

El script ejecuta dos controles de parada inmediata (`stop()`): 1. **Unicidad de la llave:** En cada mes se verifica que la llave no presente duplicados en ninguno de los 4 módulos (`sum(duplicated(df[, llave_geih])) == 0`). El resultado es 0 duplicados en todos los meses (`1_1_verificacion_llaves.csv`). 2. **Conservación de filas:** El módulo base es `Características generales` (N_{general}). Al unir sucesivamente por izquierda `Fuerza de trabajo`, `Ocupados` y `No ocupados`, el número de filas final debe ser idéntico al inicial. Si algún cruce aumentara las filas, el script aborta inmediatamente la ejecución (`1_1_verificacion_pegues.csv`).

Numeral 1.2: Descripción Modular y Consistencia Laboral (2024)

El módulo de características generales abarca a toda la población encuestada. Los demás módulos corresponden a filtros temáticos y poblaciones específicas:

Relación de Inclusión y Tamaños Muestrales

- **Población Total (Módulo General):** Registra a todas las personas del hogar, incluidos menores de edad. En 2024 suma 829.683 observaciones muestrales.
- **Población en Edad de Trabajar (PET, Módulo Fuerza de Trabajo):** En Colombia, la PET comprende a personas de 15 años y más (estandarizado por el DANE bajo lineamientos OIT). Suma 657.803 registros en 2024.
- **Ocupados (Módulo Ocupados):** Personas que durante la semana de referencia trabajaron al menos una hora remunerada, o no trabajaron pero tenían empleo, o trabajadores familiares sin remuneración que laboraron al menos una hora. Suma 353.672 registros en 2024.
- **No Ocupados (Módulo No Ocupados):** Agrupa a los desocupados (cesantes y aspirantes) y a la población fuera de la fuerza de trabajo (estudiantes, personas dedicadas al cuidado del hogar, rentistas, jubilados). Suma 304.131 registros en 2024.

Verificación de Identidades Conceptuales

El código comprueba programáticamente dos identidades laborales en cada uno de los 12 meses de 2024 (`1_2_consistencia_laboral_2024.csv`):

$$\text{PET} = \text{Fuerza de Trabajo (FT)} + \text{Fuera de la Fuerza de Trabajo (FFT)}$$

$$\text{Fuerza de Trabajo (FT)} = \text{Ocupados (OCI)} + \text{Desocupados (DSI)}$$

$$\text{Módulo Fuerza de Trabajo} = \text{Módulo Ocupados} + \text{Módulo No Ocupados}$$

Las tres identidades se satisfacen en el 100 % de los casos, validando la coherencia interna de las clasificaciones del DANE.

Numeral 1.3: Diccionario de Datos Exhaustivo

A continuación se detalla el diccionario completo estructurado por encuesta, módulo, tabla y numeral del taller.

Tabla 1: Variables Requeridas de la GEIH (Numeral 1.3)

Variables obligatorias solicitadas en los literales a) a d) del numeral 1.3:

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
DIRECTORIO	GEIH	Características generales	Identificador de la edificación o vivienda	Carácter	Código alfanumérico DANE	Vivienda	Llave relacional	1.1, 1.4	Conversión a carácter
SECUENCIA_P	GEIH	Características generales	Identificador del hogar dentro de la vivienda	Carácter	Consecutivo numérico (1, 2, ...)	Hogar	Llave relacional	1.1, 1.4	Conversión a carácter
ORDEN	GEIH	Características generales	Número de orden de la persona en el hogar	Carácter	Consecutivo numérico (1, 2, ...)	Persona	Llave relacional	1.1, 1.4	Conversión a carácter

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
PERIODO	GEIH	Características generales	Período de recolección de la encuesta	Numérico	Fecha: año, mes y día (ej. 20240101)	Registro	Filtro temporal	1.1, 1.3	Año: primeros cuatro dígitos de PERIODO
MES	GEIH	Características generales	Mes de recolección de la encuesta	Numérico	1 a 12 (Enero a Diciembre)	Registro	Filtro y control	1.1, 1.4, 2.1	Numérico para agregaciones
P3271	GEIH	Características generales	Sexo al nacer del encuestado	Categórico	1 = Hombre, 2 = Mujer	Persona	Clasificación	1.3, 1.4, 2.1	Etiquetado en factores para gráficos
P3042	GEIH	Características generales	Mayor nivel educativo alcanzado	Categórico	1=Ninguno, 2=Preescolar, 3=Básica primaria (1o-5o), 4=Básica secundaria (6o-9o), 5=Media académica, 6=Media técnica, 7=Normalista, 8=Técnica profesional, 9=Tecnológica, 10=Universitaria, 11=Especialización, 12=Maestría, 13=Doctorado, 99=No sabe/no informa	Persona	Indicador de capital humano	1.3, 3.3, 4.3	Clasificación explícita de los 13 niveles conocidos y auditoría de 99 y NA
P6090	GEIH	Características generales	Afiliación al Sistema de Seguridad Social en Salud	Categórico	1 = Sí, 2 = No, 9 = No sabe	Persona	Caracterización social	1.3	Mantenido en base analítica
P6040	GEIH	Características generales	Edad en años cumplidos	Numérico	Años cumplidos	Persona	Filtro demográfico	1.3, 1.4	Validado contra edad EMICRON (P241)
P6160	GEIH	Características generales	¿Sabe leer y escribir? (Alfabetismo)	Categórico	1 = Sí, 2 = No	Persona	Caracterización social	1.3	Mantenido en base analítica

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
DPTO	GEIH	Características generales	Código DANE del departamento	Categórico	Códigos DIVIPOLA de 2 dígitos (05 a 99)	Departamento	Dominio geográfico	1.3, 4.1	Cruce espacial departamental
AREA	GEIH	Características generales	Dominio geográfico o área metropolitana	Categórico	Códigos de área metropolitana y dominios	Área urbana	Filtro geográfico	1.3, 2.3	Filtro de las 13 ciudades principales
CLASE	GEIH	Características generales	Tipo de zona geográfica de la vivienda	Categórico	1 = Cabecera, 2 = Centros poblados y rural disperso	Zona	Dominio geográfico	1.3, 1.4	Contrastado con CLASE_TE
FEX_C18	GEIH	Características generales	Factor de expansión mensual calibrado	Numérico	Ponderador poblacional continuo	Persona	Factor de expansión	1.1 a 2.4, 4	Ajustado /3 en trimestres y /12 en año
PT	GEIH	Características generales	Indicador de Población Total	Binario	1 = Población total	Persona	Agregador poblacional	1.3, 2.1	Ponderado con FEX_C18
PET	GEIH	Fuerza de trabajo	Indicador de Población en Edad de Trabajar	Binario	1 = Pertenece a PET (15 años o más), NA = Menor de 15	Persona	Filtro laboral	1.2, 1.3, 2.1	Denominador de TGP y TO
FT	GEIH	Fuerza de trabajo	Indicador de Fuerza de Trabajo (PEA)	Binario	1 = Ocupado o desocupado, NA = Fuera de FT	Persona	Indicador laboral	1.2, 1.3, 2.1	Numerador de TGP; denom. de TD
FFT	GEIH	Fuerza de trabajo	Indicador de Población Fuera de la Fuerza de Trabajo	Binario	1 = Fuera de la fuerza de trabajo, NA = En FT	Persona	Indicador laboral	1.2, 1.3	Verificación de consistencia
P6240	GEIH	Fuerza de trabajo	Actividad principal realizada la semana anterior	Categórico	1=Trabajando, 2=Buscando, 3=Estudiando, 4=Hogar, 5=Incapacitado, 6=Otro	Persona	Caracterización laboral	1.3	Mantenido en base analítica
OCI	GEIH	Ocupados	Indicador de Ocupación	Binario	1 = Ocupado, NA = No ocupado	Persona	Filtro y numerador	1.2, 1.3, 2.1	Numerador de TO; base de formalidad
RAMA2D_R4	GEIH	Ocupados	Rama de actividad económica CIIU Rev. 4 A.C. a 2 dígitos	Categórico	Códigos 01 a 99	Empleo	Sector económico	1.3, 2.3	Define formalidad en ramas 84 y 99

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P6430	GEIH	Ocupados	Posición ocupacional en el empleo principal	Categórico	1=Obrero particular, 2=Obrero gobierno, 3=Empleado doméstico, 4=Cuenta propia, 5=Patrón, 6=Familiar sin remun., 7=Sin remun. en otras empresas, 8=Jornalero o peón, 9=Otro	Persona	Clasificación ocupacional	1.3, 1.4, 2.4, 4.3	Eje central del árbol de formalidad y del cruce 4.3
INGLABO	GEIH	Ocupados	Ingreso laboral monetario mensual	Numérico	Valor en pesos colombianos	Persona	Variable socioeconómica	1.3, 4.1	Base de medianas departamentales (4.1)
DSI	GEIH	No ocupados	Indicador de Desocupación	Binario	1 = Desocupado, NA = No desocupado	Persona	Numerador laboral	1.2, 1.3, 2.1	Numerador de la Tasa de Desempleo

Tabla 2: Variables Auxiliares Indispensables para la Formalidad DANE (Numeral 2.3)

Variables de Características generales y Ocupados utilizadas en la adaptación de `Código_SAS`. Se verificaron con el diccionario descargable del catálogo GEIH 2024; su archivo interno conserva el nombre GEIH 2023. Algunas etiquetas del catálogo web difieren del archivo, por ejemplo `P3066`; aquí se usa la descripción del diccionario descargable.

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P6100	GEIH	Características generales	Régimen de seguridad social en salud	Categórico	1 = Contributivo, 2 = Especial, 3 = Subsidiado, 9 = No sabe	Persona	Régimen de salud	2.3	Construcción de SALUD
P6110	GEIH	Características generales	Quién paga la afiliación a salud	Categórico	1 = Persona y empresa, 2 = Descuento de pensión, 3 = Persona paga todo, 4 = Empresa paga todo, 5 = Beneficiario, 9 = No sabe	Persona	Pago de salud	2.3	Construcción de SALUD

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P6450	GEIH	Ocupados	Tipo de contrato laboral	Categórico	1 = Verbal, 2 = Escrito, 9 = No sabe	Empleo	Formalidad asalariados	2.3	Desempata cotizaciones con no sabe/no informa
P6920	GEIH	Ocupados	¿Cotiza actualmente a un fondo de pensiones?	Categórico	1 = Sí cotiza, 2 = No cotiza, 3 = Ya es pensionado	Empleo	Formalidad asalariados	2.3	Define variable PENSION
P6930	GEIH	Ocupados	Fondo al que cotiza en pensión	Categórico	1 = Fondo privado, 2 = Colpensiones, 3 = Régimen especial, 4 = Subsidiado, 9 = No sabe	Empleo	Formalidad asalariados	2.3	Validación institucional de pensión
P6940	GEIH	Ocupados	Quién paga la afiliación al fondo de pensiones	Categórico	1 = Persona y empresa, 2 = Persona paga todo, 3 = Empresa paga todo, 4 = No paga	Persona	Pago de pensión	2.3	Construcción de PENSION
P6765	GEIH	Ocupados	Forma de trabajo independiente en la semana pasada	Categórico	1 = Honorarios, 2 = Obra, 3 = Destajo, 4 = Comisión, 5 = Catálogo, 6 = Oficio, 7 = Negocio o finca, 8 = Otro	Empleo	Forma de trabajo	2.3	Bifurca el árbol de FORMAL
P3065	GEIH	Ocupados	¿El negocio tiene registro ante Cámara de Comercio?	Categórico	1 = Sí tiene, 2 = No tiene, 9 = No sabe	Empresa	Registro institucional	2.3	Clasifica formalidad en P6765 %in% c(4, 5, 6, 8, 9)
P3066	GEIH	Ocupados	Oficina de contabilidad o servicios de contador en la empresa	Categórico	1 = Sí, 2 = No, 9 = No sabe	Empresa	Organización contable	2.3	Árbol de FORMAL
P3067	GEIH	Ocupados	Registro del negocio ante Cámara de Comercio	Categórico	1 = Sí, 2 = No	Empresa	Registro mercantil	2.3	Árbol de FORMAL cuando P6765 = 7
P3067S1	GEIH	Ocupados	Renovación del registro mercantil	Categórico	1 = Sí, 2 = No	Empresa	Renovación del registro	2.3	Árbol de FORMAL

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
P3067S2	GEIH	Ocupados	Último año de renovación del registro	Numérico	Año de renovación	Empresa	Vigencia del registro	2.3	Comparado con ANIOS = ANIO - 1
P6775	GEIH	Ocupados	Contabilidad o libro de registro diario de operaciones	Categórico	1 = Sí, 2 = No, 3 = No aplica, 9 = No sabe	Empresa	Contabilidad	2.3	Árbol de FORMAL
P3068	GEIH	Ocupados	La contabilidad permite separar gastos del negocio y del hogar	Categórico	1 = Sí, 2 = No, 9 = No sabe	Empresa	Separación de gastos	2.3	Árbol de FORMAL
P3069	GEIH	Ocupados	Personas que trabajan en la empresa o negocio	Categórico	1 = Solo, 2 = 2–3, 3 = 4–5, 4 = 6–10, 5 = 11–19, 6 = 20–30, 7 = 31–50, 8 = 51–100, 9 = 101–200, 10 = 201 o más	Empresa	Tamaño de la unidad	2.3	Código >= 4 representa seis o más personas
OFICIO_C8	GEIH	Ocupados	Clasificación Internacional Uniforme de Ocupaciones (CIUO-08)	Categórico	Código ocupacional de 4 dígitos	Ocupación	Calificación profesional	2.3	Primeros dos dígitos del código

Tabla 3: Variables de la EMICRON 2024 (Numerales 1.4, 3 y 4.2)

Variables provenientes de los cuatro módulos de la Encuesta de Micronegocios:

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
DIRECTORIO	EMICRON	Identificación	Identificador de la edificación o vivienda	Carácter	Código alfanumérico DANE	Vivienda	Llave relacional	1.4, 3	Conversión a carácter
SECUENCIA_P	EMICRON	Identificación	Identificador del hogar en la vivienda	Carácter	Consecutivo numérico (1, 2, ...)	Hogar	Llave relacional	1.4, 3	Conversión a carácter
SECUENCIA_ENCUESTA	EMICRON	Identificación	Orden del propietario del micronegocio en el hogar	Carácter	Consecutivo numérico (1, 2, ...)	Persona	Llave relacional	1.4, 3	Equivale a ORDEN de la GEIH
P35	EMICRON	Identificación	Sexo del propietario	Categórico	1 = Hombre, 2 = Mujer	Persona	Caracterización y control	1.4, 3.1	Contrastado con

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
			del micronegocio						P3271 de la GEIH
P241	EMICRON	Identificación	Edad en años cumplidos del propietario	Numérico	Años cumplidos	Persona	Caracterización y control	1.4, 3.1	Contrastado con P6040 de la GEIH
MES_REF	EMICRON	Identificación	Mes de referencia de la entrevista EMICRON	Carácter	Nombre del mes en mayúsculas	Micronegocio	Control temporal	1.4	Desfase: $\text{MES_REF} = \text{MES}_{\text{GEIH}} + 1$
COD_DEPTO	EMICRON	Identificación	Código DANE del departamento	Categórico	Códigos DIVIPOLA de 2 dígitos	Departamento	Cobertura geográfica	1.4, 3	24 dominios: 23 departamentos y Bogotá D.C.
CLASE_TE	EMICRON	Identificación	Zona geográfica del micronegocio	Categórico	1 = Cabecera, 2 = Centros poblados y rural disperso	Zona	Control geográfico	1.4	Contrastado con CLASE de la GEIH
GRUPOS4	EMICRON	Identificación	Rama de actividad económica agregada a 4 ramas	Categórico	1 = Agricultura, 2 = Industria manufacturera, 3 = Comercio, 4 = Servicios	Micronegocio	Agrupador sectorial	3.2	Base del análisis de inclusión financiera
GRUPOS12	EMICRON	Identificación	Rama de actividad económica desagregada a 12 sectores	Categórico	Códigos 1 a 12 (y 13 = No informa, 4 registros)	Micronegocio	Distribución económica	3.1	Comparado contra boletín técnico DANE
F_EXP	EMICRON	Identificación	Factor de expansión anual de micronegocios	Numérico	Ponderador anual continuo	Micronegocio	Ponderador de unidades	3.1, 3.2, 3.3, 4.2	**Factor anual: no se divide entre 12**
P1633	EMICRON	Características	¿El micronegocio cuenta con Registro Único Tributario (RUT)?	Categórico	1 = Sí cuenta, 2 = No cuenta	Micronegocio	Formalidad tributaria	3.1, 3.3	Indicador de formalización tributaria
P1055	EMICRON	Características	¿Tiene registro mercantil ante Cámara de Comercio?	Categórico	1 = Sí tiene, 2 = No tiene	Micronegocio	Formalidad mercantil	3.1	Indicador de formalización mercantil
P1764_1	EMICRON	Inclusión financiera	Acepta pagos en efectivo	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Base del perfil "Solo efecti-

Variable	Encuesta	Módulo	Descripción	Tipo	Codificación	Unidad	Función	Apartado	Tratamiento
									vo" (exclusivo)
P1764_2	EMICRON	Inclusión financiera	Acepta pagos en cheque	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio bancario tradicional
P1764_3	EMICRON	Inclusión financiera	Acepta transferencias bancarias o por internet	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	No distingue proveedores o billeteras específicas
P1764_4	EMICRON	Inclusión financiera	Acepta factura a crédito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio comercial a plazo
P1764_5	EMICRON	Inclusión financiera	Acepta tarjeta débito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio de pago electrónico
P1764_6	EMICRON	Inclusión financiera	Acepta tarjeta de crédito	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Medio de pago electrónico
P1764_7	EMICRON	Inclusión financiera	Acepta otro medio de pago	Binario	1 = Sí acepta, 2 = No acepta	Micronegocio	Medio de pago	3.2, 4.2	Categoría residual de medios
P1765	EMICRON	Inclusión financiera	¿Solicitó un préstamo o crédito para el negocio en el año anterior?	Categórico	1 = Sí solicitó, 2 = No solicitó, NA = No informa (5.376 registros en total; 5.202 con ventas > 0)	Micronegocio	Solicitud de crédito	3.2, 4.2	Mide demanda revelada de crédito
P3014	EMICRON	Inclusión financiera	¿El micronegocio ahorró parte de sus ingresos?	Categórico	1 = Sí ahorró, 2 = No ahorró, NA = No informa	Micronegocio	Capacidad de ahorro	3.2	Ahorro declarado durante el año anterior
VENTAS_MES_ANTERIOR	EMICRON	Ventas o ingresos	Ventas o ingresos brutos del mes anterior a la entrevista	Numérico	Valor en pesos colombianos	Micronegocio	Escala productiva	4.2	Flujo de ingresos mensuales del negocio

Diferencia Conceptual entre `DPTO`, `AREA` y `CLASE`

En la GEIH, estas tres variables delimitan dimensiones geográficas distintas y no son intercambiables: 1. `DPTO`: Representa la división político-administrativa de primer nivel (23 departamentos y Bogotá D.C. en los archivos utilizados). Permite agregar información regional o departamental completa (cabeceras más zonas rurales). 2. `AREA`: Identifica dominios urbanos y metropolitanos específicos. En la GEIH, las 13 ciudades y áreas metropolitanas principales corresponden a los códigos `c(5, 8, 11, 13, 17, 23, 50, 52, 54, 66, 68, 73, 76)` (Medellín A.M., Barranquilla A.M., Bogotá D.C., Cartagena, Manizales A.M., Montería, Villavicencio, Pasto, Cúcuta A.M., Pereira A.M., Bucaramanga A.M., Ibagué y Cali A.M.). No cubre áreas rurales. 3. `CLASE`: Diferencia la morfología

del asentamiento humano dentro de un municipio: `1 = Cabecera municipal` (casco urbano consolidado) y `2 = Centros poblados y rural disperso`. Permite el análisis urbano-rural.

Numeral 1.4: Integración Relacional de EMICRON y GEIH 2024 (`base_micro`)

Selección Muestral y Asimetría de Inclusión

La Encuesta de Micronegocios (EMICRON) no es una muestra aleatoria independiente tomada de un censo de empresas. Es una submuestra derivada de la GEIH: - **Población elegible:** En la muestra mensual de la GEIH, el DANE identifica a los ocupados cuya posición ocupacional (`P6430`) corresponde a trabajadores por cuenta propia (4) o patrones/empleadores (5) en unidades económicas de hasta 9 personas ocupadas. - **Relación asimétrica:** Todo registro de la EMICRON proviene forzosamente de un hogar encuestado por la GEIH. Por el contrario, solo una fracción de la muestra de la GEIH califica para la EMICRON. Entender esta relación de inclusión es indispensable: el pegue correcto debe realizarse sobre la base de la EMICRON como tabla izquierda (`left_join`), preservando sus 78.501 registros sin pérdida ni multiplicación.

Cobertura Geográfica Diferencial

Existe una divergencia geográfica estructural entre ambas operaciones estadísticas: - La GEIH tiene cobertura nacional; los archivos usados contienen 24 dominios departamentales (23 departamentos y Bogotá D.C.). Esta cobertura observada no equivale a enumerar todo el marco geográfico de la operación. - La EMICRON excluye explícitamente de su diseño muestral a los ocho departamentos de la Amazonía y Orinoquía: Amazonas, Arauca, Casanare, Guainía, Guaviare, Putumayo, Vaupés y Vichada (documentado en la ficha metodológica y catálogo 875 de microdatos de ANDA/DANE).

Metodología de Ponderación: `FEX_C18` vs. `F_EXP`

Uno de los errores más graves en econometría aplicada es intercambiar o combinar factores de expansión con universos y períodos disímiles: - `FEX_C18` (Factor de la GEIH): Ponderador probabilístico de personas calibrado mensualmente contra proyecciones de población nacional. Si se combinan varios meses para estimar poblaciones promedio, el factor debe dividirse entre el número de meses analizados (ej. FEX_C18 /3 para estimaciones trimestrales y FEX_C18 /12 para estimaciones anuales). - `F_EXP` (Factor de la EMICRON): Ponderador probabilístico anual de micronegocios. Cada registro expandido representa el número total de unidades económicas existentes en el país durante el año calendario 2024. **Bajo ninguna circunstancia debe dividirse entre 12 ni entre el número de meses**, pues subestimaría el universo de micronegocios en un factor de 12. Tampoco puede combinarse con `FEX_C18` en una misma fórmula para personas y micronegocios simultáneamente.

Determinación Empírica de la Llave: `SECUENCIA_ENCUESTA` vs. `ORDEN`

En los microdatos de la EMICRON no se publica la variable `ORDEN`, sino `SECUENCIA_ENCUESTA`. Al examinar empíricamente su distribución en los 78.501 registros de EMICRON (`1_4_relacion_orden.csv` y los controles del numeral 1.4.c), se comprueba que: - El 94,95 % de los registros toma valores entre `1` y `3`; el máximo es `16`. Hay hogares con uno a seis propietarios. La secuencia identifica la persona del hogar, no un consecutivo exclusivo de propietarios. - En el 100 % de los casos emparejados con la GEIH, el valor de `SECUENCIA_ENCUESTA` coincide unívocamente con el valor de `ORDEN` de la persona propietaria del micronegocio. Por lo tanto, la llave de persona para unir EMICRON con GEIH es `DIRECTORIO + SECUENCIA_P + SECUENCIA_ENCUESTA` (empatada con `ORDEN`).

Desfase Temporal y Período de Referencia

Al contrastar `MES_REF` (EMICRON) con `MES` (GEIH) sobre las observaciones enlazadas, se evaluaron tres hipótesis formales (`1_4_relacion_meses.csv`): 1. **Mismo mes ($\mathbf{MES_REF = MES_{GEIH}}$):** 0 % de correspondencia. 2. **Un mes atrás ($\mathbf{MES_REF = MES_{GEIH} - 1}$):** 0 % de correspondencia. 3. **Un mes adelante**

($\mathbf{MES_REF = MES_{GEIH} + 1}$): 100 % de correspondencia (78.501 de 78.501 casos, contrastando con GEIH 2023 y 2024).

Este desfase responde al operativo de campo: la entrevista de EMICRON se aplica el mes siguiente a la visita de la GEIH. Debido a este desfase, el mes jamás debe incorporarse dentro de la llave de unión, pues destruiría el emparejamiento.

Auditoría del Enlace y Explicación de los Registros No Emparejados

Al realizar el `left_join` de EMICRON 2024 con GEIH 2024: - De los 78.501 micronegocios, 71.754 (91,41 %) enlazan con la GEIH 2024 (`base_micro`). - Los 6.747 registros sin enlace (8,59 %) corresponden en su totalidad al mes de referencia `ENERO` de 2024 (`1_4_auditoria_mensual.csv`). - **Causa estructural:** Dado el desfase de recolección de un mes, los informantes de enero de 2024 de EMICRON fueron encuestados en la GEIH en diciembre de 2023. Al cruzar estos 6.747 registros con diciembre de 2023 de la GEIH (`1_4_fuera_2024.csv`), se encuentra al 100 % de ellos (6.747 de 6.747). Quedan fuera de `base_micro` por diseño temporal del ejercicio (que restringe el pegue a 2024) y no por un error en la llave de enlace.

Validación de la Calidad del Enlace

Para verificar que el pegue unió a la persona correcta, se contrastaron variables sociodemográficas medidas de forma independiente en ambas encuestas (`1_4_validacion_pegue.csv`): - Coincidencia en sexo (`P35` vs. `P3271`): 100,0 %. - Coincidencia en edad (`P241` vs. `P6040`): 100,0 %. - Coincidencia en zona geográfica (`CLASE_TE` vs. `CLASE`): 100,0 %.

Interpretación de la Posición Ocupacional en 1.4.g

El 88,53 % de los propietarios enlazados declaró trabajo por cuenta propia y el 9,22 % ser patrón o empleador (97,75 % en conjunto). El 2,25 % restante incluye empleados particulares (1,54 %) y trabajadores sin remuneración en empresas de otros hogares (0,33 %). Podrían intervenir cambios ocupacionales, actividades secundarias o imprecisiones de reporte; el cruce no permite distinguir estas hipótesis. La identificación como propietario en EMICRON y la posición del empleo principal en GEIH describen aspectos distintos de la actividad económica. Los conteos muestrales son 64.479 por cuenta propia y 6.019 patrones; los porcentajes usan `F_EXP`.

Principales Indicadores de Mercado Laboral (Punto 2)

Numeral 2.1: Tasas y Poblaciones (2023-2024)

Los indicadores macroeconómicos del mercado laboral se construyen expandiendo las observaciones muestrales con `FEX_C18 / 3` para obtener los promedios trimestrales oficiales:

$$\text{Tasa Global de Participación (TGP)} = \frac{\text{Fuerza de Trabajo}}{\text{Población en Edad de Trabajar (PET)}} \times 100$$

$$\text{Tasa de Ocupación (TO)} = \frac{\text{Ocupados}}{\text{Población en Edad de Trabajar (PET)}} \times 100$$

$$\text{Tasa de Desempleo (TD)} = \frac{\text{Desocupados}}{\text{Fuerza de Trabajo}} \times 100$$

El script genera y exporta las tablas `2_1_tasas_hombres.xlsx` y `2_1_tasas_mujeres.xlsx`, comprobando en cada trimestre que $\text{FT} = \text{Ocupados} + \text{Desocupados}$ (`2_1_consistencia_tasas.csv`).

Numeral 2.2: Descomposición del Desempleo y Brechas de Género

El gráfico `2_2_tasas_sexo.png` presenta paneles por tasa y distingue ambos sexos en los ocho trimestres de 2023 y 2024:

- En participación, la TGP de los hombres oscila entre 76,27 % y 76,84 %, frente a 52,02 % a 53,07 % en las mujeres. La brecha trimestral va de 23,64 a 24,37 puntos porcentuales. En ocupación, la TO masculina varía entre 68,97 % y 70,96 %, y la femenina entre 44,23 % y 46,88 %; la brecha es de 24,08 a 25,22 puntos.
- La TD femenina varía entre 11,15 % y 15,09 %, frente a 7,06 % a 9,57 % en hombres. La diferencia desfavorable para las mujeres se sitúa entre 3,84 y 5,91 puntos porcentuales.
- Entre julio-septiembre y octubre-diciembre de 2024, la TD cae de 7,67 % a 7,06 % en hombres y de 12,12 % a 11,15 % en mujeres. La TO aumenta de 70,51 % a 70,92 % y de 46,30 % a 46,79 %, respectivamente, mientras la TGP disminuye ligeramente (76,37 % a 76,30 % y 52,69 % a 52,66 %). La caída del desempleo coincide con una mayor ocupación relativa a la PET y una menor participación: $\mathrm{TD} = 100(1 - \mathrm{TO} \,/\, \mathrm{TGP})$. La serie no identifica causas sectoriales ni permite establecer un patrón estacional.

Numeral 2.3: Informalidad Laboral en 13 Ciudades (Diciembre 2024)

Adaptación y validación de la clasificación del DANE (`Código_SAS`)

Se adapta la sintaxis oficial en SAS del DANE (`Código_SAS` del anexo `anex-GEIHEISS-oct-dic2024.xlsx`) para obtener `EI = 1` en empleo formal y `EI = 0` en informal. Se construyen `FORMAL`, `SALUD` y `PENSION` antes de `EI`. El contraste independiente coincide en `EI` para los 353.672 ocupados de 2024. `FORMAL` difiere en 11.911 empleados domésticos (0 en R y faltante en SAS), sin cambiar la clasificación final. Las variables de negocio describen forma de trabajo, registro y renovación, contabilidad, separación de gastos, tamaño y oficio.

En el código, `SALUD` y `PENSION` se calculan para `P6430 %in% c(1, 3, 7)`; `EI` asigna 1 a empleados del gobierno, 0 a las posiciones 6 y 8, `FORMAL` a cuenta propia y patrones, y combina salud y pensión para las posiciones 1, 3 y 7. Esta descripción corresponde al código que se expondrá; la coincidencia final comprobada no implica identidad de todos los pasos intermedios.

Al replicar el cálculo para el trimestre octubre–diciembre de 2024 en las 13 ciudades y áreas metropolitanas, la proporción de ocupados informales es de **42,5 %**, mostrando una diferencia de **0,0 puntos porcentuales** frente al boletín oficial del DANE (`2_3_control_ei_dane.csv`). En el mes de diciembre de 2024 (`2_3_formalidad_13ciudades.png` y `2_3_tabla_formalidad_13ciudades.csv`), la informalidad en las 13 ciudades fue de **42,2 %** en hombres (57,8 % formal) y **42,3 %** en mujeres (57,7 % formal).

Numeral 2.4: Posición Ocupacional Nacional (Enero 2023)

El gráfico `2_4_posicion_nacional.png` presenta la distribución de los ocupados según posición ocupacional y sexo para enero de 2023: - Los trabajadores por cuenta propia concentran el **40,6 %** del empleo nacional y los patrones o empleadores el **2,6 %**, sumando en conjunto el **43,2 %** de la población ocupada del país (alrededor de 9,3 millones de personas). - **Relevancia metodológica:** De estas posiciones provienen los propietarios potenciales de EMICRON, sujetos también al criterio de unidades de hasta nueve personas ocupadas.

Caracterización de los Micronegocios en Colombia (Punto 3)

Numeral 3.1: Indicadores Estructurales y Comparación con el Boletín DANE (EMICRON 2024)

Los porcentajes de `3_1_indicadores.xlsx` se calcularon directamente con la suma de `F_EXP` **antes de redondear los totales expandidos** (`TOTAL_SIN_REDONDEAR = sum(F_EXP, na.rm = TRUE)`): - **Total nacional:** 5.297.252 micronegocios (coincidencia exacta con el boletín técnico del DANE). - **Composición por sexo (`P35`):** 64,6 %

liderados por hombres (3.421.325) y 35,4 % por mujeres (1.875.927). - **Ramas de actividad (`GRUPOS12`):** Comercio y reparación de vehículos (23,9 %; 1.263.754) y agricultura, ganadería, caza, silvicultura y pesca (21,5 %; 1.138.758) concentran el 45,4 % del total, seguidas por industrias manufactureras (10,0 %; 531.988) y alojamiento y servicios de comida (8,3 %; 440.223). Se documentan 4 registros con código `GRUPOS12 == 13` (*No informa*, 82 micronegocios expandidos, 0,0 %). - **Registro Único Tributario (`P1633`):** El 22,4 % cuenta con RUT (1.185.978) y el 77,6 % no cuenta con RUT (4.111.274), coincidiendo con el Gráfico 11 del boletín DANE. - **Cámara de Comercio (`P1055`) y explicación de la discrepancia de —0, 2 pp:** - Nuestro cálculo sobre los microdatos arroja **10,3 %** con registro mercantil (`P1055 == 1`) y **89,7 %** sin registro (`P1055 == 2`). - El **Gráfico 9** del Boletín Técnico EMICRON 2024 publica **10,5 %** con registro y **89,5 %** sin registro, lo que representa una diferencia de **—0, 2 puntos porcentuales** (`+0,2` pp en no registrados). - Al contrastar la **Tabla 8** del mismo boletín oficial del DANE, se verifica que las cantidades absolutas publicadas por el DANE son **547.581** micronegocios con registro mercantil y **4.749.671** sin registro sobre un total de **5.297.252**; su cociente exacto es $\frac{547.580,7}{5.297.252,1} = 10,337$ % (**10,3 %** a un decimal), lo que demuestra que los microdatos coinciden exactamente con la Tabla 8 del boletín (`3_1_indicadores.xlsx` y objeto `verificacion_3_1_dane`).

Numeral 3.2: Inclusión Financiera de Micronegocios

El módulo de inclusión financiera evalúa siete medios de pago mediante un ciclo agrupado por `GRUPOS4` y ponderado con `F_EXP`.

El efectivo se acepta en el 99,0 % de los micronegocios agropecuarios y de comercio, el 98,0 % de industria y el 95,7 % de servicios. Las transferencias bancarias o por internet alcanzan 6,7 %, 39,0 %, 43,4 % y 51,9 %, respectivamente. Los porcentajes son ponderados con `F_EXP` dentro de cada rama y las opciones son multirrespuesta. Entre micronegocios con rama clasificada y respuesta válida a cada pregunta, el 14,2 % solicitó crédito o préstamo y el 18,1 % ahorró dinero del negocio durante el año anterior. La solicitud no demuestra aprobación ni distingue crédito formal de otras fuentes.

Numeral 3.3: Cruce Conjunto GEIH - EMICRON con Categorías Explícitas del DANE

- **Pregunta de investigación:** *¿Se asocia el nivel educativo alcanzado por el propietario del micronegocio (GEIH: `P3042`) con la tenencia de RUT en la unidad económica (EMICRON: `P1633`)?*
- **Universo y ponderador:** 71.754 propietarios emparejados entre febrero y diciembre de 2024, expandidos exclusivamente con `F_EXP` (4.864.444 micronegocios).
- **Clasificación explícita del diccionario GEIH 2024 (`P3042`):** Se clasifican por separado los códigos `1` a `13` y `99`. La auditoría comprueba que el 100 % de los 71.754 propietarios emparejados tiene niveles conocidos en `1:13` (`0` en `99 = No sabe, no informa`, `0` en `NA` y `0` códigos inválidos; `0` faltantes en `P1633`).
- **Hallazgos (`3_3_cruce.png` y `3_3_tabla_educacion_rut.csv`):**
  - La tenencia de RUT muestra una asociación positiva general con la educación, sin aumentar en todas las categorías sucesivas: **0,0 %** en *Preescolar* ($n = 6$), **2,8 %** en *Ninguno*, **11,7 %** en *Básica primaria (1o - 5o)*, **13,1 %** en *Normalista*, **14,5 %** en *Básica secundaria (6o - 9o)*, **22,3 %** en *Media académica* y **26,8 %** en *Media técnica*.
  - En educación superior y posgrado la formalización se acelera: **34,0 %** en *Técnica profesional*, **43,9 %** en *Tecnológica*, **51,7 %** en *Universitaria*, **73,2 %** en *Especialización*, **78,7 %** en *Maestría* y **88,8 %** en *Doctorado*.
- **Hipótesis no causales:** La escala del negocio y su rama podrían relacionarse con educación y registro tributario. El cruce no prueba esos mecanismos ni controla por capital inicial, ventas o sector.

Análisis Socioeconómico de la Población Colombiana (Punto 4)

Numeral 4.1: Geografía de la Informalidad Laboral

El gráfico `4_1_geografia_informalidad.png` relaciona tasas ponderadas de informalidad (`FEX_C18 / 12`) con medianas muestrales sin ponderar de ingresos positivos. Bogotá registra 34,6 % y $1,5 millones; Cundinamarca, 42,8 % y $1,3 millones; Antioquia, 48,1 % y $1,4 millones. Chocó registra 79,2 % y $1,2 millones; Sucre, 82,1 % y $800.000; La Guajira, 79,4 % y $800.000. La comparación describe diferencias territoriales y no identifica sus causas.

Numeral 4.2: Inclusión Digital, Solicitud de Crédito y Escala de Ventas

El gráfico `4_2_inclusion_ventas_micro.png` evalúa las ventas brutas mensuales (`VENTAS_MES_ANTERIOR > 0`) cruzando el perfil de medios de pago (**Transferencias bancarias / internet** con `P1764_3 == 1` frente a **Solo efectivo** definido como efectivo exclusivo `P1764_1 == 1` sin otros medios seleccionados en `P1764_2:7`) con la **solicitud de crédito** (`P1765`: `1 = Solicitó crédito`, `2 = No solicitó crédito`): - **Auditoría de no respuesta y exclusiones:** De los 75.671 micronegocios con ventas positivas, se contabilizan y documentan **5.202 registros sin respuesta (`NA`) en `P1765`** (338.120 expandidos; 5.376 en toda la EMICRON) y **645 registros en otros perfiles de pago** (23 de ellos también con `NA` en `P1765`), analizando **69.847 unidades válidas** (4.711.543 expandidas). - **Resultados (`4_2_tabla_inclusion_ventas.csv`):** Las medianas siguientes son muestrales, sin ponderar. El gráfico pondera densidades y cajas con `F_EXP`; la escala logarítmica y el zoom entre $0,1 y $100 millones no excluyen registros del cálculo. La asociación no demuestra efectos del medio de pago o del crédito sobre las ventas. - En **Solo efectivo**, la mediana de ventas mensuales pasa de **$1,20 millones** sin solicitud de crédito ($n = 37.700$) a **$1,70 millones** con solicitud de crédito ($n = 5.804$). - En **Transferencias bancarias / internet**, la mediana sube a **$2,30 millones** sin solicitud de crédito ($n = 21.061$) y alcanza **$3,00 millones** con solicitud de crédito ($n = 5.282$).

Numeral 4.3: Emparejamiento Laboral entre Nivel Educativo y Posición Ocupacional

El gráfico `4_3_mismatch_educacion.png` cruza las **13 categorías educativas explícitas del DANE** (`P3042`: `1` a `13`) con las **9 posiciones ocupacionales** (`P6430`: `1` a `9`) sobre 353.668 ocupados de la GEIH 2024; el gráfico muestra frecuencias muestrales y la tabla porcentajes ponderados con `FEX_C18 / 12` (excluyendo y documentando los únicos 4 registros con `P3042 == 99`, equivalentes a 473 ocupados expandidos): - En *Ninguno* (62,5 %), *Básica primaria* (54,8 %) y *Básica secundaria* (48,6 %) predomina el trabajo por cuenta propia. - A partir de *Media académica* (47,8 % obrero particular vs. 39,9 % cuenta propia) y *Media técnica* (57,8 % vs. 32,7 %), y en toda la educación superior (*Técnica profesional* 61,5 %, *Tecnológica* 66,6 %, *Universitaria* 62,1 %) y posgrado (*Especialización* 58,4 %, *Maestría* 55,6 %, *Doctorado* 56,5 %), predomina el empleo asalariado particular junto con una participación creciente del empleo en el gobierno (hasta 28,2 % en *Doctorado*). - Sin embargo, se identifican **986.256 ocupados con educación superior o posgrado** (`P3042 %in% 8:13`) trabajando por cuenta propia (incluyendo 454.991 universitarios y 360.875 técnicos profesionales); estos datos no permiten establecer sobreeducación ni las razones para trabajar por cuenta propia. Para ello se necesitarían los requisitos educativos del puesto y evidencia adicional.

Banco de Preguntas y Argumentación para la Sustentación Oral (Punto 5)

Este banco organiza las preguntas de defensa individual directamente por los cuatro numerales del taller, vinculando las respuestas con los numerales del script oficial y a la evidencia empírica.

Bloque 1: Defensa del Punto 1 (Conformación de Bases y Enlace Relacional)

Pregunta 1.1: ¿Por qué la llave relacional de la GEIH exige tres variables y qué riesgo existe al omitir una?
Respuesta: La GEIH maneja una estructura anidada donde `DIRECTORIO` identifica la vivienda, `SECUENCIA_P` el hogar y `ORDEN` la persona. Si se omitiera `SECUENCIA_P`, en viviendas multifamiliares con más de un hogar se emparejarían personas distintas que comparten el mismo número de orden (ej. el hijo del hogar 1 con el del hogar 2), generando una multiplicación espuria de registros y corrompiendo la representatividad muestral.

Pregunta 1.2: ¿Por qué se utilizó `contador <- 1` en el bucle 1.1 en lugar de `append()`?
Respuesta: El contador organiza las 24 auditorías mensuales en posiciones consecutivas de las listas. El índice local `i` recorre los doce meses de cada año y `contador` continúa de 1 a 24. Los resultados se consolidan con `bind_rows()` al finalizar. Como las listas se inicializan vacías, no se trata de una preasignación de memoria; tampoco se midió el rendimiento frente a `append()`.

Pregunta 1.3: ¿Por qué 6.747 micronegocios de EMICRON 2024 no emparejan con la GEIH de 2024?
Respuesta: Por el desfase de recolección temporal ($\text{MES_REF} = \text{MES}_{\text{GEIH}} + 1$). En consecuencia, los informantes encuestados en enero de 2024 en EMICRON fueron entrevistados por la GEIH en diciembre de 2023. Al cruzar esos 6.747 registros contra diciembre de 2023 de la GEIH (`1_4_fuera_2024.csv`), se encuentra al 100 % de ellos. No es un error de llave, sino un límite temporal del ejercicio al restringir la base a 2024.

Pregunta 1.4: ¿Por qué no se puede usar indistintamente `FEX_C18` y `F_EXP`?
Respuesta: Porque representan universos y períodos distintos. `FEX_C18` expande personas de la GEIH y está calibrado mensualmente; para calcular trimestres debe dividirse entre 3 y para años entre 12. `F_EXP` expande unidades productivas de micronegocios en EMICRON y es un ponderador anual calibrado para todo 2024. Si se dividiera `F_EXP` entre 12, se subestimaría el universo microempresarial a la doceava parte. Mezclarlos en un mismo cálculo destruye la validez de la inferencia.

Bloque 2: Defensa del Punto 2 (Indicadores Laborales y Formalidad DANE)

Pregunta 2.1: ¿Por qué para las tasas trimestrales del punto 2.1 se divide `FEX_C18` entre 3?
Respuesta: Porque `FEX_C18` es un factor mensual. Al apilar los tres meses de un trimestre (ej. enero, febrero y marzo), la suma simple del factor triplicaría la población real de Colombia. Dividir entre 3 calcula la población promedio del trimestre, que es el estándar metodológico oficial del DANE para estimar poblaciones y tasas del mercado de trabajo.

Pregunta 2.2: ¿Cómo se construyó la clasificación de formalidad laboral (`EI`) en el punto 2.3?
Respuesta: Se adapta la sintaxis oficial en SAS del DANE (`Código_SAS` del anexo `anex-GEIHEISS-oct-dic2024.xlsx`) para obtener `EI = 1` en empleo formal y `EI = 0` en informal. Se construyen `FORMAL`, `SALUD` y `PENSION` antes de `EI`. El contraste independiente coincide en `EI` para los 353.672 ocupados de 2024. `FORMAL` difiere en 11.911 empleados domésticos (0 en R y faltante en SAS), sin cambiar la clasificación final. Las variables de negocio describen forma de trabajo, registro y renovación, contabilidad, separación de gastos, tamaño y oficio. La informalidad en las 13 ciudades durante octubre–diciembre de 2024 es 42,5 %, coincidente a un decimal con el anexo oficial.

Pregunta 2.3: ¿Cómo se interpreta que baje la tasa de desempleo pero caiga la tasa de ocupación?
Respuesta: La identidad `TD = 100(1 - TO/TGP)` permite que TD disminuya aunque baje TO, si la participación cae proporcionalmente más y aumenta la razón TO/TGP. Esto no demuestra desaliento laboral: las tasas agre-

gadas no identifican por qué una persona sale de la fuerza de trabajo. En el último trimestre de 2024 observado aquí, TO aumenta y TGP baja ligeramente para ambos sexos.

Bloque 3: Defensa del Punto 3 (Micronegocios e Inclusión Financiera)

Pregunta 3.1: ¿Por qué en Cámara de Comercio (`P1055 == 1`) el cálculo da 10,3 % mientras el Gráfico 9 del boletín DANE muestra 10,5 %?

Respuesta: Los totales publicados en la Tabla 8 son 547.581 registrados sobre 5.297.252 micronegocios: 10,337 %, o 10,3 % a un decimal. El Gráfico 9 presenta 10,5 %. Los microdatos coinciden con la Tabla 8; la diferencia de −0,2 puntos con el gráfico no se explica por redondear. No se identificó documentalmente la causa de esa discrepancia.

Pregunta 3.2: ¿Por qué la mayor aceptación de transferencias (`P1764_3`) en comercio y servicios no se traduce en una alta solicitud de crédito (`P1765`)?

Respuesta: La aceptación de transferencias y la solicitud de crédito miden decisiones distintas. El 14,2 % solicitó un préstamo o crédito durante el año anterior, pero `P1765` no indica aprobación ni distingue fuentes formales. La necesidad de financiamiento y las condiciones de acceso podrían influir; esos mecanismos no se comprueban con los porcentajes por rama.

Pregunta 3.3: ¿Cómo se trataron las categorías de `P3042` en el cruce 3.3 y por qué la relación con el RUT no es causal?

Respuesta: Se utilizaron las 13 categorías conocidas de `P3042` y se auditaron 99, faltantes y códigos inválidos. Los 71.754 propietarios tienen educación conocida. La proporción con RUT es 51,7 % en universitaria y 88,8 % en doctorado; el patrón general no aumenta en cada categoría sucesiva. La escala y la rama del negocio son posibles explicaciones, sin que este cruce demuestre causalidad ni mediación.

Bloque 4: Defensa del Punto 4 (Análisis Socioeconómico y Rigor Gráfico)

Pregunta 4.1: ¿Qué correcciones metodológicas se aplicaron en el análisis de inclusión financiera y ventas (4.2) y en el cruce educativo-ocupacional (4.3)?

Respuesta: En 4.2 se identificaron las transferencias bancarias o por internet con `P1764_3 == 1` (ya que `P1764_2` es cheque), se definió *Solo efectivo* como efectivo exclusivo (`P1764_1 == 1` sin ningún otro medio seleccionado entre `P1764_2` y `P1764_7`), y se trató `P1765` como solicitud de crédito (`1 = Solicitó`, `2 = No solicitó`), auditando y documentando los 5.202 registros con `NA` en `P1765` y los 645 de otros medios antes de graficar los 69.847 registros válidos. En 4.3 se utilizaron las 13 categorías explícitas de `P3042` (`1:13`, excluyendo y documentando los 4 registros con código `99`) frente a las 9 posiciones ocupacionales de `P6430`, identificando 986.256 ocupados con educación superior o posgrado en trabajo por cuenta propia.

Pregunta 4.2: ¿Qué criterios garantizan que todos los gráficos del taller estén completamente documentados y sean autocontenidos?

Respuesta: Tanto en el script como en el cuaderno pedagógico, cada gráfico está documentado detallando datos y ponderador (`FEX_C18 / 3`, `FEX_C18 / 12` o `F_EXP`), mapeos estéticos (`aes`), capas geométricas (`geom_*`), ajustes de posición (`position_dodge`, `position_stack`), escalas (`scale_*`), sistema de coordenadas (`coord_flip`), facetas (`facet_wrap`), paleta de colores, etiquetas (`labs` con título, subtítulo, ejes, leyenda y fuente con universo y exclusiones), tema (`theme_bw` y `theme`) y parámetros de exportación (`ggsave` a 300 DPI).