Taller 2: mercado laboral y micronegocios en Colombia

Informe explicativo del script del Grupo 10

Taller de programación en R · Universidad de los Andes · 2026-02

Borrador para revisión del grupo. Los resultados del numeral 2.3 y el punto 4 requieren trabajo adicional antes de la entrega.

1. Conformación y unión de las bases

1.1. GEIH: construcción y controles

La Gran Encuesta Integrada de Hogares (GEIH) permite estudiar la población y el mercado laboral. El script recorre los doce meses de 2023 y 2024 mediante dos ciclos anidados. En cada mes lee los módulos de características generales, fuerza de trabajo, ocupados y no ocupados; conserva las variables requeridas; une los módulos por `DIRECTORIO`, `SECUENCIA_P` y `ORDEN`; y apila las bases mensuales para formar cada año. `DIRECTORIO` identifica la unidad entrevistada, `SECUENCIA_P` el hogar dentro de ella y `ORDEN` a la persona. El módulo general es la base del `left_join` porque contiene el universo más amplio de personas encuestadas [1].

El procedimiento comprueba que la llave de persona no esté duplicada en ningún módulo y que cada unión conserve las filas de características generales. Los archivos de control registran cero duplicados y ningún aumento de filas en los 24 meses. Para limitar memoria, el script selecciona columnas antes de unir, almacena cada mes en una lista y retira objetos intermedios; el archivo de eficiencia documenta la reducción de variables.

1.2. Tamaño y estructura de GEIH 2024

Tabla 1. Registros muestrales por módulo, GEIH 2024. El total anual suma registros mensuales; no representa personas únicas a lo largo del año.

Mes	General	Fuerza	Ocupados	No ocupados
Enero	70.648	55.738	28.815	26.923
Febrero	72.148	56.856	29.943	26.913
Marzo	70.719	56.063	29.638	26.425
Abril	70.457	55.696	29.741	25.955
Mayo	70.188	55.773	30.142	25.631
Junio	70.020	55.530	29.925	25.605
Julio	69.694	55.038	29.929	25.109
Agosto	69.390	54.844	29.951	24.893
Septiembre	68.341	54.228	29.383	24.845
Octubre	67.216	53.631	29.127	24.504
Noviembre	66.235	52.679	28.924	23.755
Diciembre	64.627	51.727	28.154	23.573
TOTAL_2024	829.683	657.803	353.672	304.131

En 2024, características generales contiene 829.683 registros, frente a 657.803 de población en edad de trabajar (PET). Los módulos de ocupados (353.672) y no ocupados (304.131) particionan la PET: su suma es 657.803. El script comprueba además, mes a mes, las identidades PET = fuerza de trabajo + población fuera de la fuerza de trabajo y fuerza de trabajo = ocupados + desocupados [1].

1.3. Base analítica y diccionario

El script retiene las variables de identificación, demografía, territorio, mercado laboral y expansión solicitadas; añade las necesarias para formalidad y deriva `ANIO` de `PERIODO`. La selección temprana reduce el ancho de las bases y facilita verificar su contenido. `DPTO` identifica el departamento; `AREA`, el dominio de ciudad o área metropolitana; `CLASE`, la clase geográfica. Miden dimensiones diferentes y no son intercambiables.

Tabla 2. Diccionario de variables exigidas en 1.3(a–d), elaborado a partir del archivo exportado por el script. Las categorías resumidas deben cotejarse con el diccionario oficial antes de entregar [1].

Variable	Módulo	Descripción	Categoría / unidad

1.4. Integración GEIH–EMICRON

La Encuesta de Micronegocios (EMICRON) parte de una submuestra de ocupados elegibles de la GEIH, pero es una operación independiente. Sus cuatro módulos se unen internamente por `DIRECTORIO`, `SECUENCIA_P` y `SECUENCIA_ENCUESTA`. El script verifica que los cuatro carezcan de llaves duplicadas y que la unión preserve los 78.501 registros de identificación. `F_EXP` expande micronegocios; `FEX_C18` expande personas de la GEIH. Sus universos y diseños no permiten sustituirlos entre sí [1, 2].

La comparación empírica muestra una coincidencia única entre `SECUENCIA_ENCUESTA` y `ORDEN` para los 78.501 registros de EMICRON. Por eso el script construye `ORDEN` a partir de la primera y enlaza personas con las tres variables de identificación, sin añadir el mes a la llave. En los registros comparables, `MES_REF` de EMICRON aparece un mes después de `MES` de GEIH en el 100 % de los casos; no se observan coincidencias en el mismo mes ni un mes atrás. Esto es coherente con que las preguntas sobre actividad e ingresos se refieran al período anterior [2].

Tabla 3. Auditoría mensual del enlace con GEIH 2024.

Mes ref.	EMICRON	Enlazados	Sin enlace	Enlace (%)
ENERO	6.747	0	6.747	0
FEBRERO	6.337	6.337	0	100
MARZO	6.756	6.756	0	100
ABRIL	6.571	6.571	0	100
MAYO	6.604	6.604	0	100
JUNIO	6.544	6.544	0	100
JULIO	6.459	6.459	0	100
AGOSTO	6.661	6.661	0	100
SEPTIEMBRE	6.690	6.690	0	100
OCTUBRE	6.572	6.572	0	100
NOVIEMBRE	6.201	6.201	0	100
DICIEMBRE	6.359	6.359	0	100

La base `base_micro` conserva los 78.501 registros de EMICRON; 71.754 (91,41 %) encuentran contraparte en GEIH 2024. Sexo, edad y clase geográfica coinciden en el 100 % de los enlazados. Los 6.747 no enlazados son exactamente los registros de referencia enero: todos aparecen en GEIH diciembre de 2023, fuera de la ventana GEIH 2024 usada en el pegue. Esta concentración temporal explica la falta de enlace sin alterar ni descartar observaciones.

Entre los propietarios enlazados, 88,53 % declararon en GEIH trabajar por cuenta propia y 9,22 % ser patrones; el 2,25 % restante declaró otras posiciones. La diferencia recuerda que EMICRON identifica la propiedad de un micronegocio y GEIH registra la posición ocupacional declarada en el empleo de referencia. No debe interpretarse automáticamente como un error de llave, dada la validación independiente del enlace.

2. Indicadores de mercado laboral

2.1. Poblaciones y tasas trimestrales

El script divide `FEX_C18` entre tres al combinar meses para obtener una población trimestral promedio. Calcula TGP = fuerza de trabajo / PET, TO = ocupados / PET y TD = desocupados / fuerza de trabajo. En todos los grupos de año, trimestre y sexo, la verificación exportada confirma fuerza de trabajo = ocupados + desocupados, con diferencia cero. Las siguientes tablas incluyen las ocho columnas temporales de los archivos Excel solicitados; las poblaciones están expresadas en personas [1].

Tabla 4. Tasas y poblaciones de hombres, total nacional.

Indicador	E-M 23	A-J 23	J-S 23	O-D 23	E-M 24	A-J 24	J-S 24	O-D 24
TGP (%)	76,50	76,74	76,84	76,49	76,27	76,56	76,37	76,30
TO (%)	69,48	70,50	70,96	70,53	68,97	69,88	70,51	70,92
TD (%)	9,18	8,14	7,66	7,78	9,57	8,72	7,67	7,06
Población	24.748.804	24.810.197	24.869.525	24.930.631	24.990.309	25.049.813	25.107.634	25.167.164
PET	18.881.919	18.946.514	19.011.565	19.080.726	19.149.619	19.218.233	19.283.702	19.349.487
Fuerza laboral	14.444.388	14.540.454	14.609.435	14.594.473	14.604.582	14.712.896	14.726.116	14.764.021
Ocupados	13.118.794	13.357.249	13.490.093	13.458.585	13.207.089	13.429.720	13.597.066	13.722.209
Desocupados	1.325.594	1.183.205	1.119.342	1.135.888	1.397.493	1.283.176	1.129.050	1.041.812

Tabla 5. Tasas y poblaciones de mujeres, total nacional.

Indicador	E-M 23	A-J 23	J-S 23	O-D 23	E-M 24	A-J 24	J-S 24	O-D 24
TGP (%)	52,13	52,75	53,07	52,44	52,02	52,27	52,69	52,66
TO (%)	44,26	45,93	46,88	46,35	44,23	45,64	46,30	46,79
TD (%)	15,09	12,92	11,65	11,62	14,98	12,68	12,12	11,15
Población	26.080.284	26.152.845	26.223.382	26.295.834	26.366.929	26.437.712	26.506.805	26.577.650
PET	20.454.972	20.529.442	20.603.334	20.680.445	20.756.972	20.833.277	20.907.273	20.982.464
Fuerza laboral	10.662.324	10.829.473	10.933.226	10.845.021	10.797.737	10.890.556	11.016.301	11.050.039
Ocupados	9.053.858	9.429.973	9.659.727	9.585.297	9.180.448	9.509.175	9.680.991	9.817.474
Desocupados	1.608.466	1.399.500	1.273.499	1.259.724	1.617.289	1.381.381	1.335.310	1.232.565

Nota: E-M = enero–marzo; A-J = abril–junio; J-S = julio–septiembre; O-D = octubre–diciembre. Las tasas son porcentajes; los demás valores son poblaciones promedio estimadas.

2.2. Evolución por sexo

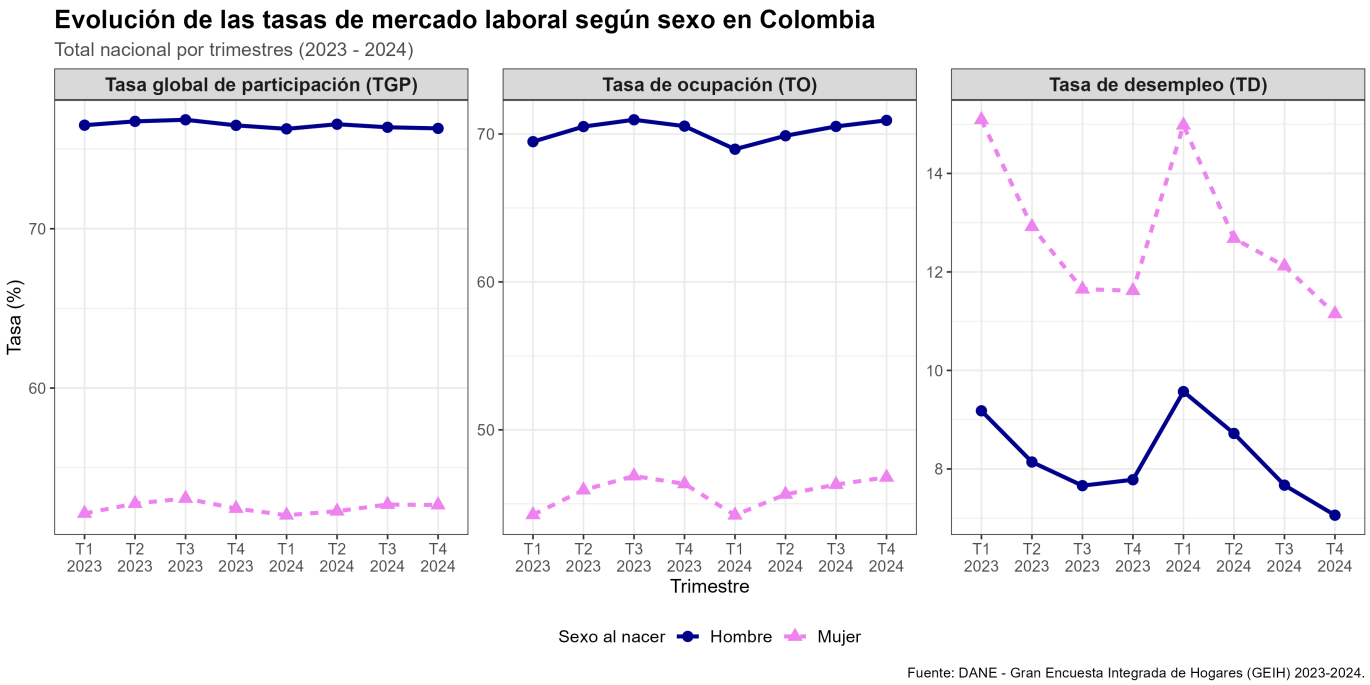


Figura 1: Tasas de participación, ocupación y desempleo por sexo, 2023–2024. Fuente: procesamiento del Grupo 10 con GEIH.

La participación y la ocupación masculinas superan a las femeninas en todos los trimestres, mientras la tasa de desempleo femenina permanece más alta. Entre enero–marzo y octubre–diciembre de 2024, la TD baja de 9,57 % a 7,06 % en hombres y de 14,98 % a 11,15 % en mujeres. La caída combina más ocupación relativa con cambios en participación: la TD no puede explicarse mirando solo el número de desocupados, pues su denominador es la fuerza de trabajo.

2.3. Formalidad en las 13 ciudades: resultado por revisar

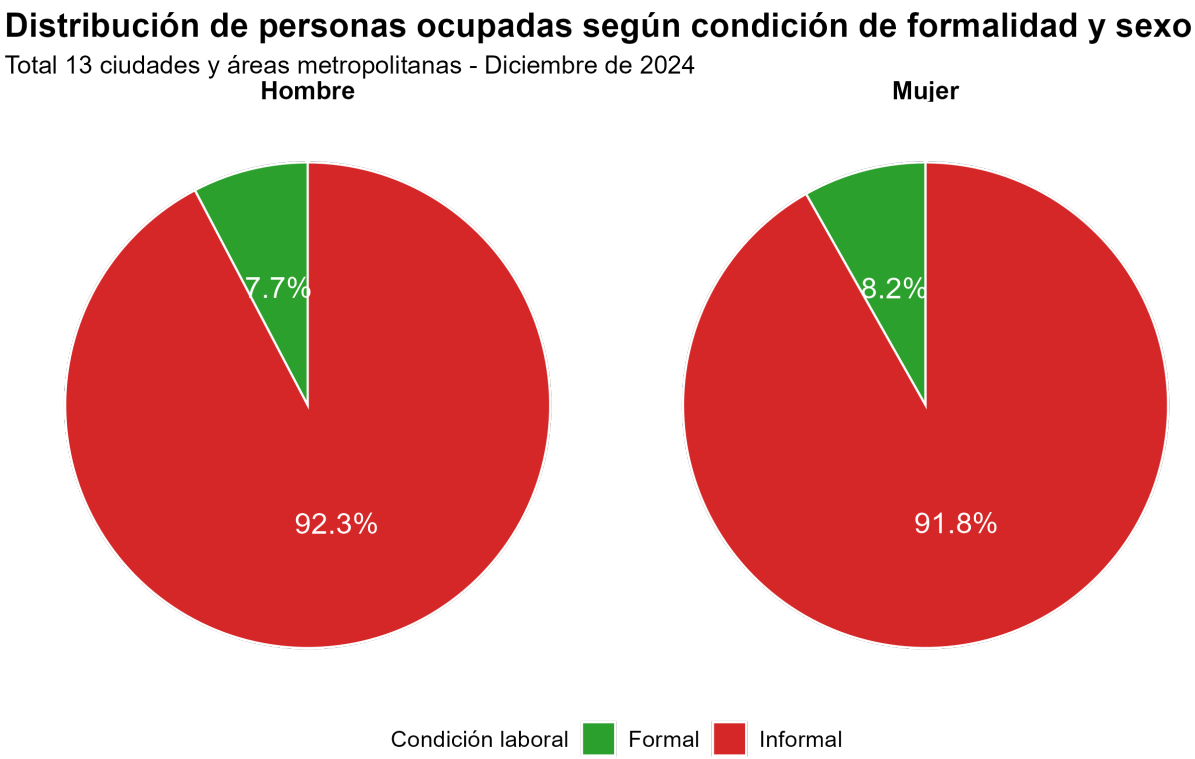


Figura 2: Clasificación de formalidad calculada por el script para diciembre de 2024. Resultado preliminar: requiere corregir o validar EI.

El script filtra ocupados de diciembre de 2024 en las 13 ciudades y aplica una regla sobre tamaño de empresa, posición ocupacional, oficio y cotización a pensión. Su salida clasifica como informales al 92,3 % de los hombres y al 91,8 % de las mujeres. Como contraste, el DANE reporta **42,5 %** de informalidad para las 13 ciudades en octubre–diciembre de 2024 (42,5 % hombres; 42,4 % mujeres) [3]. El período oficial es trimestral y el gráfico del script es mensual, de modo que no son cifras idénticamente comparables; aun así, una brecha cercana a 50 puntos porcentuales exige revisar el filtro geográfico, la codificación y la adaptación de `EI` antes de usar la figura como conclusión sustantiva.

2.4. Posición ocupacional

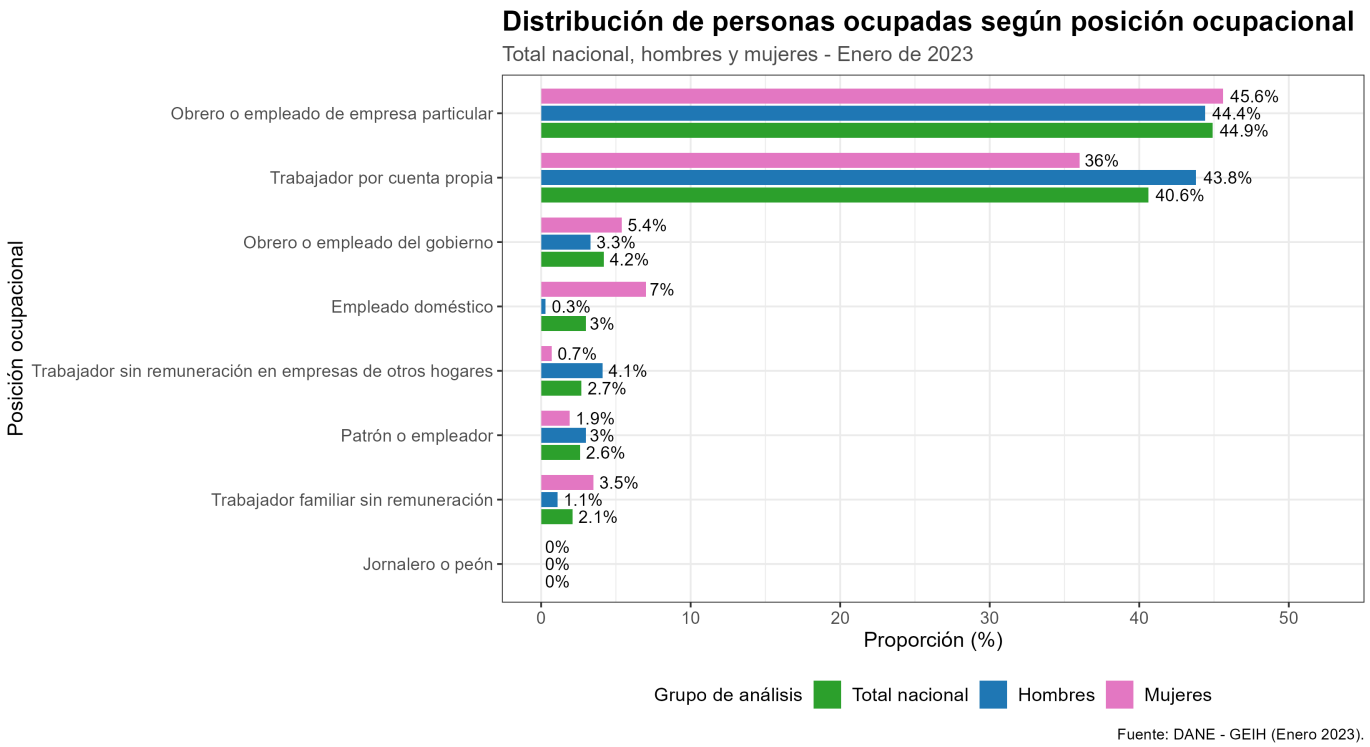


Figura 3: Distribución de ocupados por posición ocupacional y sexo, enero de 2023. Fuente: procesamiento del Grupo 10 con GEIH.

Las proporciones se calculan dentro de total nacional, hombres y mujeres, de manera que cada grupo suma 100 %. La ocupación por cuenta propia (40,6 %) y la de patrones o empleadores (2,6 %) concentran conjuntamente **43,2 %** de la ocupación nacional. Estos dos grupos constituyen la población de referencia para la selección de EMICRON.

3. Micronegocios en Colombia

3.1. Indicadores básicos de 2024

El archivo `3_1_indicadores.xlsx` estima **5.297.252 micronegocios**, exactamente el total publicado por el DANE. El 64,6 % pertenece a hombres y el 35,4 % a mujeres; comercio y reparación de vehículos es la rama más grande (23,9 %), seguida de agricultura (21,5 %). El 22,4 % cuenta con RUT y el 10,3 % figura registrado ante Cámara de Comercio. Estas cifras y las participaciones sectoriales coinciden con el boletín oficial dentro del redondeo [2]. El dominio nacional de EMICRON excluye ocho departamentos de la Amazonía y Orinoquía; por ello no debe confundirse con la cobertura nacional de GEIH [2].

Tabla 6. Selección de indicadores exportados por el script. El detalle de las doce ramas permanece en `3_1_indicadores.xlsx`.

Categoría	Micronegocios	Porcentaje
Total micronegocios	5.297.252	100,0 %
Hombre	3.421.325	64,6 %
Mujer	1.875.927	35,4 %
Agricultura, ganadería, caza, silvicultura y pesca	1.138.758	21,5 %
Industrias manufactureras	531.988	10,0 %
Comercio y reparación de vehículos	1.263.754	23,9 %
Transporte y almacenamiento	628.817	11,9 %
Cuenta con RUT	1.185.978	22,4 %
No registrado	4.749.671	89,7 %
Registrado ante Cámara de Comercio	547.581	10,3 %

3.2. Inclusión financiera

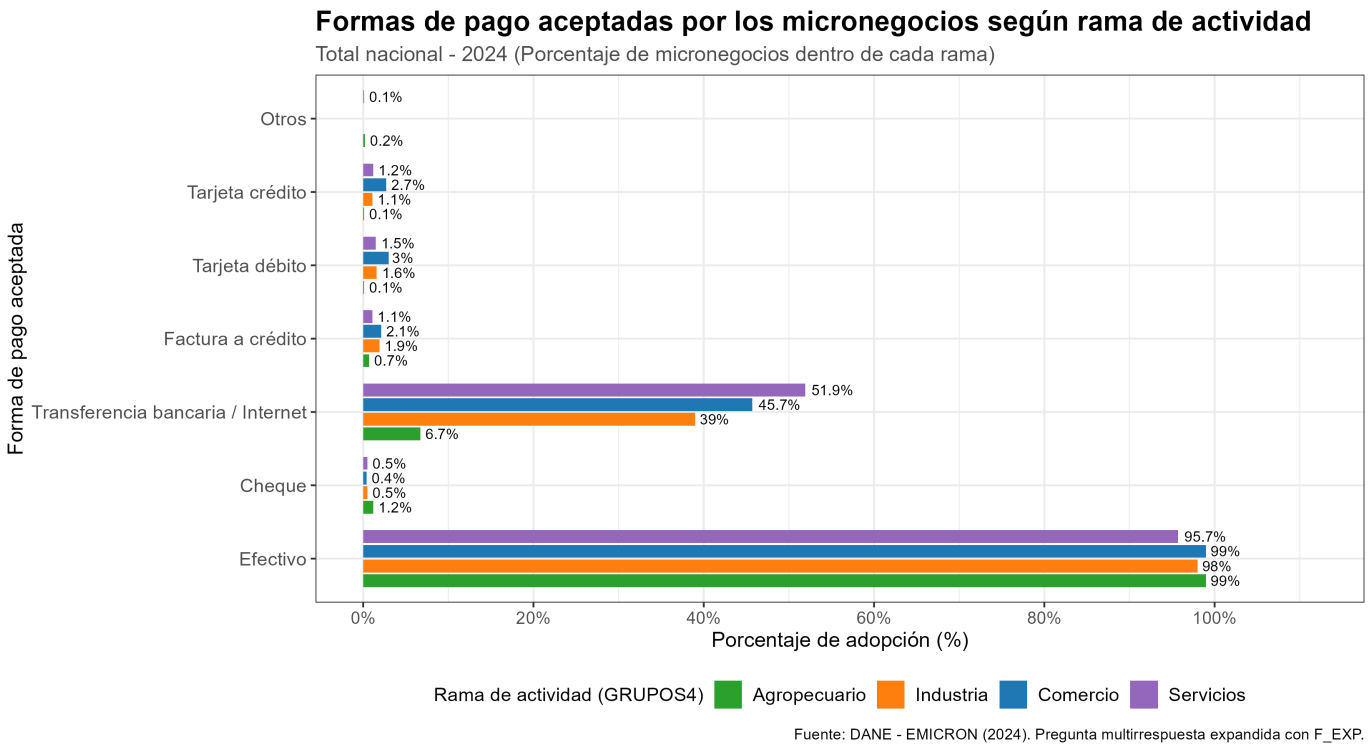


Figura 4: Medios de pago aceptados por rama de actividad, EMICRON 2024. Fuente: procesamiento del Grupo 10 con EMICRON.

El ciclo `for` recorre `P1764_1` a `P1764_7` y calcula con `F_EXP` la aceptación de cada forma de pago por rama. Predominan los medios que no requieren terminal especializado. El script calcula también solicitud de crédito y ahorro, pero no exporta esos porcentajes; falta verificarlos e incorporarlos. El gráfico describe asociaciones, no efectos causales del crédito sobre los medios de pago.

3.3. Educación del propietario y RUT

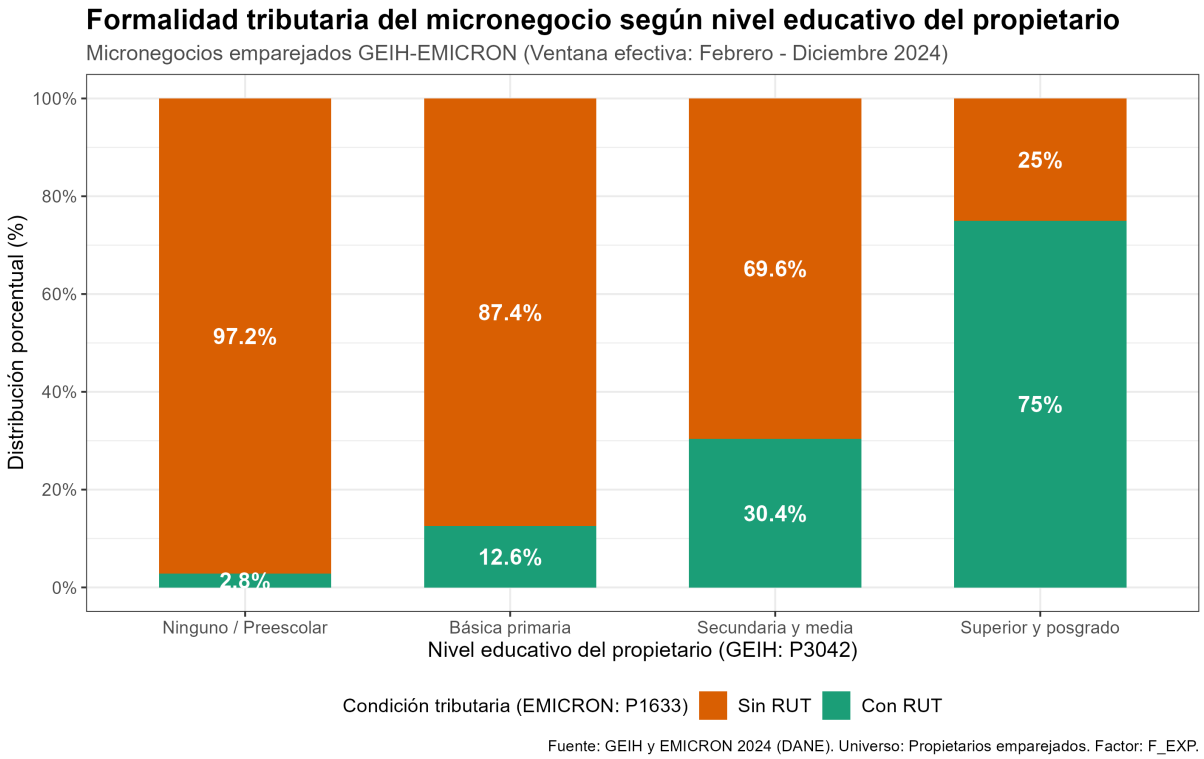


Figura 5: Tenencia de RUT según nivel educativo del propietario enlazado. Fuente: procesamiento del Grupo 10 con GEIH–EMICRON.

La pregunta es si la educación en GEIH (`P3042`) se asocia con la tenencia de RUT en EMICRON (`P1633`). El script calcula una tabla de contingencia con **`F_EXP` solamente** y porcentajes dentro de cada nivel educativo. El universo abarca propietarios enlazados con GEIH 2024 y datos válidos; la ventana efectiva es febrero–diciembre de 2024. El gráfico muestra una asociación descriptiva. Sector, ubicación, ingreso y tamaño del negocio pueden contribuir a ella sin que la educación cause directamente el registro.

La tabla de contingencia está calculada como `tabla_contingencia_cruce` en memoria, pero el script aún no la exporta. Para la versión de entrega debe guardarse desde R en `outputs` e incorporarse aquí junto al gráfico.

4. Análisis socioeconómico: pendiente

El script revisado termina en el numeral 3.3. Aún faltan los tres gráficos distintos exigidos en el punto 4, sus respectivos análisis de máximo 150 palabras y la comprobación de sus condiciones (variables diferentes, desagregación geográfica, al menos una variable porcentual y al menos un gráfico basado en EMICRON o `base_micro`). Esta sección debe completarse con resultados generados por el grupo antes de entregar el informe.

Referencias y notas de verificación

1. DANE. *Gran Encuesta Integrada de Hogares, GEIH 2023 y 2024*. Microdatos, formulario y diccionarios en ANDA 2023 y ANDA 2024.
2. DANE. *Boletín técnico: Encuesta de Micronegocios, EMICRON 2024*. Total, sectores, sexo y registros de formalidad empresarial.
3. DANE. *Boletín técnico: Empleo informal y seguridad social, octubre–diciembre de 2024*. Indicadores de las 13 ciudades y áreas metropolitanas.

Controles previos a la entrega. Resolver la discrepancia de 2.3; exportar la tabla de 3.3 y los porcentajes de crédito y ahorro; completar la cifra exacta de 2.4 y el punto 4; y revisar que cada integrante pueda justificar código, resultados y decisiones metodológicas. Las tablas y gráficos anteriores proceden de los archivos que genera `Taller2_Grupo_10.R`; el PDF no reejecuta los microdatos.

Anexo. Declaración de uso de inteligencia artificial

Borrador editable; el grupo debe completar y verificar esta declaración antes de la entrega.

Elemento	Declaración que debe completar el grupo
Herramienta	Codex / ChatGPT: precisar versión o servicio utilizado.
Propósito	Revisión, organización y refinamiento de un borrador explicativo basado en el script y las salidas preexistentes del grupo.
Contenido tratado	Identificar los numerales, párrafos, tablas, figuras y verificaciones concretas en las que se utilizó la herramienta.
Revisión humana	Describir quién contrastó el texto con el código, los archivos exportados, el enunciado y las publicaciones del DANE; indicar las correcciones realizadas.
Decisiones pendientes	Documentar la corrección de formalidad, el punto 4 y cualquier modificación posterior del informe.

Esta plantilla no sustituye la declaración factual del grupo. El enunciado exige declarar todo uso efectivo de IA y limita su papel a editar, revisar o refinar trabajo elaborado por los estudiantes.