Universidad de los Andes Colombia | Facultad de Economía

Taller 2
Taller de programación en R

Facultad de Economía, Universidad de los Andes

Fecha máxima de entrega: domingo 11 de octubre de 2026, 11:59 p.m.

Aspectos generales.

El presente taller busca que los estudiantes apliquen los conceptos desarrollados durante las clases magistrales de las semanas 6 a 9 del curso. Asimismo, los ejercicios propuestos tienen como propósito fortalecer la comprensión del uso de R y de las herramientas trabajadas en clase, así como fomentar un razonamiento lógico que permita abordar, implementar e interpretar adecuadamente los problemas planteados.

El Taller 2 **deberá desarrollarse exclusivamente en los grupos de tres (3) estudiantes previamente establecidos**. Para este taller **no se aceptarán entregas individuales ni entregas realizadas por grupos diferentes a los conformados previamente**. Las entregas que no cumplan esta condición no serán calificadas. Será suficiente con que uno de los integrantes del grupo realice la entrega en representación de sus compañeros.

El taller deberá entregarse en la fecha indicada a través de la plataforma Bloque Neón. No se aceptarán entregas por medios distintos a este. Se recomienda leer cuidadosamente la totalidad del enunciado antes de iniciar su desarrollo, con el fin de comprender de manera integral las actividades, productos y requerimientos solicitados.

Carga de trabajo esperada. El taller ha sido diseñado considerando una dedicación aproximada de **6 horas de trabajo por estudiante durante las cuatro semanas** previstas para su desarrollo. Esta dedicación comprende la preparación y procesamiento de las bases de datos, el desarrollo y verificación del código, la elaboración de tablas y gráficos, la interpretación de los resultados y la preparación para la sesión de entrevista. Se espera que el grupo distribuya adecuadamente el trabajo durante el periodo disponible y evite concentrar su desarrollo en los días previos a la entrega. La distribución de tareas entre los integrantes **no exime a ninguno de ellos de comprender la totalidad del trabajo entregado**.

Los ejercicios han sido diseñados para resolverse con los temas, métodos, herramientas y consideraciones abordados en el curso hasta la fecha de entrega. Salvo cuando el enunciado de un literal lo autorice explícitamente, no se permite el uso de paquetes, funciones o herramientas adicionales que no hayan sido trabajados en clase.

La nota ordinaria del taller se distribuye en partes iguales entre dos componentes. **La evaluación práctica**, correspondiente a la entrega realizada por el grupo, representa el 50 % de la nota y tiene un valor de **2,5 puntos**. La **sesión de entrevista por grupos** representa el 50 % restante y tiene igualmente un valor de **2,5 puntos**. Cada integrante deberá estar en capacidad de explicar cualquier parte del código entregado, justificar las decisiones metodológicas adoptadas e interpretar los resultados obtenidos.

La nota máxima del taller es 5,25 / 5,0,
considerando el bono establecido en el punto 4.

Sobre plagio y uso de inteligencia artificial.

La copia y el plagio están estrictamente prohibidos. Incurrir en estas prácticas implicará una **nota de cero (0,0) en el taller**, sin perjuicio de las actuaciones o sanciones que procedan de acuerdo con el reglamento de estudiantes de la Universidad.

De acuerdo con los lineamientos institucionales, este taller se encuentra en **Nivel 3 de uso de inteligencia artificial**. En consecuencia, las herramientas de inteligencia artificial generativa (IAG) podrán utilizarse como apoyo para editar, revisar o refinar ideas, explicaciones o código previamente elaborado por el grupo. No está permitido delegar en estas herramientas la elaboración sustantiva de la solución ni copiar y pegar directamente código, análisis o respuestas generadas por IAG como si fueran de autoría propia. El contenido entregado deberá ser de autoría del grupo y **todos sus integrantes deberán estar en capacidad de explicar, justificar y, cuando se solicite, modificar el código y los análisis presentados durante la sesión individual de entrevista**.

Todo uso de herramientas de IAG deberá ser declarado. Para ello, la entrega deberá incluir un anexo breve, que no contará dentro del límite de páginas del documento, en el que se indique la herramienta utilizada, el propósito de su uso, el contenido sobre el cual se utilizó y la forma en que el grupo revisó, verificó o modificó la respuesta obtenida.

La ausencia del anexo no será interpretada como evidencia de que no se utilizó inteligencia artificial. Si se utilizó IAG, su declaración es obligatoria y deberá corresponder de manera transparente con el uso efectivamente realizado.

La omisión total o parcial de esta declaración cuando se haya utilizado IAG constituye un incumplimiento de las condiciones del taller. Cuando existan indicios de uso de inteligencia artificial no declarado a partir de la revisión de la entrega, el código, la documentación presentada, herramientas de apoyo a la revisión u otra evidencia, estos serán contrastados con el anexo presentado y con el desempeño individual de los integrantes durante la entrevista.

Si a partir de esta revisión se establece que se presentó como propio contenido generado mediante un uso de IAG **no permitido o no declarado**, el caso será tratado de acuerdo con las disposiciones sobre plagio y fraude académico y **la nota del taller será de cero (0,0)**, además de las actuaciones institucionales a que haya lugar.

Los lineamientos institucionales sobre el uso de inteligencia artificial pueden consultarse en el enlace correspondiente de la Universidad en el siguiente link:
https://secretariageneral.uniandes.edu.co/images/documents/lineamientos-uso-inteligencia-artificial-generativa-IAG-uniandes.pdf

Uso de herramientas y librerías
Solo se permite el uso de herramientas, funciones y librerías trabajadas en clase hasta la fecha de entrega. El uso de herramientas adicionales está prohibido, salvo cuando el enunciado de un literal lo autorice expresamente.

Cada grupo debe entregar:

- Un script de R, organizado por puntos y subpuntos, con comentarios claros y con las verificaciones de llaves, conteos y consistencia solicitadas en el enunciado. El código será ejecutado en su totalidad durante el proceso de calificación y deberá correr de principio a fin, sin errores ni intervención manual, desde una sesión limpia de R. No solo se evaluarán

los resultados obtenidos, sino también el uso adecuado de las herramientas y procedimientos trabajados en clase.
- Un documento en formato PDF, de máximo ocho (8) páginas, sin contar el anexo de uso de IAG, que incluya las interpretaciones, tablas, gráficos y explicaciones solicitadas en cada punto. Cuando un numeral no requiera un producto adicional al código, podrá incluirse una breve explicación metodológica en el documento.
- Una carpeta denominada outputs, que contenga todas las tablas y gráficos exportados desde R. Los elementos incluidos en el documento deberán haber sido generados y exportados directamente por el script y sus nombres de archivo deberán corresponder al numeral del taller. Por ejemplo: 2_1_tasas_hombres.xlsx y 2_1_tasas_mujeres.xlsx.

El script deberá utilizar una única ruta base declarada al inicio, por ejemplo, mediante un objeto denominado ruta, de manera que todo el código pueda ejecutarse modificando únicamente dicha línea. Si el código no puede ejecutarse completamente cambiando solo la ruta base, la nota de la evaluación práctica será cero (0,0).

A. Evaluación práctica (2,5 puntos)

1. Conformación y unión de las bases de datos (0,8 puntos).

Este taller tiene dos propósitos. El primero, es replicar la construcción de algunos de los principales indicadores de mercado laboral de Colombia. El segundo, es caracterizar a los micronegocios del país y vincularlos con las características sociodemográficas de las personas que los tienen. Para ello se utilizarán dos operaciones estadísticas del DANE que están relacionadas:

- **Gran Encuesta Integrada de Hogares (GEIH).** Microdatos disponibles en el Archivo Nacional de Datos (ANDA) del DANE en los siguientes enlaces: https://microdatos.dane.gov.co/index.php/catalog/782 y https://microdatos.dane.gov.co/index.php/catalog/819.

- **Encuesta de Micronegocios (EMICRON) 2024.** Microdatos disponibles en: https://microdatos.dane.gov.co/index.php/catalog/875.

La EMICRON es una encuesta independiente de la GEIH, pero su muestra es un subconjunto de la muestra mensual de la GEIH. Cada mes, la GEIH identifica a los ocupados que son trabajadores por cuenta propia o patrones de unidades productivas de hasta nueve (9) personas ocupadas, y a una parte de ellos se les aplica en un segundo momento el cuestionario de la EMICRON. Esta relación de inclusión tiene una consecuencia que será central en el punto 1.4: **todo registro de la EMICRON proviene de un hogar que la GEIH entrevistó**, mientras que solo una fracción de los registros de la GEIH tiene contraparte en la EMICRON. Entender esta asimetría, y sus implicaciones sobre lo que se debe esperar del pegue, es parte del ejercicio y deberá quedar documentada en el informe.

Los microdatos deberán ordenarlos según las carpetas que se adjuntan con los nombres “GEIH_2023”, “GEIH_2024” y “EMICRON_2024”. Solo deberán tener en cuenta las bases en formato .csv y su nombre no debe cambiarse para garantizar que el código entregado corra solo cambiando el directorio en el que se encuentran ubicadas las carpetas mencionadas. Las bases de datos que deben tener en cuenta para resolver el taller son las siguientes:

De la GEIH 2023 y 2024:

1. Características generales, seguridad social en salud y educación.
   Este capítulo brinda las características generales de la población tales como sexo, edad, nivel educativo, afiliación a seguridad social, entre otras características. Esta base contiene los registros del total de las personas encuestadas.

2. Fuerza de trabajo.
   Este capítulo permite caracterizar a la Población en Edad de Trabajar (PET) entre población en la Fuerza de Trabajo (población ocupada o desocupada) o Fuera de la Fuerza de Trabajo (FFT). Esta base contiene los registros de la PET (15 años y más).

3. Ocupados.
   Este módulo brinda la información de las características de la PET clasificada como ocupada y de sus empleos. Es, con diferencia, el módulo más ancho de la encuesta: contiene alrededor de doscientas variables.

4. No ocupados.
   Este capítulo caracteriza a la PET clasificada como no ocupada, es decir, todas las personas desocupadas o la población fuera de la fuerza de trabajo.

De la EMICRON 2024:

5. Módulo de identificación.
   Contiene la identificación del micronegocio, las características básicas del propietario (sexo P35, edad P241), el mes de referencia (MES_REF), la ubicación (COD_DEPTO, AREA, CLASE_TE), la rama de actividad agrupada (GRUPOS4 y GRUPOS12) y el factor de expansión anual (F_EXP).

6. Módulo de características del micronegocio.
   Contiene la información de registro y formalidad del micronegocio (RUT, régimen, Cámara de Comercio, declaraciones tributarias y tipo de contabilidad).

7. Módulo de inclusión financiera.
   Contiene las formas de pago que acepta el micronegocio, la solicitud y obtención de crédito, el destino de los recursos y el comportamiento de ahorro.

8. Módulo de ventas o ingresos.
   Contiene los ingresos del micronegocio por tipo de actividad y las ventas o ingresos del mes de referencia (VENTAS_MES_ANTERIOR).

Una vez se descarguen y ordenen las bases de datos, deberán desarrollar los siguientes puntos:

1.1 Pegue de las bases de datos de la GEIH (0,2 puntos)

Deberá crear la base de datos de la GEIH. Para ello, debe crear un loop que realice el merge de los datos de enero a diciembre para los años 2023 y 2024. El loop deberá tomar las bases de cada año y mes para realizar el pegue teniendo en cuenta que el módulo básico para construir la información mensual es “Características generales, seguridad social en salud y educación.CSV”, el cual contiene la información de todas las personas encuestadas para cada mes. Una vez se construya la base de cada mes, se integrarán para construir la base total del año.

Tenga en cuenta que en la GEIH la llave para el merge de los registros está compuesta por las variables DIRECTORIO, SECUENCIA_P y ORDEN. Consulte a qué hace referencia cada una de estas y consigne dicha información en el documento. Asimismo, describa las generalidades de la GEIH, las cuales podrá consultar en los materiales relacionados en el enlace del ANDA referenciado anteriormente y en los boletines de mercado laboral publicados por el DANE mensualmente. También, incluya una descripción de la lógica utilizada para construir el loop para el merge de las bases.

Incorpore en su código dos verificaciones y repórtelas en el documento: que la llave de persona no tenga registros duplicados en ninguno de los módulos, y que ningún pegue aumente el número de registros del módulo base. Un merge que multiplica filas es el error más común y difícil de detectar después.

Consideración sobre el manejo eficiente de los datos: tenga en cuenta que la base anual de la GEIH contiene un número elevado de registros y variables. Por esta razón, las decisiones adoptadas durante la importación, procesamiento, unión y consolidación de los módulos pueden afectar de manera importante el uso de memoria y el tiempo de ejecución del código.

El grupo deberá identificar e implementar una estrategia adecuada para realizar este procesamiento de manera eficiente, utilizando únicamente las herramientas trabajadas en el curso. Tanto la estrategia seleccionada como su implementación harán parte de la evaluación del punto. En el documento, describa brevemente las decisiones adoptadas para manejar el tamaño de los datos y presente evidencia que permita sustentar que la estrategia implementada es adecuada.

1.2 Descripción general de los datos (0,1 puntos)

Uno de los elementos clave de un analista de datos es entender las bases que está trabajando. En este punto deberá realizar una descripción básica de la base de datos de la GEIH 2024. Para tal fin, cree una tabla en la que describa el tamaño total de la muestra para cada mes y el total del año 2024. Asimismo, debe incluir el número de observaciones para cada uno de los módulos de la encuesta que deben tenerse en cuenta en este ejercicio (características generales, fuerza de trabajo, ocupados, no ocupados). Explique a qué se debe la diferencia en el número de observaciones de cada una de estas bases de datos y verifique que la relación entre ellas sea la que usted espera a partir de las definiciones de PET, fuerza de trabajo, ocupados y desocupados. Para ello, podría consultar el Formulario y Manual de recolección y conceptos básicos de la GEIH.

1.3 Construcción y documentación de la base analítica (0,1 puntos)

La GEIH contiene una gran cantidad de variables distribuidas entre sus diferentes módulos. Para reducir el uso de memoria y construir una base adecuada para los análisis posteriores, dentro del loop desarrollado en el punto 1.1 deberá conservar únicamente las variables que se relacionan a continuación, según el módulo del que provienen:

a) Características generales, seguridad social en salud y educación: DIRECTORIO, SECUENCIA_P, ORDEN, PERIODO, MES, P3271, P3042, P6090, P6040, P6160, DPTO, AREA, CLASE, FEX_C18, PT.
b) Fuerza de trabajo: PET, FT, FFT, P6240.
c) Ocupados: OCI, RAMA2D_R4, P6430, INGLABO.
d) No ocupados: DSI.
e) Identifique y conserve las variables necesarias para construir la variable de formalidad requerida en el punto 2.3.

Una vez finalizado el proceso de construcción, verifique programáticamente que la base analítica contenga únicamente las variables señaladas en los literales a) a d), las variables adicionales identificadas en el literal e) para construir el indicador de formalidad y la variable ANIO, que deberá construir a partir de PERIODO.

A partir del formulario, diccionario y manual de recolección de la GEIH, identifique qué mide cada variable y construya en el documento una tabla de diccionario de variables que contenga, como mínimo: variable, módulo de origen, descripción y categorías o unidad de medida, cuando corresponda. Realice este ejercicio únicamente para las variables incluidas en los literales a) a d).

En el código, **construya las etiquetas necesarias para que las categorías utilizadas posteriormente sean interpretables en tablas y gráficos**. Por ejemplo, P3271 deberá permitir identificar las categorías "Hombre" y "Mujer", en lugar de presentar únicamente sus códigos numéricos (1 y 2, para este caso). Finalmente, explique brevemente la diferencia conceptual entre DPTO, AREA y CLASE y señale por qué no son variables intercambiables.

1.4 Incorporación de la EMICRON 2024 y unión con la GEIH (0,4 puntos)

En este punto construirá la base que integra las dos encuestas. Este ejercicio busca evaluar su capacidad para identificar y resolver los problemas que pueden surgir al integrar bases de datos provenientes de distintas fuentes. La dificultad no está únicamente en ejecutar un merge, sino en establecer correctamente las variables de identificación, comprender la relación entre las dos encuestas y evaluar la calidad del resultado obtenido. Desarrolle los siguientes literales en orden y documente las decisiones adoptadas y las verificaciones realizadas.

a. Construcción de la base de la EMICRON (0,05 puntos). Importe los cuatro módulos de la EMICRON 2024 señalados anteriormente y construya una única base a partir de ellos, utilizando como llave las variables DIRECTORIO, SECUENCIA_P y SECUENCIA_ENCUESTA.

Durante este proceso, identifique y resuelva los problemas que puedan surgir como consecuencia de la estructura y contenido de los diferentes módulos. Implemente las verificaciones que considere necesarias para evaluar la calidad de la base resultante y documente brevemente en el informe las decisiones adoptadas durante su construcción.

b. Documentación de la relación entre las dos encuestas (0,05 puntos). Consultando la metodología, el boletín técnico de la EMICRON y la presentación de resultados de 2024[1], explique en el documento: (i) cómo se selecciona la muestra de la EMICRON a partir de la GEIH y qué población es elegible; (ii) cuál es la cobertura geográfica de la EMICRON y en qué se diferencia de la de la GEIH; (iii) qué mide el factor de expansión F_EXP y por qué no puede utilizarse indistintamente con FEX_C18; y (iv) cuál es el período de referencia de las preguntas de la EMICRON. Este último punto será decisivo en el literal siguiente.

c. Determinación de la llave y análisis del período de referencia (0,1 puntos). La GEIH identifica a las personas mediante las variables DIRECTORIO, SECUENCIA_P y ORDEN. Los microdatos publicados de la EMICRON no incluyen la variable ORDEN, sino SECUENCIA_ENCUESTA. Adicionalmente, ambas encuestas contienen variables asociadas al mes (MES en la GEIH y MES_REF en la EMICRON), cuya interpretación no necesariamente es equivalente.

[1] Puede acceder a los anexo y presentaciones de la EMICRON en el siguiente link: https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral/micronegocios/micronegocios-historicos#2024

Antes de realizar el pegue entre las dos encuestas, deberá establecer empíricamente y documentar los siguientes aspectos:

- *Qué identifica exactamente SECUENCIA_ENCUESTA y cuál es su relación con ORDEN de la GEIH.* Examine su distribución de frecuencias y, en particular, los valores que toma dentro de los hogares observados en la EMICRON. Utilice esta evidencia para determinar cómo debe construirse la llave de identificación entre ambas encuestas. La conclusión deberá sustentarse en los datos y no únicamente en el nombre de las variables.

- *Cuál es la relación entre MES_REF de la EMICRON y MES de la GEIH.* Una vez identificadas las personas potencialmente comunes entre ambas fuentes, compare el mes registrado en las dos encuestas. Evalúe al menos tres hipótesis: correspondencia en el mismo mes, diferencia de un mes hacia atrás y diferencia de un mes hacia adelante. Presente una tabla que permita establecer empíricamente cuál de estas relaciones predomina y explique el resultado utilizando el período de referencia de la EMICRON documentado en el literal b.

Importante: MES_REF y MES no deben incorporarse a la llave utilizada para realizar el pegue. Su comparación tiene como propósito identificar y explicar la relación temporal entre las dos encuestas y constituye una validación adicional del enlace. No construya llaves artificiales ni descarte observaciones para aumentar la correspondencia.

d. Pegue de las dos encuestas (0,05 puntos). Con la llave de identificación establecida en el literal anterior, pegue la base de la EMICRON con la base de la GEIH solo para el año 2024. El pegue deberá realizarse únicamente a partir de las variables que identifican a la persona; no incluya MES_REF, MES ni transformaciones de estas variables dentro de la llave. Llame a la base resultante base_micro.

Verifique programáticamente que el pegue no aumente el número de filas de la EMICRON. Si esto ocurre, examine la unicidad de la llave en ambas bases, identifique la causa de la multiplicación de registros y corríjala antes de continuar. Reporte el número y porcentaje de registros de la EMICRON que encontraron contraparte en la GEIH.

e. Validación de la calidad del pegue (0,05 puntos). Que un pegue devuelva muchas filas no significa que haya emparejado a la persona correcta. Para comprobarlo, aproveche que las dos encuestas miden de manera independiente algunas características del propietario y de su ubicación: contraste el sexo reportado en la EMICRON (P35) con el de la GEIH (P3271), la edad de la EMICRON (P241) con la de la GEIH (P6040) y la clase geográfica de la EMICRON (CLASE_TE) con la de la GEIH (CLASE). Reporte el porcentaje de coincidencia de cada una de las tres. Si la llave de identificación y el pegue son correctos, estos porcentajes deben ser prácticamente perfectos; un emparejamiento alto acompañado de una coincidencia baja indica que el pegue está uniendo registros equivocados y debe corregirse.

f. Auditoría del pegue (0,05 puntos). Construya y presente una tabla de auditoría por mes que reporte los registros de la EMICRON, los emparejados, el porcentaje de correspondencia y los no emparejados. **Dado que la muestra de la EMICRON se deriva de la GEIH, se espera una correspondencia muy alta entre ambas fuentes para los registros cuya entrevista GEIH se encuentre dentro de los archivos disponibles para el ejercicio.** Una correspondencia sustancialmente inferior a la esperada puede ser señal de un error en la construcción de la llave o en el tratamiento de las variables de identificación. Por ejemplo, tipos de dato incompatibles, pérdida de ceros a la izquierda o una llave de identificación incorrectamente construida. En un párrafo de máximo 200 palabras identifique cuál es la razón estructural por la que un subconjunto acotado y

predecible de registros de la EMICRON no puede tener contraparte dentro de los archivos de 2024, y cuantifíquelo.

Complementariamente, utilice la comparación entre MES_REF y MES desarrollada en el literal c para describir la relación temporal observada entre las dos encuestas.

g. Interpretación (0,05 puntos). Sobre la base enlazada, construya la distribución de la posición ocupacional (P6430) que declararon en la GEIH las personas que la EMICRON identifica como propietarias de un micronegocio. La gran mayoría serán trabajadores por cuenta propia y patrones, que es la población de la que se selecciona la encuesta, pero encontrará también categorías inesperadas. Explique en máximo 150 palabras qué significa que una persona aparezca en la EMICRON como propietaria de un micronegocio y declare en la GEIH una posición ocupacional, y qué implica ese hecho para la medición del empleo.

2. Construcción de los principales indicadores de mercado laboral (0,7 puntos).

En este punto se replicarán algunos de los indicadores de mercado laboral de Colombia. Por tanto, los datos mensuales que obtenga deberán coincidir con los publicados por el DANE en sus anexos estadísticos de empleo, los cuales podrán consultar en el siguiente enlace: https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral.

2.1 Tasas y poblaciones (0,25 puntos)

Construya una tabla como la que se muestra abajo con los principales indicadores de mercado laboral para el total nacional según sexo (hombres y mujeres) para los trimestres enero-marzo, abril-junio, julio-septiembre y octubre-diciembre para 2023 y 2024. Para ello, identifique la variable con la información del sexo al nacer, construya dos dataframe y posteriormente expórtelos como tablas de Excel con los nombres 2_1_tasas_hombres.xlsx y 2_1_tasas_mujeres.xlsx. Las tablas deberá incluirlas en el documento. Para la exportación se autoriza de manera explícita el uso del paquete openxlsx o writexl.

La estructura de cada tabla debe ser la siguiente:

Tasas (%) y poblaciones	Enero-marzo 2023	…	Octubre - diciembre 2024
Tasa global de participación (TGP)			
Tasa de ocupación (TO)			
Tasa de desempleo (TD)			
Población total			
Población en edad de trabajar (PET)			
Fuerza de trabajo			
Población ocupada			
Población desocupada			

Puede consultar las definiciones de las tasas y poblaciones en el boletín técnico en el enlace señalado en el encabezado del segundo punto o en el Manual de recolección de la GEIH en el enlace del ANDA. En este punto y en adelante, tenga en cuenta que para obtener los datos

poblacionales deberá expandir los datos muestrales con la variable FEX_C18.[2] Incluya en su código una verificación de consistencia entre la fuerza de trabajo, la población ocupada y la población desocupada, y explique brevemente el resultado en el documento.

2.2 Análisis de las tasas de mercado laboral (0,15 puntos)

Con base en los dataframe construidos en el punto anterior, cree un gráfico de serie de tiempo en el que se muestre el comportamiento de la TGP, TO y TD para el total nacional en los periodos analizados según sexo. Utilice paneles o facetas con escalas claramente rotuladas para presentar cada tasa y mostrar su comportamiento diferenciado entre hombres y mujeres.

Por favor, incluya título, colores y marcadores diferenciados para cada tasa, labels, leyenda, título de los ejes, fuente y período, y demás elementos que permitan obtener una gráfica autocontenida. Exporte el gráfico como 2_2_tasas_sexo.png en la carpeta “outputs”. Explique e interprete en el documento el comportamiento de las tres tasas y las brechas según sexo que observa. En particular, qué puede concluirse sobre el origen de la variación de la tasa de desempleo a lo largo de los periodos a partir de la tendencia conjunta de la participación y la ocupación.

2.3 Población ocupada según formalidad (0,2 puntos)

Cree un gráfico de torta (pie) con la distribución de las personas ocupadas según formalidad y sexo en el mes de diciembre de 2024 para el total de las 13 ciudades y áreas metropolitanas[3]. Recuerde comparar los resultados que obtenga con los presentados por el DANE en el respectivo anexo estadístico.

Para calcular la población ocupada formal e informal, deberá adaptar a lenguaje R el código que presenta el DANE en el anexo estadístico de Empleo informal y seguridad social. Con este obtendrá una variable EI=1 para la población formal y EI=0 para la población informal.

Luego de ello, cree un nuevo dataframe con el total expandido (aplicando el factor de expansión para el mes) del número de personas ocupadas formales e informales en el total de las 13 ciudades y según sexo. Con esta información cree el gráfico, que deberá incluir título, leyenda, labels, y etiquetas de los datos en porcentaje, título de los ejes y demás elementos que considere necesarios para que sea autocontenido. Expórtelo como 2_3_formalidad_13ciudades.png en la carpeta “outputs”, inclúyalo en el documento y explique lo que encuentra en este.

2.4 Población ocupada según posición ocupacional (0,10 puntos)

Cree un gráfico de barras horizontales de personas ocupadas según posición ocupacional para el mes de enero de 2023 para el total nacional y según sexo. Para crearlo ordene las posiciones ocupacionales de mayor a menor y muestre en un solo gráfico el total nacional, hombres y mujeres.

Para crear este gráfico, filtre la base final solamente para el mes de enero de 2023, use las variables P6430, OCI y P3271, y cree un nuevo dataframe con el total expandido del número de personas ocupadas por posición ocupacional. A partir de esto, debe crear una variable con la proporción de

[2] Esto quiere decir que, para obtener información agregada a nivel nacional y no muestral, cuando se combinen varios meses para estimar poblaciones promedio del período, deberá ajustarse el factor de expansión según el número de meses incluidos. Por ejemplo, para estimaciones promedio trimestrales se divide entre 3 y para estimaciones promedio anuales entre 12.”

[3] Las 13 ciudades y áreas metropolitanas definidas en la GEIH son: Bogotá D.C., Medellín A.M., Cali A.M., Barranquilla A.M., Bucaramanga A.M., Manizales A.M., Pereira A.M., Cúcuta A.M., Pasto, Ibagué, Montería, Cartagena y Villavicencio. Para identificar las 13 ciudades y áreas metropolitanas debe usar la variable AREA seleccionada en el punto 1.3. Consulte en el diccionario de la encuesta los códigos que identifican estas áreas y documente en el informe la diferencia entre el dominio de las 13 ciudades y el total nacional.

personas ocupadas por cada posición ocupacional y ordenarlas según tamaño. Calcule las proporciones dentro de cada grupo de análisis, es decir, total nacional, hombres y mujeres, de manera que sumen 100 % en cada caso. El gráfico deberá tener título, leyenda, etiquetas de los datos en porcentaje y demás elementos que considere necesarios para que sea autocontenido. Expórtelo como 2_4_posicion_nacional.png en la carpeta “outputs”, inclúyalo en el documento y explique lo que encuentra en este.

En su interpretación, señale qué proporción de la ocupación total concentran en conjunto los trabajadores por cuenta propia y los patrones o empleadores, y explique por qué esa cifra es relevante para el punto siguiente.

3. Caracterización de los micronegocios en Colombia (0,4 puntos).

Los micronegocios concentran una parte sustancial del empleo del país y son, en su mayoría, unidades informales. La EMICRON es la fuente oficial para caracterizarlos. En este punto usará primero la EMICRON de manera autónoma y luego la base base_micro construida en el punto 1.4. Todas las cifras poblacionales de micronegocios deben expandirse con la variable F_EXP.

3.1 Indicadores básicos de los micronegocios (0,1 puntos)

Construya un dataframe y expórtelo como 3_1_indicadores.xlsx con la siguiente información, para el total nacional en 2024: (i) el número total de micronegocios; (ii) su distribución por rama de actividad usando la variable GRUPOS12; (iii) su distribución según el sexo del propietario (variable P35); (iv) el porcentaje de micronegocios que cuentan con Registro Único Tributario (variable P1633); y (v) el porcentaje registrado ante Cámara de Comercio (variable P1055).

Compare sus resultados con las cifras publicadas por el DANE en el boletín técnico de la EMICRON 2024, disponible en https://www.dane.gov.co/files/operaciones/EMICRON/bol-EMICRON-2024.pdf. Esta comparación es una verificación obligatoria: el total de micronegocios que usted obtenga debe reproducir el publicado por el DANE, y las distribuciones por sexo y por rama deben coincidir dentro del redondeo. Una diferencia apreciable indica un error en el uso del factor de expansión o en la construcción de la base, no una particularidad de sus cálculos. Reporte explícitamente las diferencias encontradas y explique a qué las atribuye.

3.2 Inclusión financiera de los micronegocios (0,15 puntos)

El módulo de inclusión financiera registra, mediante un conjunto de variables dicotómicas (P1764_1 a P1764_7), las formas de pago que acepta cada micronegocio, y captura además la solicitud de crédito (P1765) y el comportamiento de ahorro (P3014).

Construya, a partir de estas variables, un dataframe con el porcentaje expandido de micronegocios que acepta cada forma de pago, desagregado por rama de actividad (variable GRUPOS4). Dado que se trata de siete variables con la misma estructura, deberá resolver este punto sin repetir el mismo bloque de código siete veces: use un loop o una función de la familia apply y documente en el informe la lógica utilizada.

Con esa información cree un gráfico de barras apiladas o agrupadas que permita comparar las formas de pago entre ramas de actividad. El gráfico debe ser autocontenido y exportarse como 3_2_formas_pago.png en la carpeta “outputs”. En un párrafo de máximo 200 palabras interprete los resultados. Preste atención en particular a la distancia entre los medios de pago que no requieren infraestructura y los que sí la requieren, y relacione lo que encuentra con el porcentaje de micronegocios que solicitó crédito y que ahorró.

3.3 Análisis conjunto GEIH – EMICRON (0,15 puntos)

Este punto solo puede resolverse con la base base_micro construida en el punto 1.4 y busca que aprovechen la información que aporta cada encuesta y que la otra no tiene. La EMICRON caracteriza al micronegocio; la GEIH caracteriza a la persona y a su hogar.

Formule de manera explícita una pregunta que solo pueda responderse con las dos fuentes unidas. Para ello, seleccione al menos una variable de la GEIH que no esté disponible en la EMICRON (por ejemplo, nivel educativo P3042, afiliación a seguridad social en salud P6090, ingresos laborales INGLABO o departamento DPTO) y crúcela con al menos una variable de la EMICRON (por ejemplo, formalidad medida por P1633, rama de actividad GRUPOS12, ventas del mes de referencia VENTAS_MES_ANTERIOR o ahorro P3014).

Debe presentar dos productos: una tabla de contingencia o de estadísticas descriptivas y un gráfico autocontenido exportado como 3_3_cruce.png. En el documento debe indicar de manera explícita el factor de expansión que utilizó y por qué, asimismo, delimitar el universo y el período que sus cifras representan a partir de la ventana temporal establecida en el punto 1.4. Un análisis que mezcle FEX_C18 y F_EXP en un mismo indicador, o que presente los resultados como representativos del año calendario completo sin delimitar la ventana efectiva, será penalizado. Las conclusiones deben ser descriptivas: si encuentra una asociación fuerte, explique al menos dos factores que podrían explicarla sin que exista una relación causal directa.

4. Análisis socioeconómico de la población colombiana (0,6 puntos) – Ejercicio libre.

La GEIH ofrece una gran cantidad de datos más allá de la construcción de los indicadores de mercado laboral. Dada su cobertura nacional y recolección continua, la convierte en una de las principales fuentes de información socioeconómica en Colombia. Con esta, también puede construir indicadores desagregados por edad, nivel educativo, analfabetismo, ingreso laboral, afiliación a seguridad social, entre otros, para el total de la población nacional o por departamento.

En este punto, explore las encuestas y seleccione las variables que considere interesantes para el análisis más allá de las abordadas en los puntos anteriores. Cree tres gráficas y realice un análisis socioeconómico de la población colombiana para el año 2024. La elección temporal es libre (valores anuales, semestrales, trimestrales, mensuales); tengan cuidado al expandir las poblaciones con la variable FEX_C18.

Se tendrá en cuenta la calidad del análisis, la creatividad de las gráficas y que las mismas estén autocontenidas. Expórtelas en formato png en la carpeta “outputs” con nombres que empiecen por 4_1, 4_2 y 4_3 seguidos de una palabra descriptiva (por ejemplo, 4_1_edad.png). Algunos lineamientos básicos:

a. Utilizar 3 tipos de gráficos distintos entre sí y distintos de los ya usados en los puntos 2 y 3, es decir, distintos de series de tiempo en paneles, barras horizontales, torta y barras apiladas o agrupadas. Puede recurrir, por ejemplo, a histogramas, diagramas de caja, gráficos de dispersión, de densidad, de área o mapas de calor.
b. Usar 3 conjuntos distintos de variables para el análisis de cada gráfico.
c. Por lo menos uno de los gráficos debe estar desagregado en unidad geográfica menor al nivel nacional. Por ejemplo, región, departamento, ciudad.
d. Por lo menos uno de los gráficos debe utilizar alguna variable porcentual.
e. Por lo menos uno de los gráficos debe construirse a partir de la base base_micro o de la EMICRON.

f. Deben presentar en párrafos de máximo 150 palabras los resultados asociados a cada uno de los gráficos. ¿Qué encuentran? ¿Por qué es importante a nivel socioeconómico?
g. Cada uno de los tres gráficos, junto con su respectivo análisis, tendrá un valor de 0,20 puntos.
h. El grupo que envíe **los 3 gráficos más interesantes** recibirá **un bono de 0,25** sobre la nota del taller. Los gráficos y reseñas relevantes serán publicados dentro de Bloque Neón.

B. Sesión de entrevista (2,5 puntos)

De acuerdo con el programa del curso, la sesión individual de entrevista corresponde a 2,5 puntos de la nota del Taller 2 y se llevará a cabo en la semana 10 (miércoles 14 de octubre de 2026) en el horario de clase. La asistencia a esta sesión es obligatoria. Si una persona no asiste a la misma, su nota será de 0,0 en este componente.

En la entrevista, cada integrante del grupo deberá estar en capacidad de explicar cualquier parte del código entregado, justificar las decisiones metodológicas tomadas e interpretar los resultados obtenidos. Se evaluará, entre otros: la lógica de los loops y funciones construidas; la relación de inclusión entre la EMICRON y la GEIH y su efecto sobre lo que debe esperarse del pegue; la evidencia con la que se determinó la llave de identificación y se analizó la relación temporal entre MES_REF y MES; la validación de la calidad del pegue mediante variables medidas de forma independiente en las dos encuestas; el uso correcto de los factores de expansión; y la lectura sustantiva de los indicadores.